# データ解析３回
# 回帰分析

藤田 一寿

Ver.20261027

# アイスを売りたい

なるべく在庫を持たずに，
アイスを仕入れるにはどう
すればよいだろう？

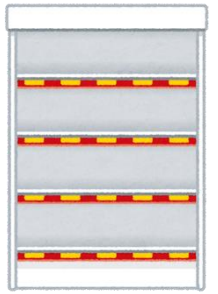




## 心配事



仕入れ量が少ない



商機を失うかも



仕入れ量が多い



在庫が増えるかも

# 予測する



暑い
冷たいものがほしい





暑ければアイスが欲しくなる.
暑い日は多くアイスを仕入れよう！！

# 予測する

明日は今日より暑くなるから
今日の倍のアイスを仕入れよう！！



根拠のない予測



# 結果

やったー！！
予想通り売れまくったぞぉ！！
在庫もなし！！





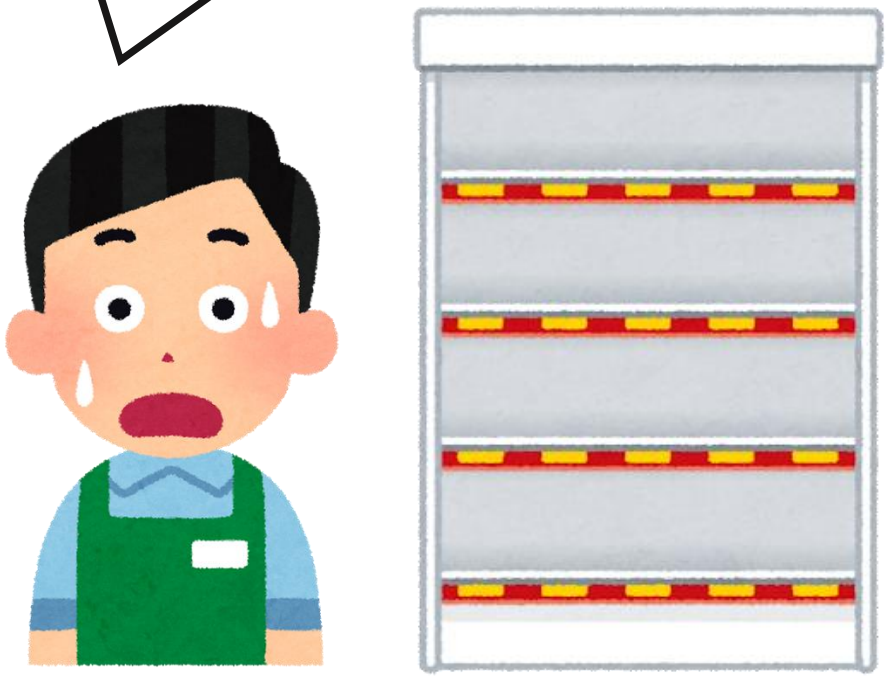
でもね
そんなに上手くいかないよね

# 予想通りにはいかない

全然売れない.
仕入れすぎた…



えっ！？
こんなに売れるの？
全然足りない…



# 何が問題だったか

# 規則性を見つける

- 勘や当てずっぽで仕入れる数量を決めていませんか？



明日は今日より暑くなるから今日の倍
アイスを仕入れよう！！

根拠のない予測

- データに基づいて数量の予測をしましょう.





これまでの気温のデータと販売数から,
明日売れる数を予測しよう.

# 規則性を見つける

- 勘や当てずっぽで仕入れる数量を決めていませんか？



明日は今日より暑くなるから今日の倍
アイスを仕入れよう！！

根拠のない予測

- データに基づいて数量の予測をしましょう.





これまでの気温のデータと販売数から,
明日売れる数を予測しよう.

# データを見よう

# 数値データを見る

## アイスクリームの平均購入額と最高気温などのデータ

| 年 | 月 | アイスクリームの平均購入額 | 日最高気温の平均(℃) | 降水量の合計(mm) | 平均湿度(%) | 日最高気温25℃以上日数(日) |
|---|---|---|---|---|---|---|
| 2003 | 1 | 331 | 9.3 | 101 | 46 | 0 |
| 2003 | 2 | 268 | 9.9 | 53.5 | 52 | 0 |
| 2003 | 3 | 365 | 12.7 | 159.5 | 49 | 0 |
| 2003 | 4 | 492 | 19.2 | 121 | 61 | 3 |
| 2003 | 5 | 632 | 22.4 | 172.5 | 65 | 7 |
| 2003 | 6 | 730 | 26.6 | 85 | 69 | 21 |
| 2003 | 7 | 821 | 26 | 187.5 | 75 | 21 |
| 2003 | 8 | 1057 | 29.5 | 370 | 73 | 26 |
| 2003 | 9 | 724 | 28.1 | 150 | 66 | 23 |
| 2003 | 10 | 430 | 21.4 | 171.5 | 59 | 3 |
| 2003 | 11 | 363 | 17.4 | 229.5 | 67 | 0 |
| 2003 | 12 | 415 | 13.2 | 53 | 50 | 0 |
| 2004 | 1 | 351 | 10.1 | 3.5 | 43 | 0 |
| 2004 | 2 | 322 | 12.9 | 20 | 45 | 0 |
| 2004 | 3 | 367 | 14 | 129.5 | 53 | 0 |
| 2004 | 4 | 508 | 21.3 | 69.5 | 51 | 3 |
| 2004 | 5 | 667 | 23.7 | 149 | 67 | 13 |
| 2004 | 6 | 772 | 27.5 | 112.5 | 66 | 24 |
| 2004 | 7 | 1148 | 33.1 | 23.5 | 62 | 31 |
| 2004 | 8 | 1080 | 31 | 79.5 | 65 | 28 |
| 2004 | 9 | 653 | 28.7 | 195 | 68 | 26 |
| 2004 | 10 | 434 | 20.7 | 780 | 69 | 3 |
| 2004 | 11 | 358 | 19 | 108.5 | 60 | 0 |
| 2004 | 12 | 388 | 13.4 | 79.5 | 49 | 0 |

# 数値データを見る

## アイスクリームの平均購入額と最高気温などのデータ

| 年 | 月 | アイスクリームの平均購入額 | 日最高気温の平均(℃) | 降水量の合計(mm) | 平均湿度(%) | 日最高気温25℃以上日数(日) |
|---|---|---|---|---|---|---|
| 2003 | 1 | 331 | 9.3 | 101 | 46 | 0 |
| 2003 | 2 | 268 | 9.9 | | | |
| 2003 | 3 | 365 | 12.7 | | | |
| 2003 | 4 | 492 | 19.2 | | | |
| 2003 | 5 | 632 | 22.4 | | | |
| 2003 | 6 | 730 | 26.6 | | | |
| 2003 | 7 | 821 | 26 | | | |
| 2003 | 8 | 1057 | 29.5 | 370 | 73 | |
| 2003 | 9 | 724 | 28.1 | 150 | 66 | |
| 2003 | 10 | 430 | 21.4 | 171.5 | 59 | |
| 2003 | 11 | 363 | 17.4 | 229.5 | 67 | 0 |
| 2003 | 12 | 415 | 13.2 | 53 | 50 | 0 |
| 2004 | 1 | 351 | 10.1 | 3.5 | 43 | 0 |
| 2004 | 2 | 322 | 12.9 | 20 | 45 | 0 |
| 2004 | 3 | 367 | 14 | 129.5 | 53 | 0 |
| 2004 | 4 | 508 | 21.3 | 69.5 | 51 | 3 |
| 2004 | 5 | 667 | 23.7 | 149 | 67 | 13 |
| 2004 | 6 | 772 | 27.5 | 112.5 | 66 | 24 |
| 2004 | 7 | 1148 | 33.1 | 23.5 | 62 | 31 |
| 2004 | 8 | 1080 | 31 | 79.5 | 65 | 28 |
| 2004 | 9 | 653 | 28.7 | 195 | 68 | 26 |
| 2004 | 10 | 434 | 20.7 | 780 | 69 | 3 |
| 2004 | 11 | 358 | 19 | 108.5 | 60 | 0 |
| 2004 | 12 | 388 | 13.4 | 79.5 | 49 | 0 |



# 見た目でわかるようにしよう

# データの可視化

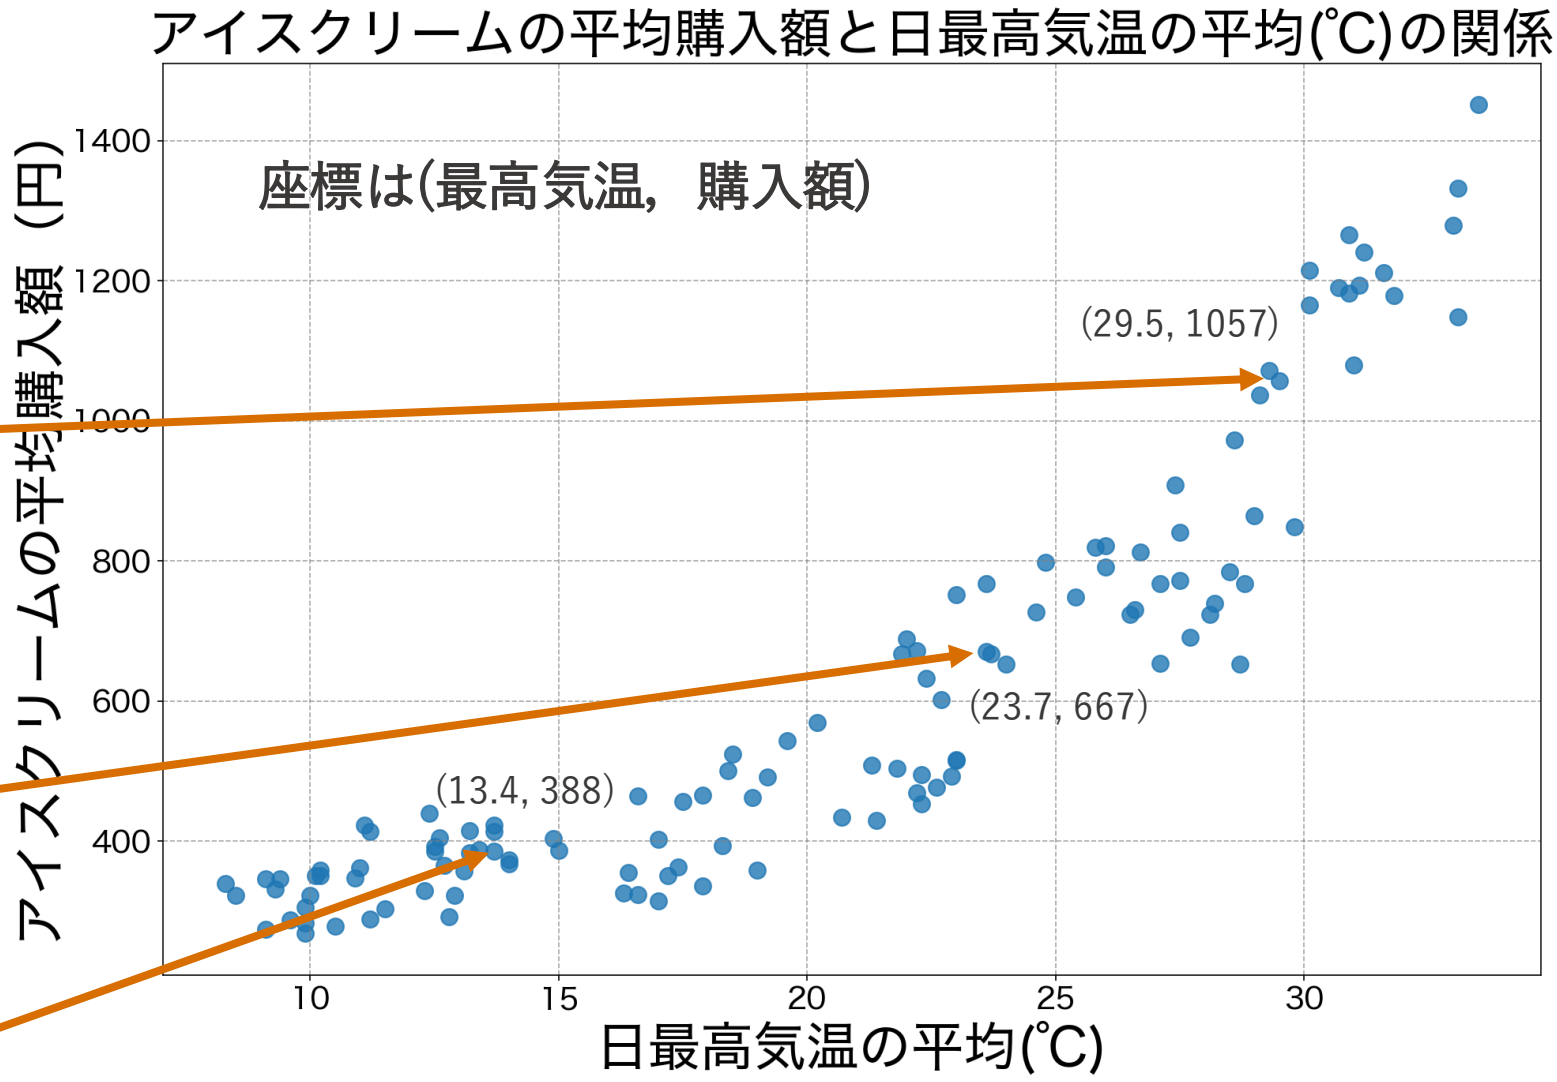
| 年 | 月 | アイスクリームの平均購入額 | 日最高気温の平均(℃) | 降水量の合計(mm) | 平均湿度(%) | 日最高気温25℃以上日数(日) |
|---|---|---|---|---|---|---|
| 2003 | 1 | 331 | 9.3 | | | |
| 2003 | 2 | 268 | 9.9 | | | |
| 2003 | 3 | 365 | 12.7 | | | |
| 2003 | 4 | 492 | 19.2 | | | |
| 2003 | 5 | 632 | 22.4 | | | |
| 2003 | 6 | 730 | 26.6 | | | |
| 2003 | 7 | 821 | 26 | | | |
| 2003 | 8 | 1057 | 29.5 | 370 | 73 | 26 |
| 2003 | 9 | 724 | 28.1 | 150 | 66 | 23 |
| 2003 | 10 | 430 | 21.4 | 171.5 | 59 | 3 |
| 2003 | 11 | 363 | 17.4 | 229.5 | 67 | 0 |
| 2003 | 12 | 415 | 13.2 | 53 | 50 | 0 |
| 2004 | 1 | 351 | 10.1 | 3.5 | 43 | 0 |
| 2004 | 2 | 322 | 12.9 | 20 | 45 | 0 |
| 2004 | 3 | 367 | 14 | 129.5 | 53 | 0 |
| 2004 | 4 | 508 | 21.3 | 69.5 | 51 | 3 |
| 2004 | 5 | 667 | 23.7 | 149 | 67 | 13 |
| 2004 | 6 | 772 | 27.5 | 112.5 | 66 | 24 |
| 2004 | 7 | 1148 | 33.1 | 23.5 | 62 | 31 |
| 2004 | 8 | 1080 | 31 | 79.5 | 65 | 28 |
| 2004 | 9 | 653 | 28.7 | 195 | 68 | 26 |
| 2004 | 10 | 434 | 20.7 | 780 | 69 | 3 |
| 2004 | 11 | 358 | 19 | 108.5 | 60 | 0 |
| 2004 | 12 | 388 | 13.4 | 79.5 | 49 | 0 |

アイスクリームの購入額と気温の関係が知りたい！！
グラフにしよう！！



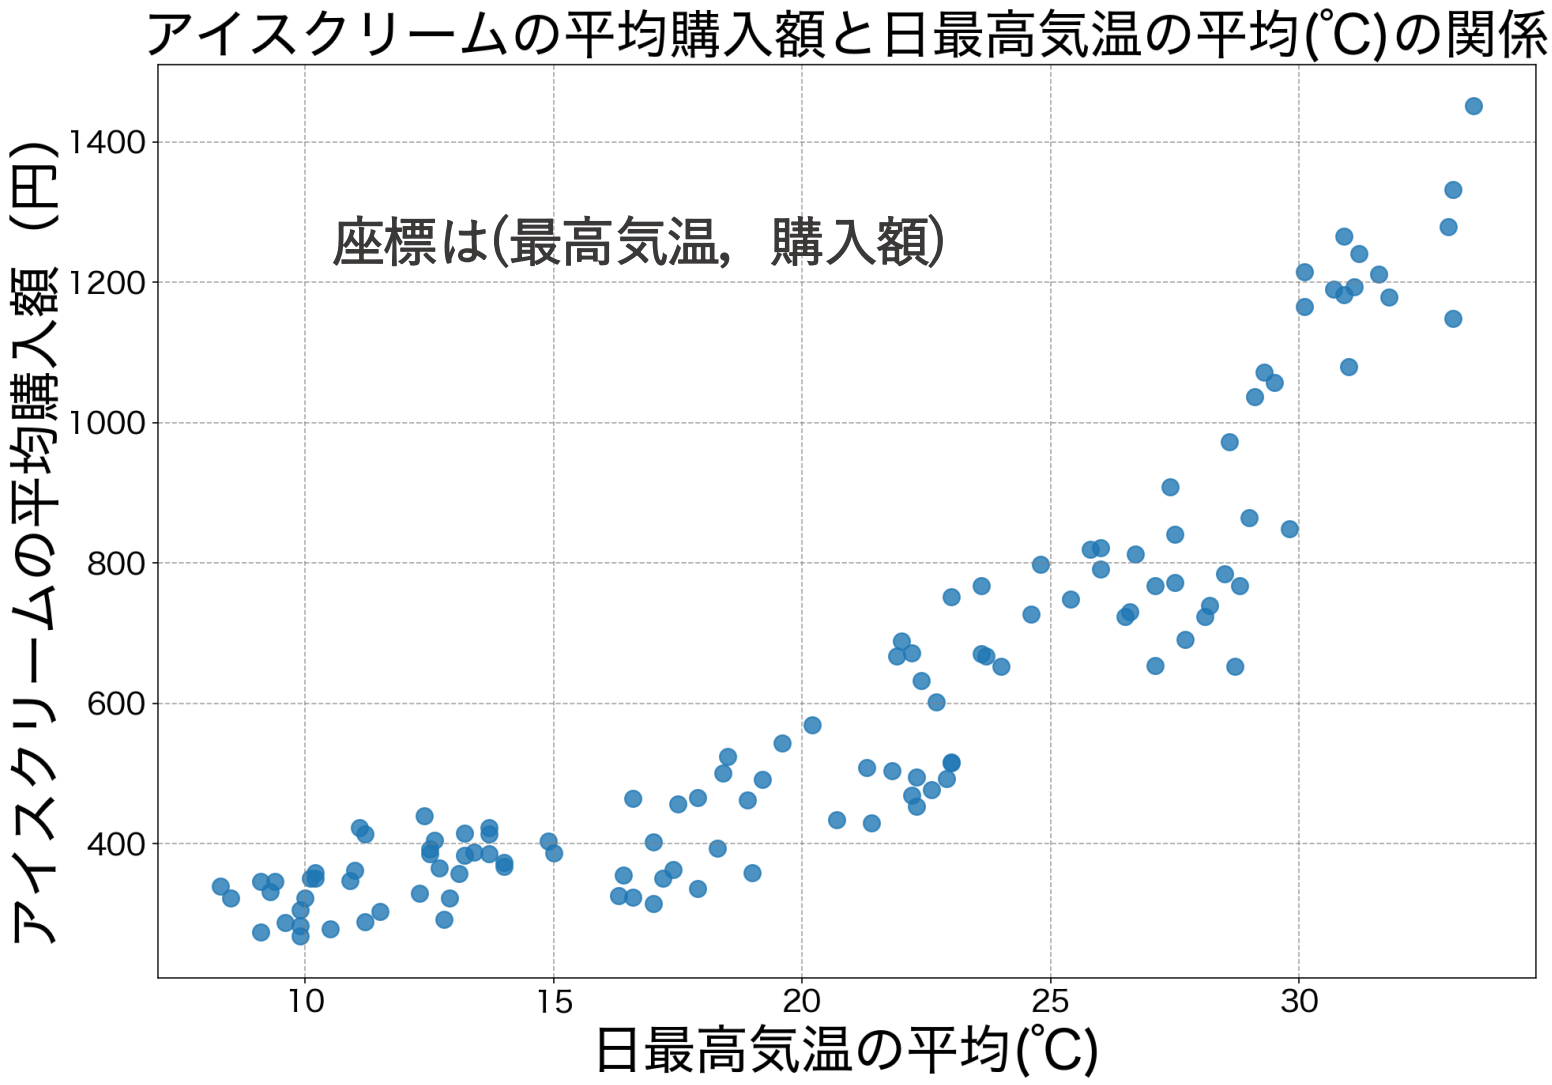
# グラフにする

| アイスクリームの平均購入額 | 日最高気温の平均(℃) |
|---|---|
| 331 | 9.3 |
| 268 | 9.9 |
| 365 | 12.7 |
| 492 | 19.2 |
| 632 | 22.4 |
| 730 | 26.6 |
| 821 | 26 |
| 1057 | 29.5 |
| 724 | 28.1 |
| 430 | 21.4 |
| 363 | 17.4 |
| 415 | 13.2 |
| 351 | 10.1 |
| 322 | 12.9 |
| 367 | 14 |
| 508 | 21.3 |
| 667 | 23.7 |
| 772 | 27.5 |
| 1148 | 33.1 |
| 1080 | 31 |
| 653 | 28.7 |
| 434 | 20.7 |
| 358 | 19 |
| 388 | 13.4 |



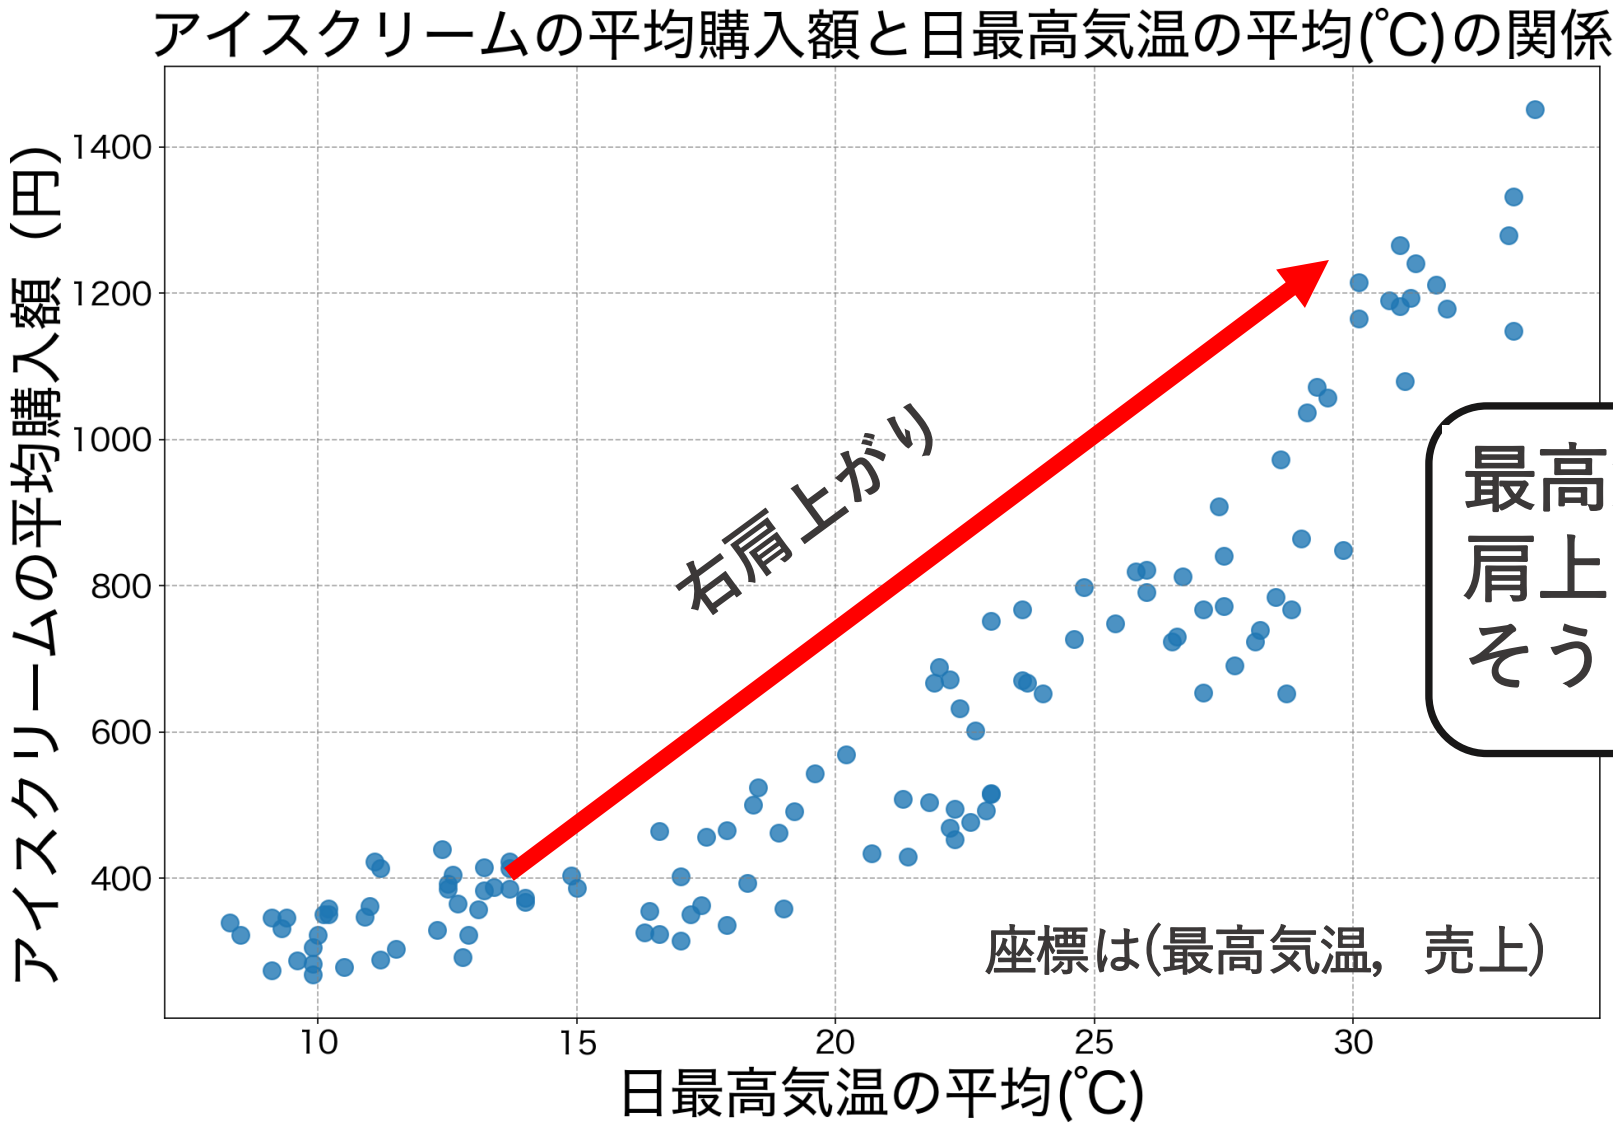

数値のペア(最高気温と購入額)を点で表す.

# グラフにする




数値のペアを点で表したグラフを**散布図**という．

# グラフにすると分かることがある




最高気温と購入額に右肩上がりの関係がありそうだ！！



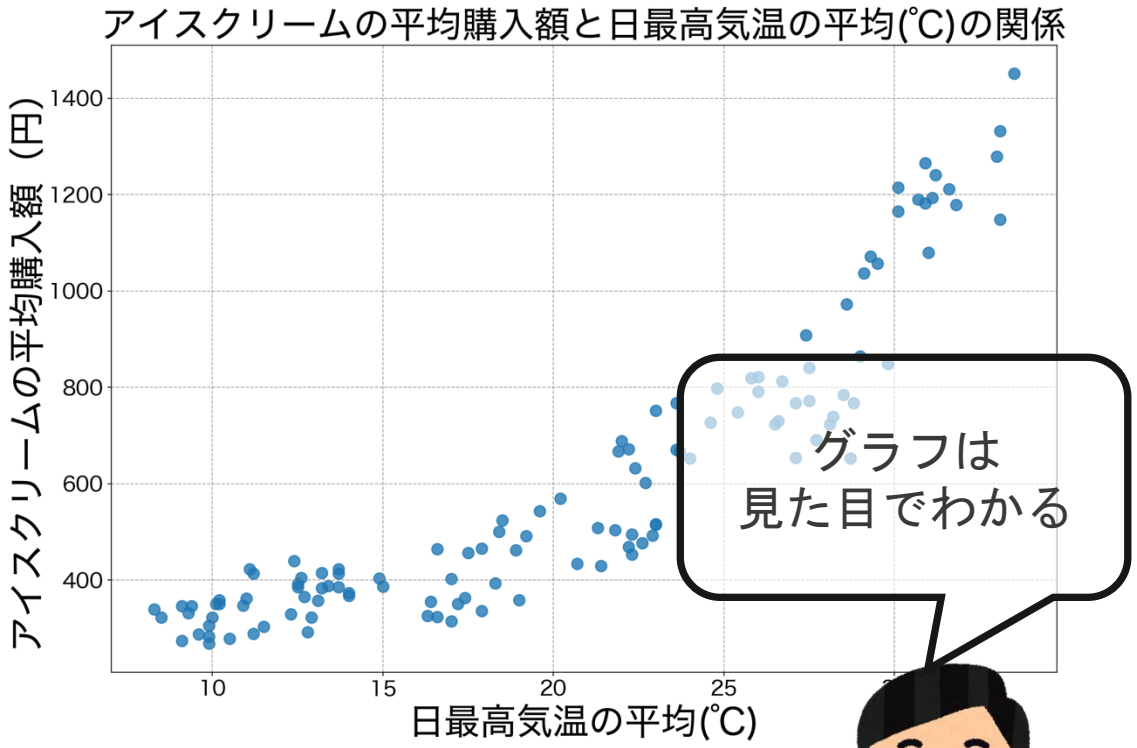
# データの可視化

| 年 | 月 | アイスクリームの平均購入額 | 日最高気温の平均(℃) | 降水量の合計(mm) | 平均湿度(%) | 日最高気温25℃以上日数(日) |
|---|---|---|---|---|---|---|
| 2003 | 1 | 331 | 9.3 | 101 | 46 | 0 |
| 2003 | 2 | 268 | 9.9 | 53.5 | 52 | 0 |
| 2003 | 3 | 365 | 12.7 | 159.5 | 49 | 0 |
| 2003 | 4 | 492 | 19.2 | 121 | 61 | 3 |
| 2003 | 5 | 632 | 22.4 | 172.5 | 65 | 7 |
| 2003 | 6 | 730 | 26.6 | 85 | 69 | 21 |
| 2003 | 7 | 821 | 26 | 187.5 | 75 | 21 |
| 2003 | 8 | 1057 | 29.5 | 370 | 73 | 26 |
| 2003 | 9 | 724 | 28.1 | 150 | 66 | 23 |
| 2003 | 10 | 430 | 21.4 | 171.5 | 59 | 3 |
| | | 363 | 17.4 | 229.5 | 67 | 0 |
| | | 415 | 13.2 | 53 | 50 | 0 |
| | | 351 | 10.1 | 3.5 | 43 | 0 |
| | | 322 | 12.9 | 20 | 45 | 0 |
| | | 367 | 14 | 129.5 | 53 | 0 |
| | | 508 | 21.3 | 69.5 | 51 | 3 |
| | | 667 | 23.7 | 149 | 67 | 13 |
| | | 772 | 27.5 | 112.5 | 66 | 24 |
| | | 1148 | 33.1 | 23.5 | 62 | 31 |
| | | 1080 | 31 | 79.5 | 65 | 28 |
| | | 653 | 28.7 | 195 | 68 | 26 |
| | | 434 | 20.7 | 780 | 69 | 3 |
| 2004 | 11 | 358 | 19 | 108.5 | 60 | 0 |
| 2004 | 12 | 388 | 13.4 | 79.5 | 49 | 0 |

数値が多すぎてよく分からない



データの可視化



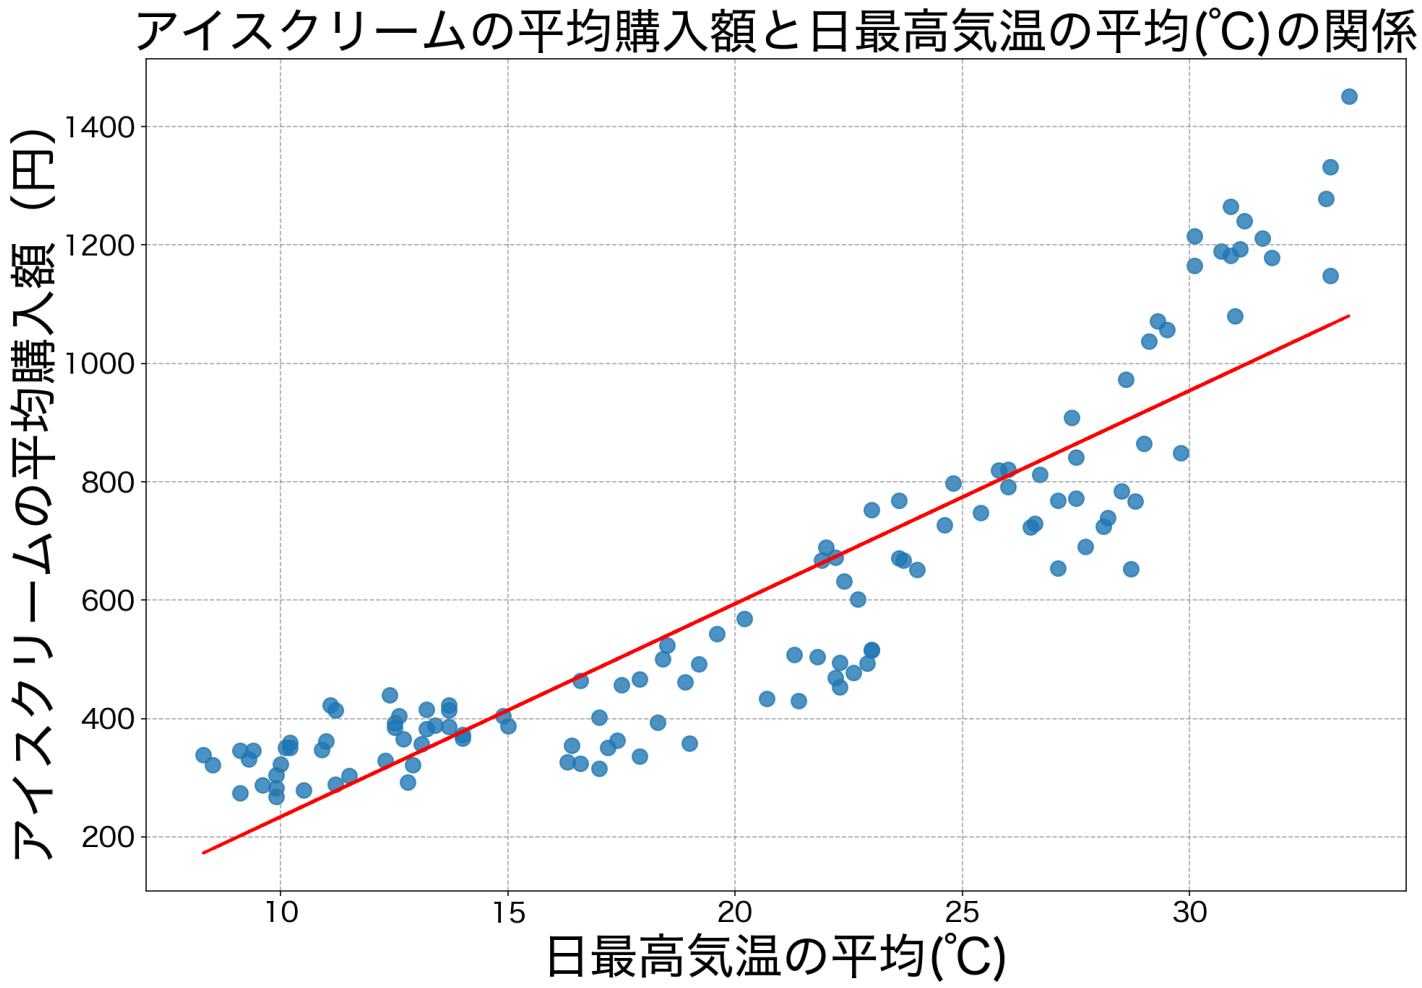

グラフは見た目でわかる



膨大な数の数値の並びでは確認しにくい数値の関係を、グラフなどで分かりやすくする見えるようにすることを**可視化**という．

# 線を引いてみる

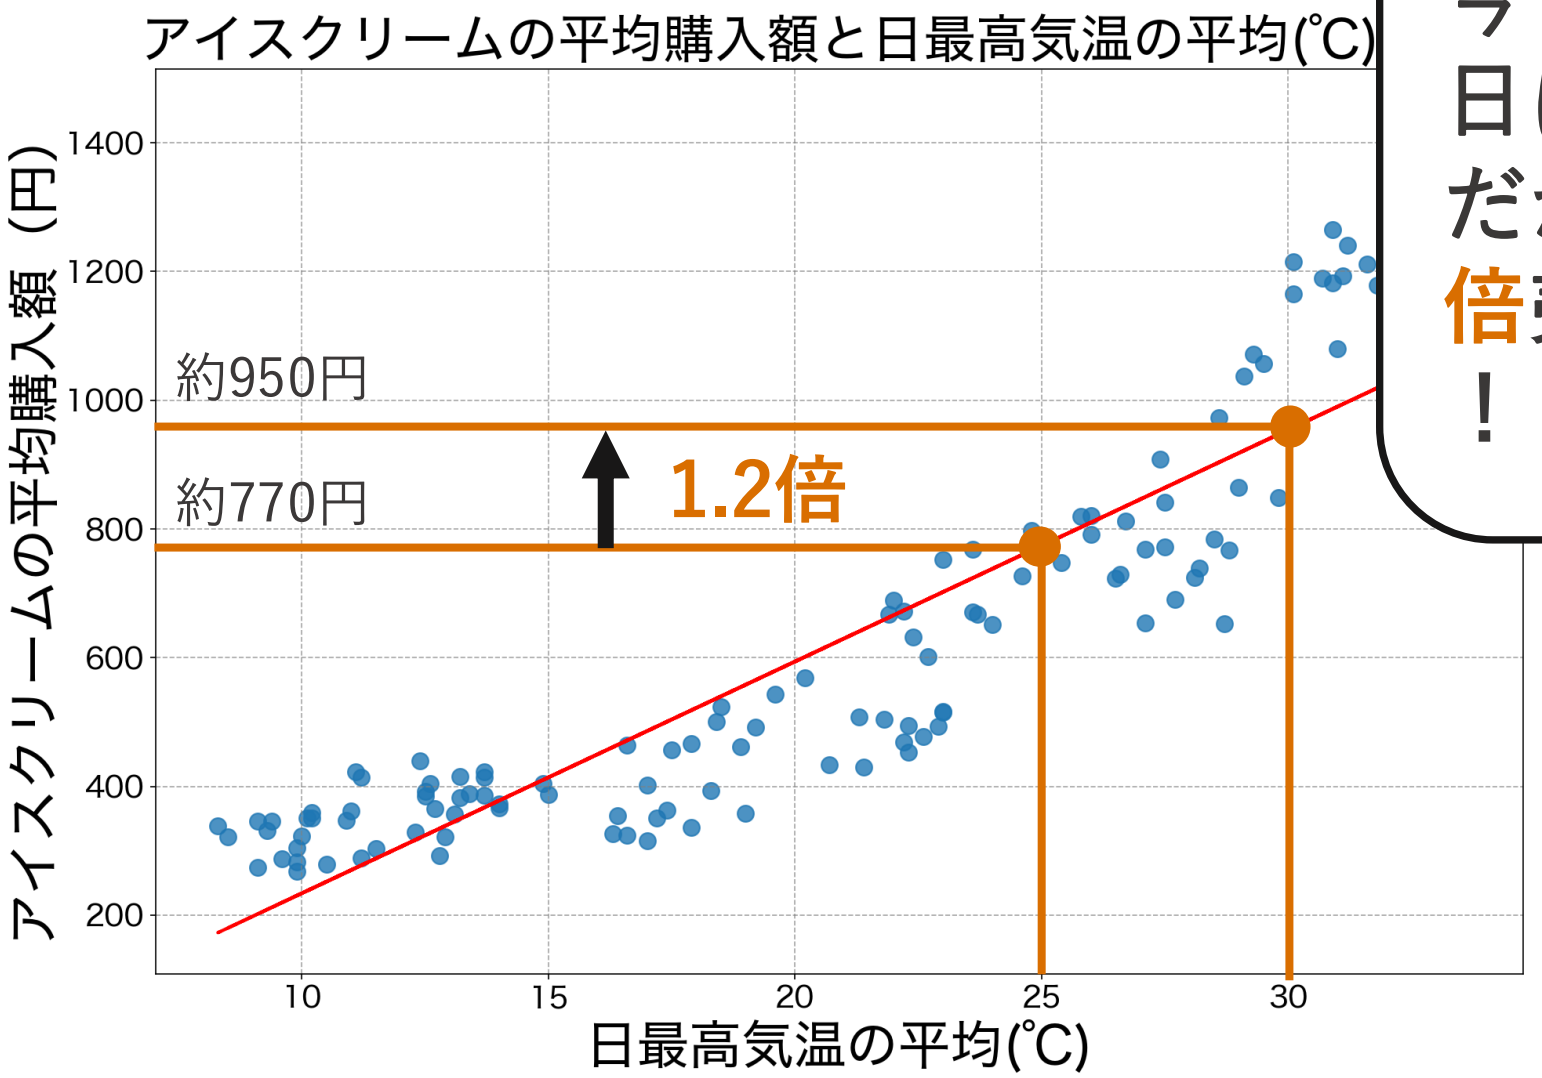
# 線をひく




データに沿って線を引いてみる.
このデータの点に基づき引かれた線のことを**回帰直線**という.

# 回帰直線をひいて何が分かる

## 最高気温から購入額が予測できるかも.




今日は25度，明日は30度の予想だから明日は1.2倍売れそうだ！！



# ここまでのまとめ

- データに基づいて考えることが大事です.
  - 勘ではダメです.
- データを可視化しましょう.
  - 数値だけ見てもよく分かりません.
- 数値の関係を直線で表そう.
  - 関係の強さが分かったり，数値の予測ができるかもしれません.

# 用語解説

# 説明変数と目的変数

今日は25度，明日は30度の予想だから明日は1.2倍売れそうだ！！



最高気温から購入額が求まる.

↓

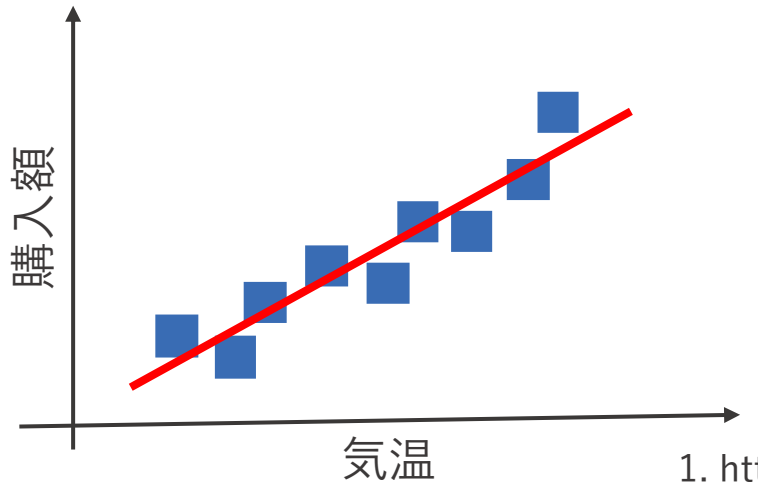
最高気温から購入額が説明できる.

最高気温で購入額を説明できるので，最高気温を**説明変数**という．

購入額は予測したい対象なので，購入額を**目的変数**という．

# 回帰

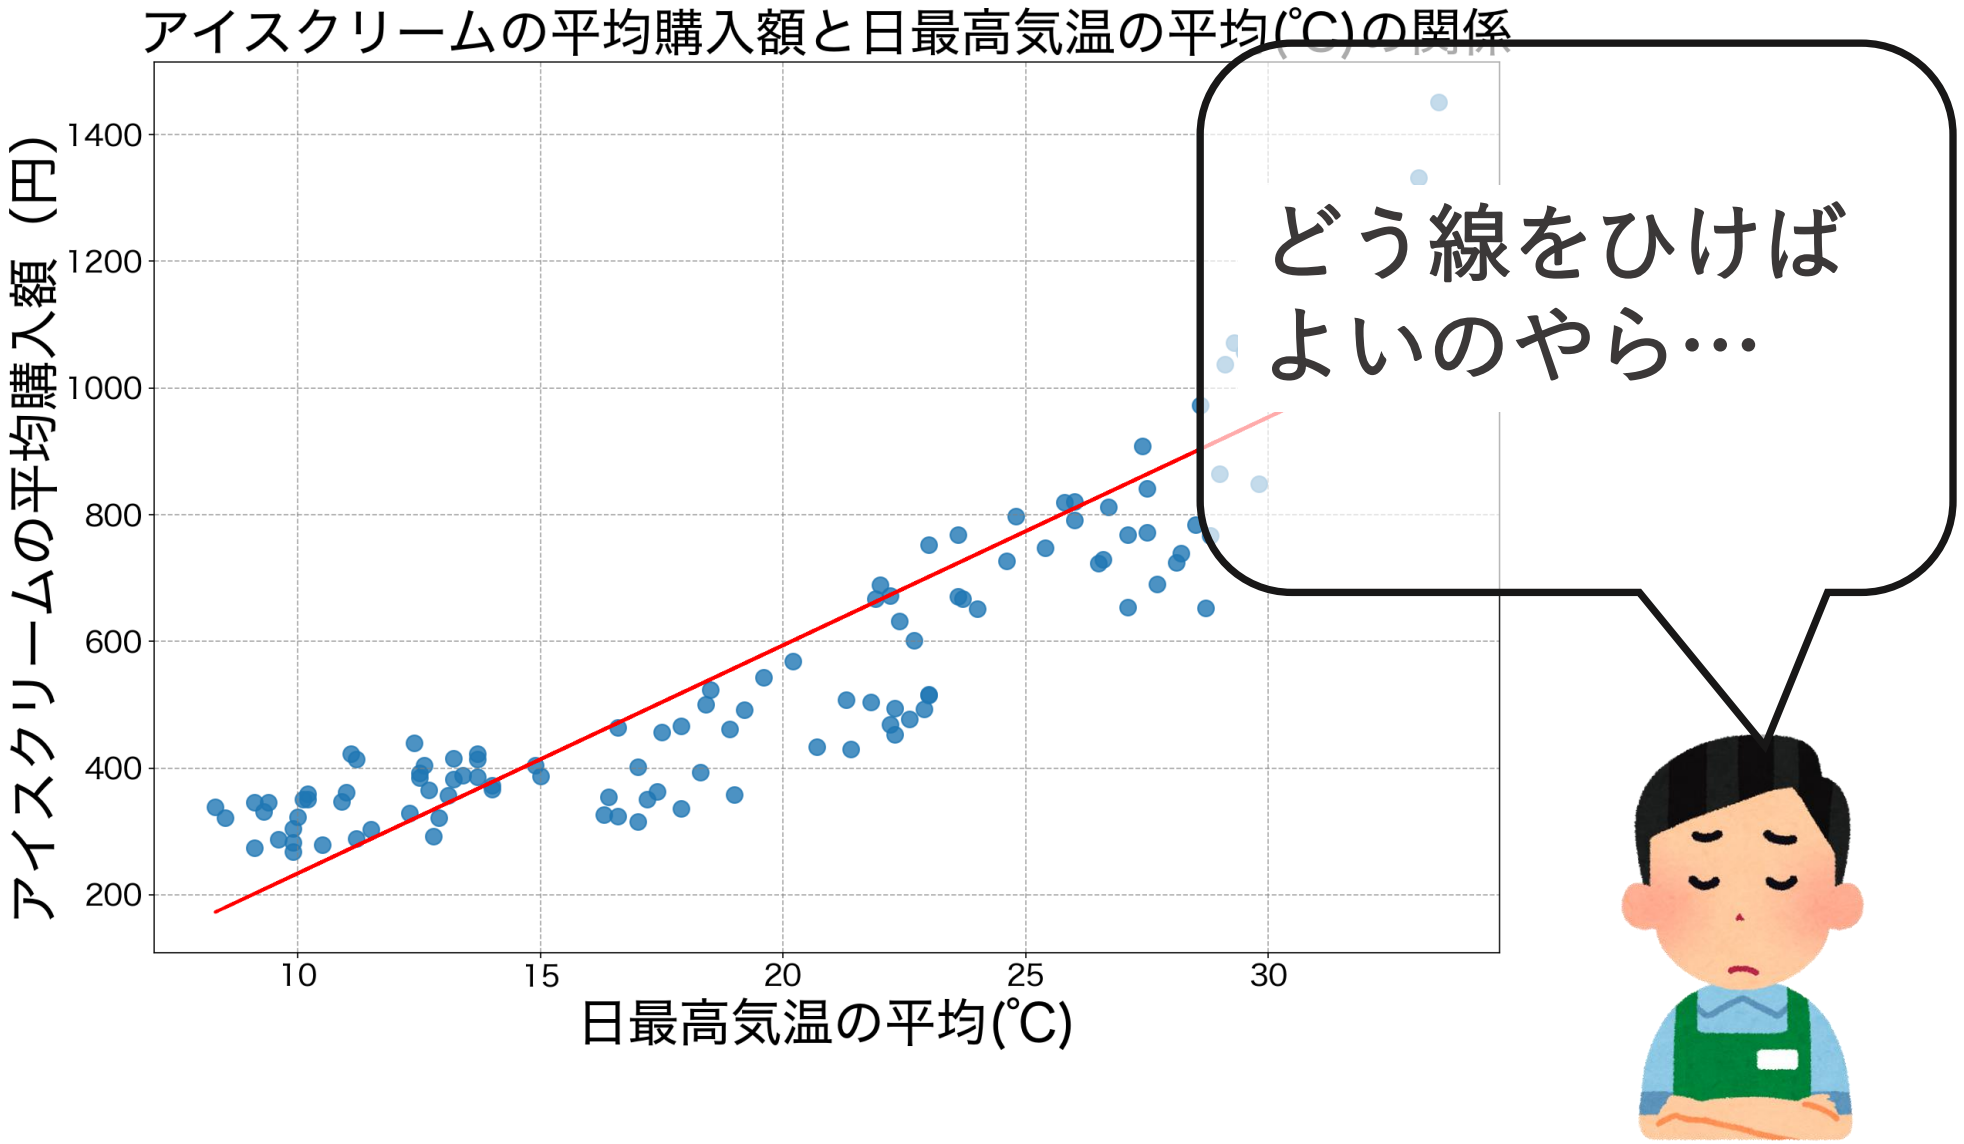
- 最高気温とアイスの購入額の関係を直線で表した.
- この直線を**回帰直線（回帰線）**という[1].
- 数値と数値の関係の式を求める問題を**回帰問題**という.
  - 特に数値の関係を直線とする場合を**線形回帰**といい，特に説明変数と目的変数が，それぞれ１つの場合を**単回帰**という.
- 回帰を用いデータの定量的な関係を説明しようとすることを**回帰分析**という .




1. https://www.stat.go.jp/naruhodo/10_tokucho/hukusu.html

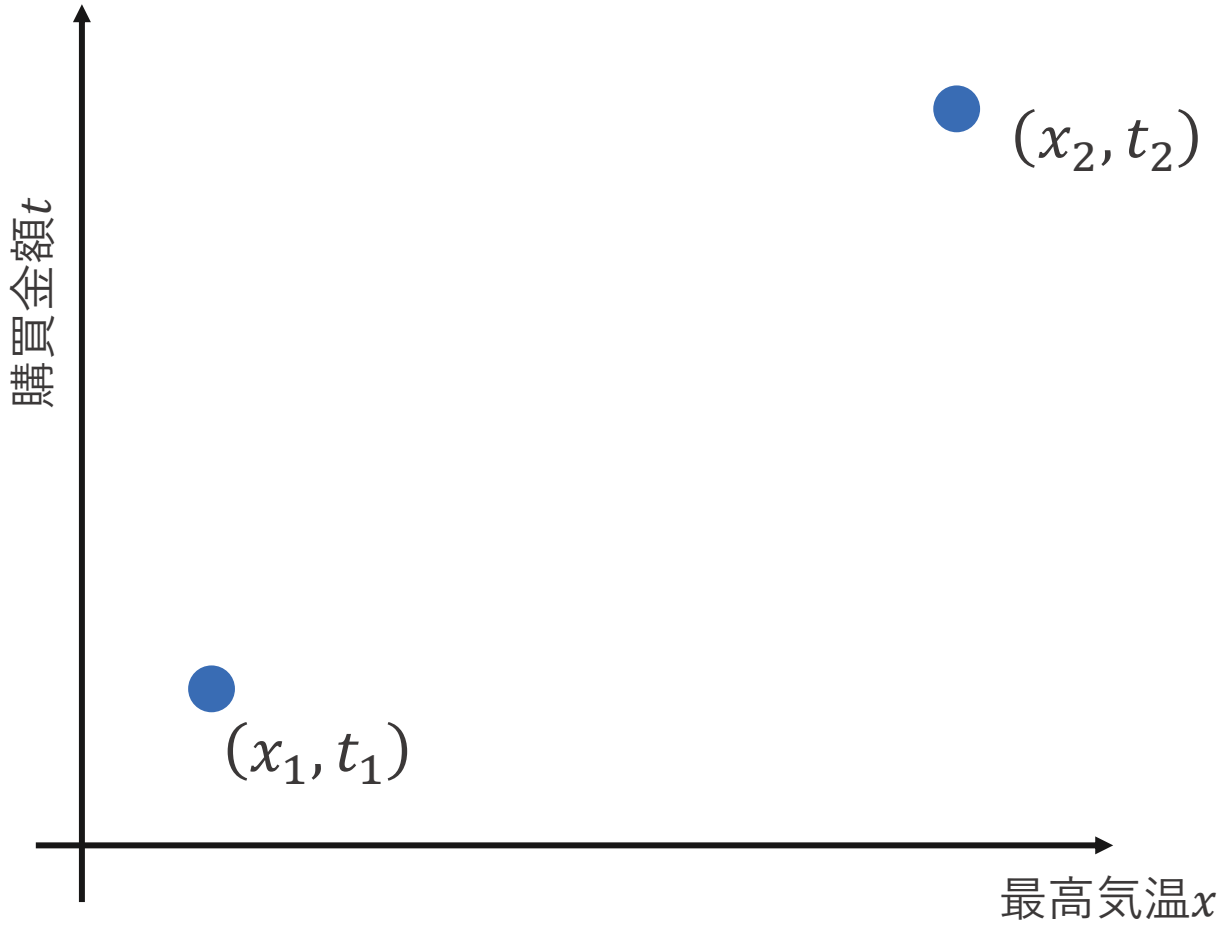
# 回帰直線の求め方

# どうやって線を引けばよいのだろうか



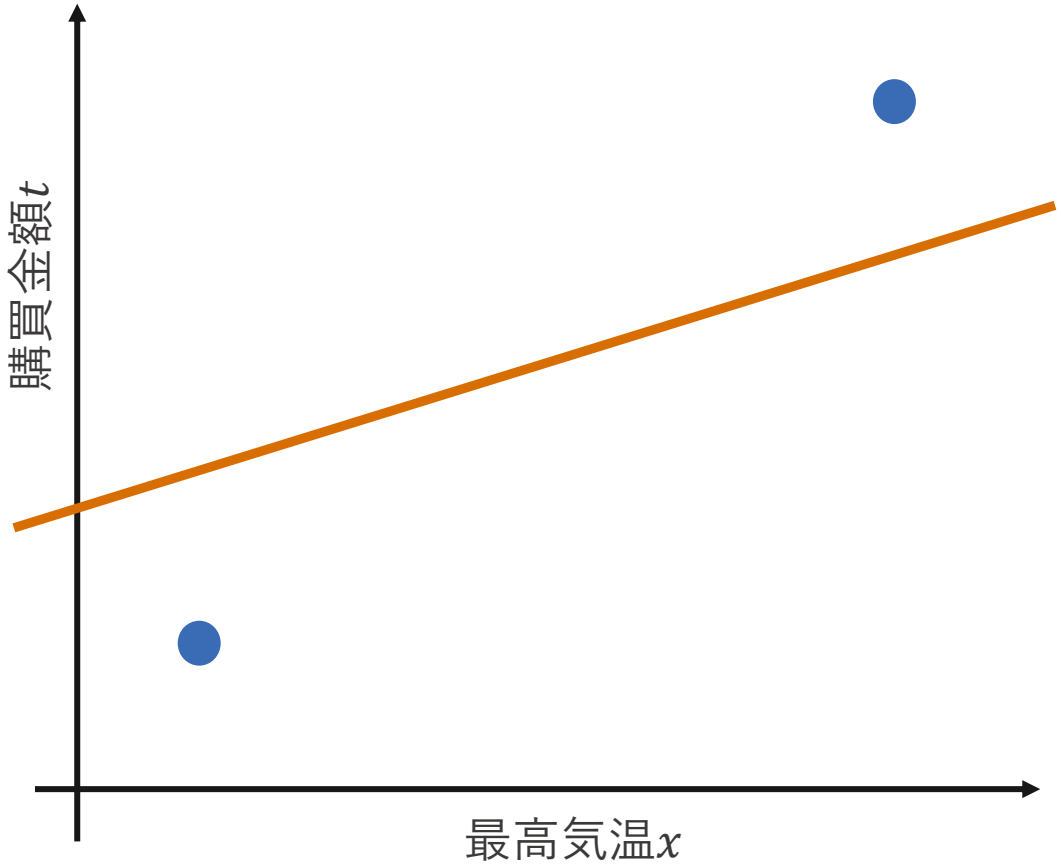
# データ点が2つの場合

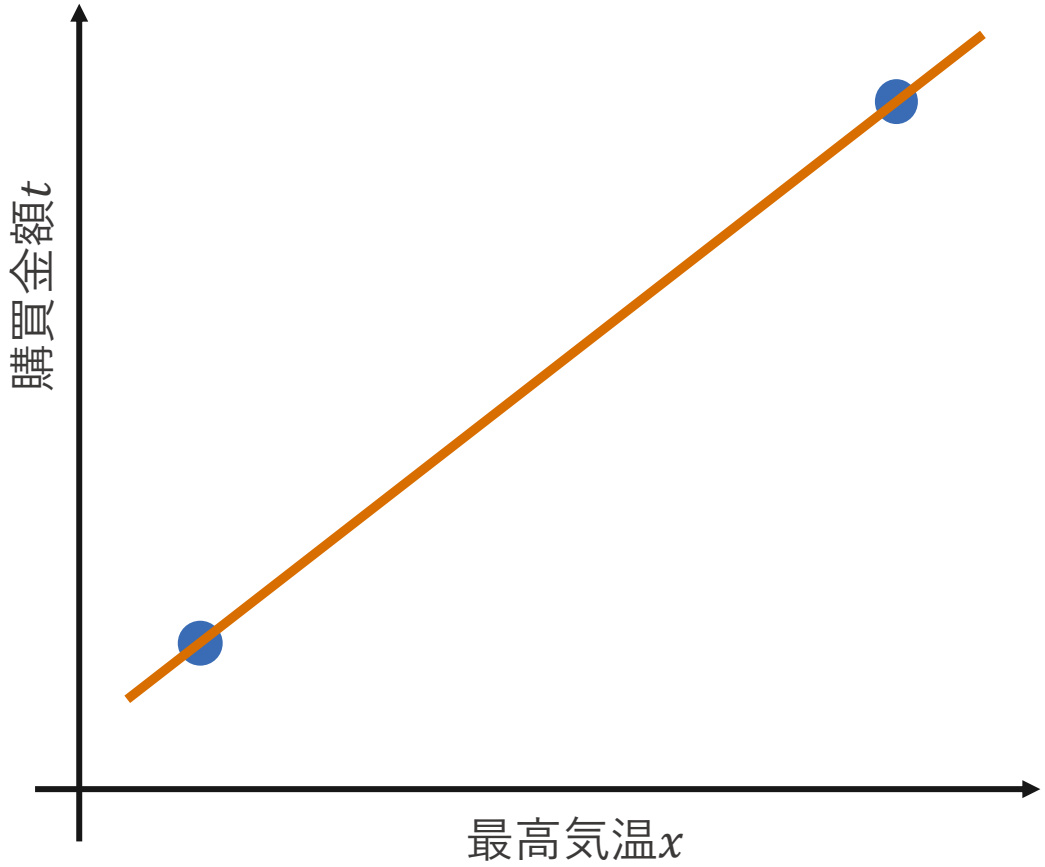
データ点が2つしかない場合を考えてみよう．
この散布図に回帰直線を引く場合，
どんな線が良いだろうか？



# データ点が2つの場合

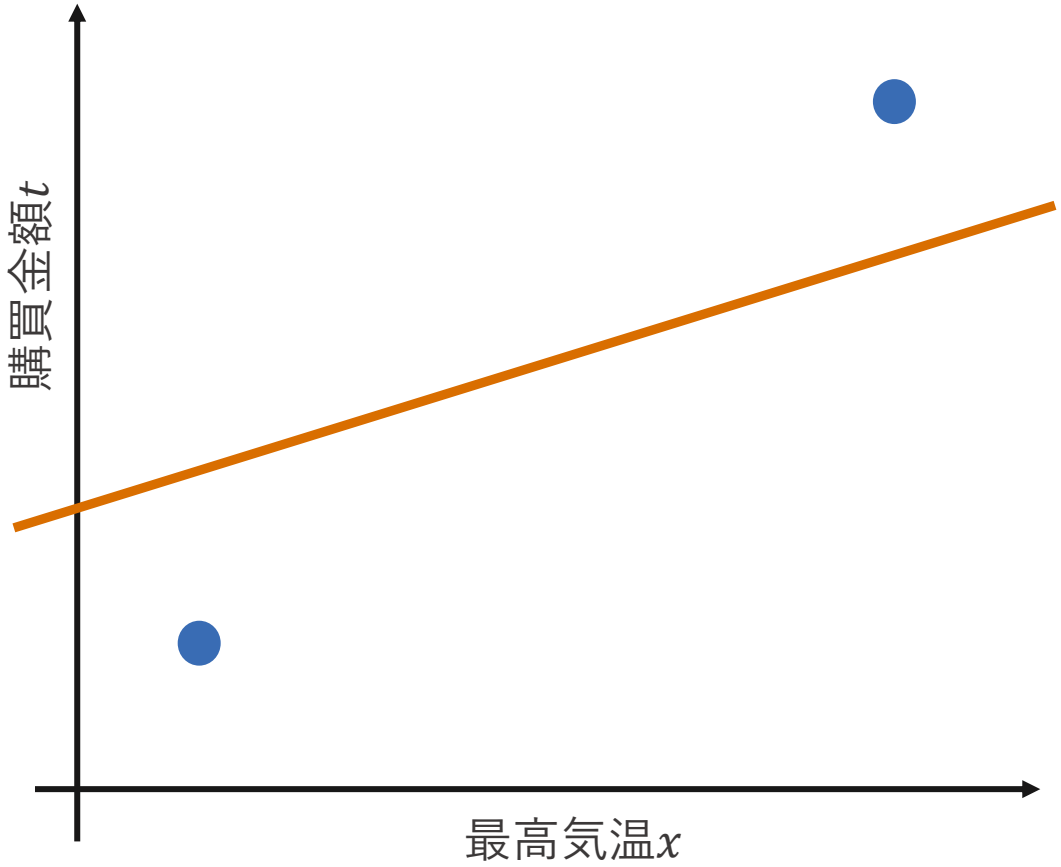
どちらの回帰直線が良いと思いますか？

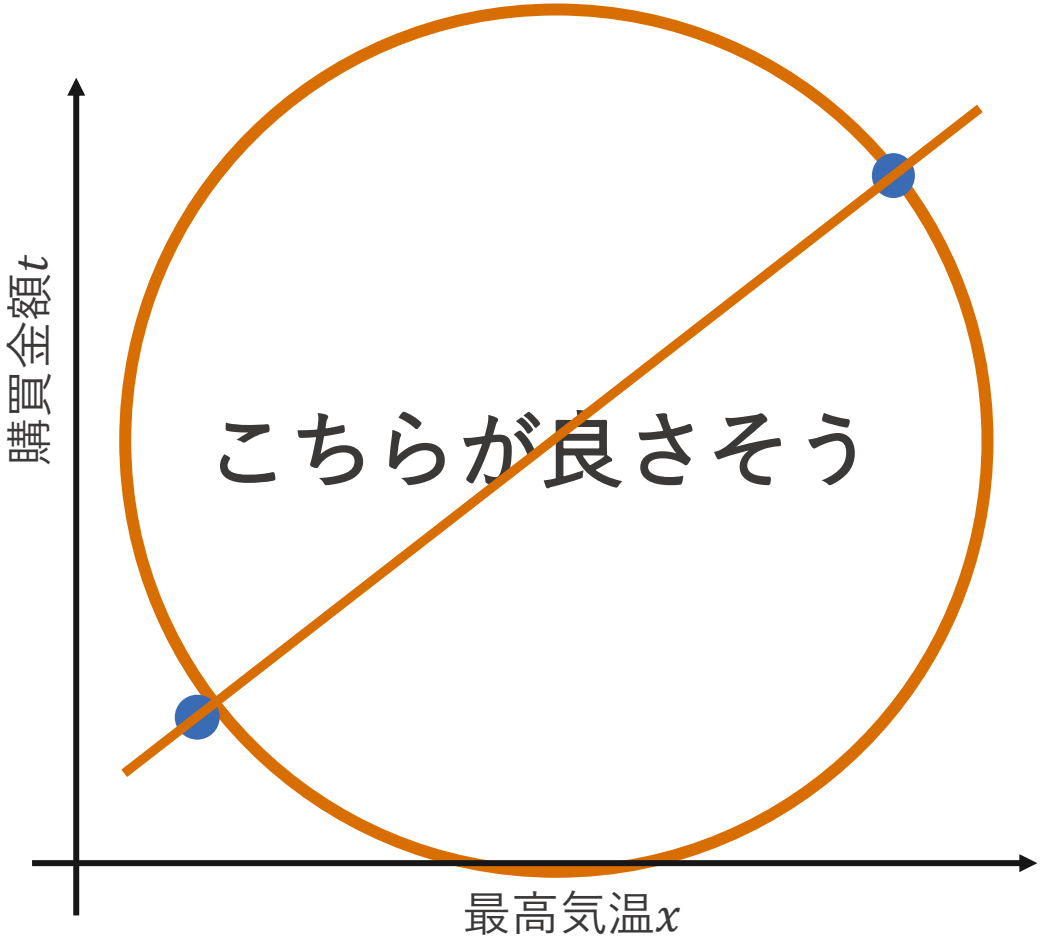


# データ点が2つの場合

どちらの回帰直線が良いと思いますか？

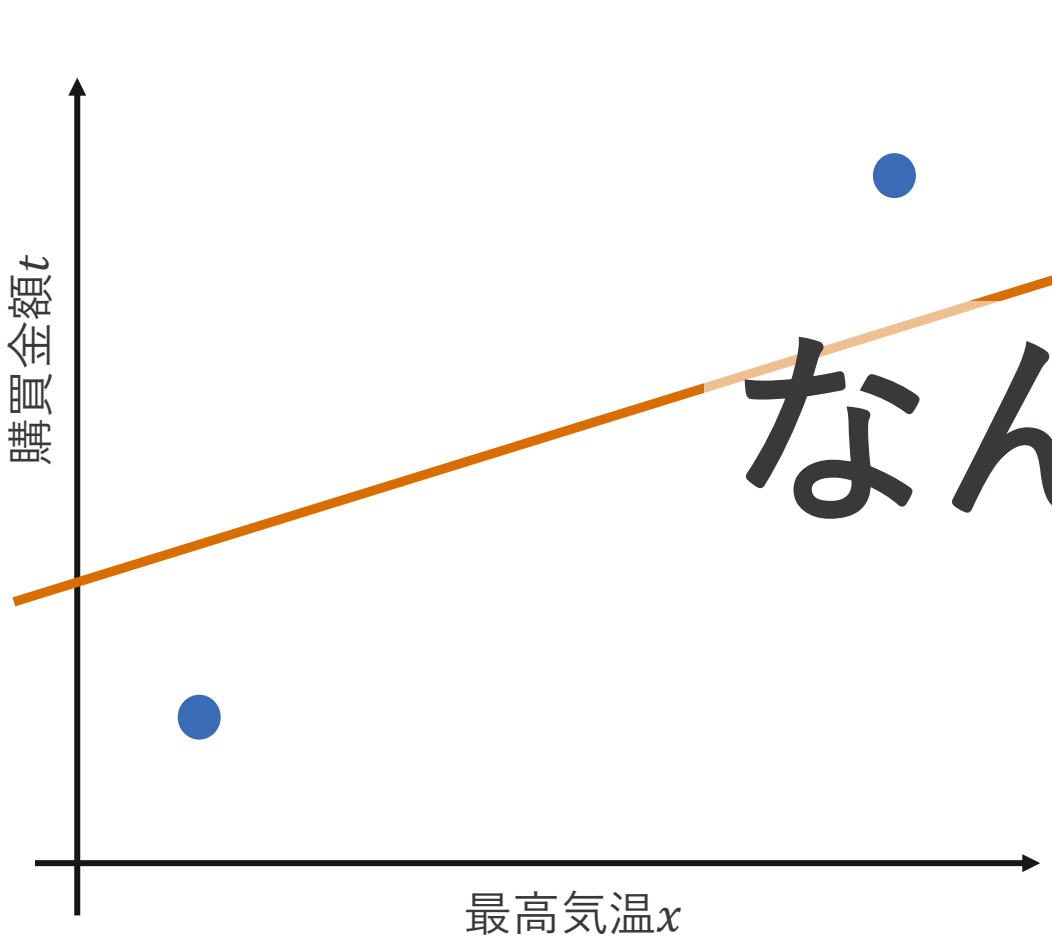


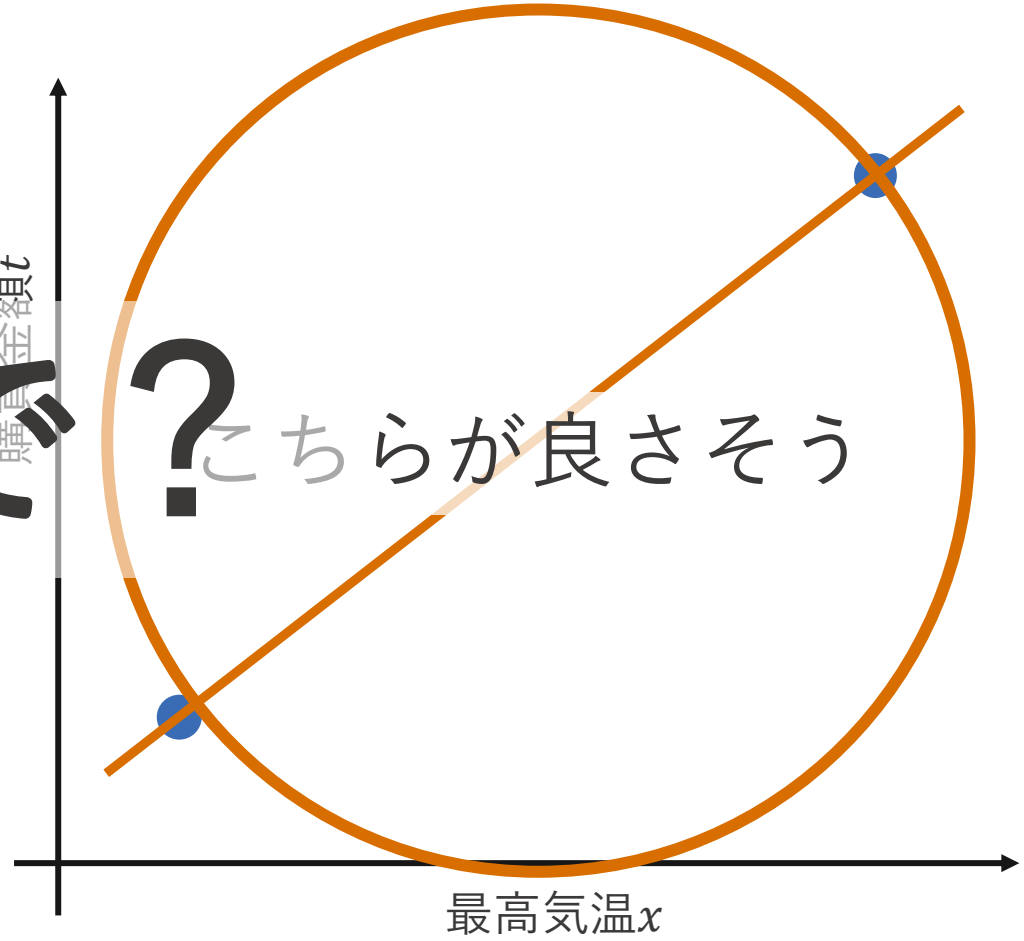

良さそうなだけで正しいかどうかは分からない！！

# データ点が2つの場合

どちらの回帰直線が良いと思いますか？




なんで？

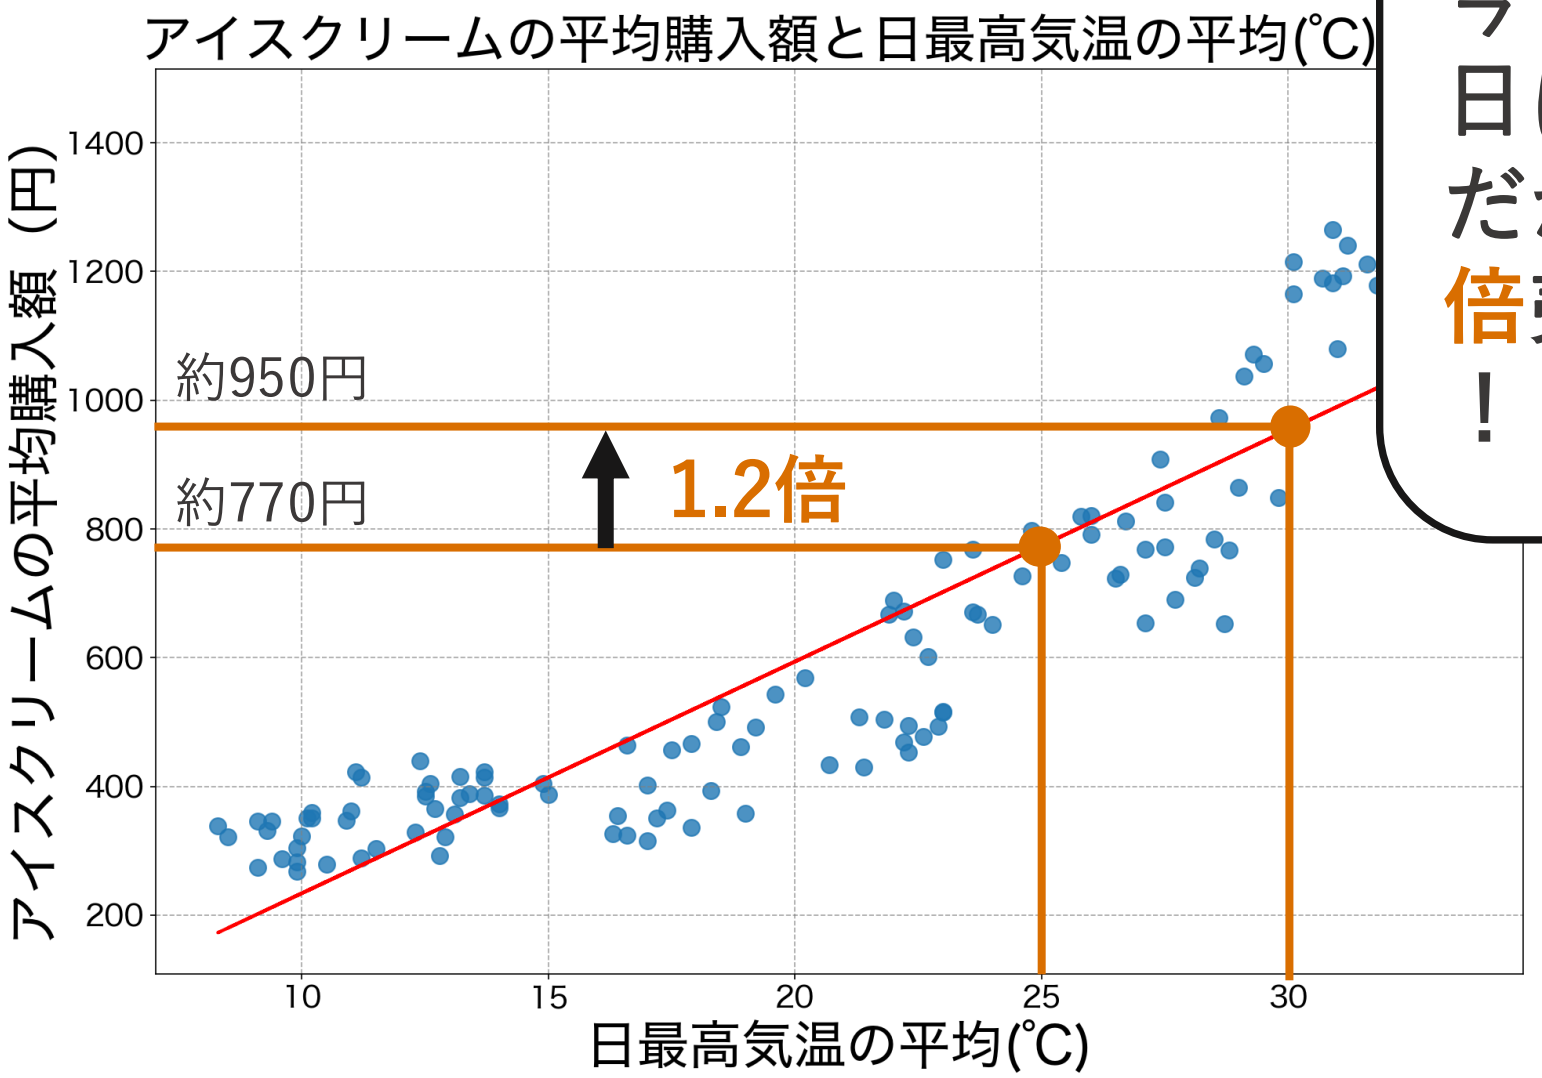



こちらが良さそう

# 回帰直線は予測する

# 回帰直線をひいて何が分かる

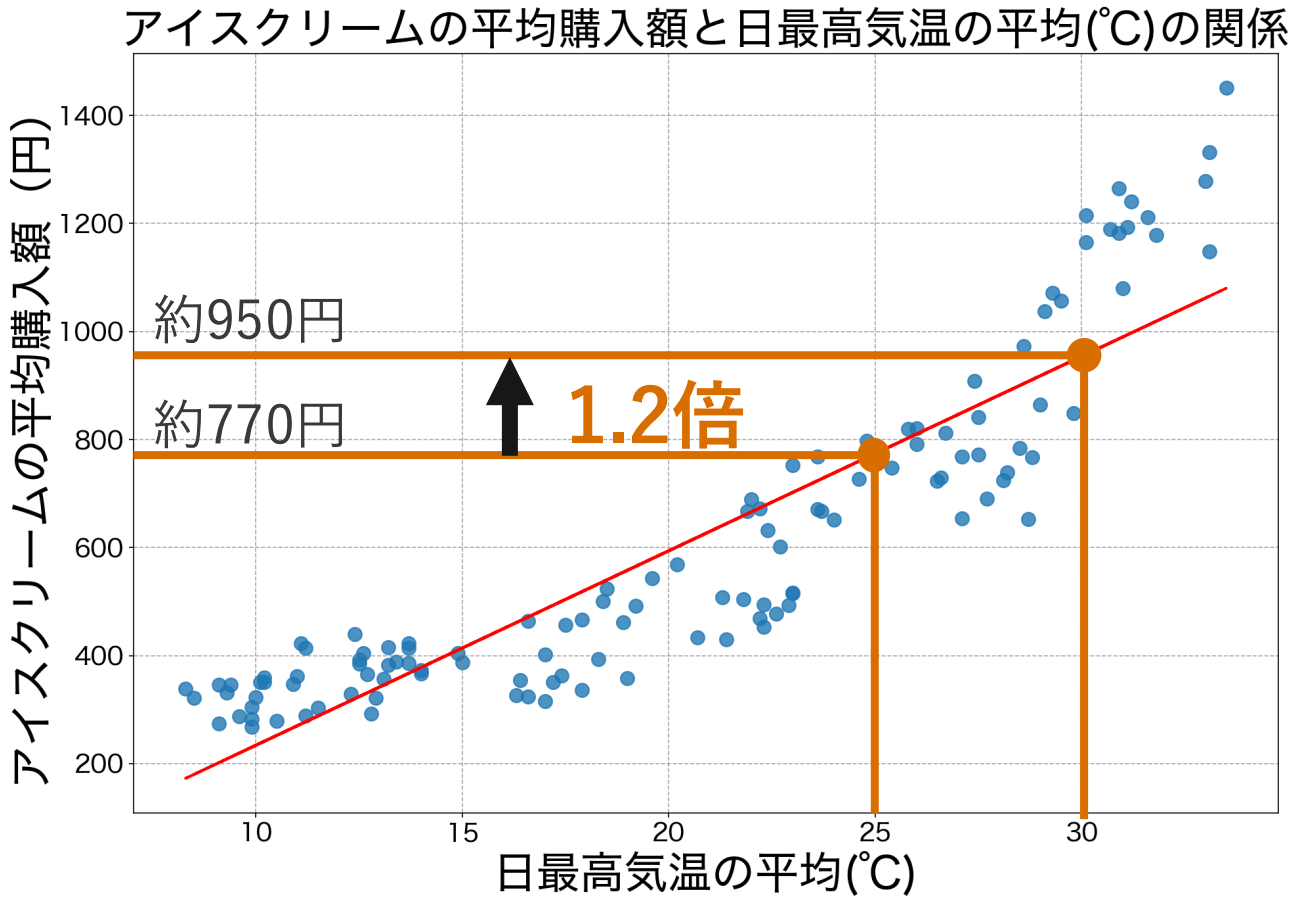
## 最高気温から購入額が予測できるかも.




今日は25度，明日は30度の予想だから明日は1.2倍売れそうだ！！



# 回帰直線から予測する

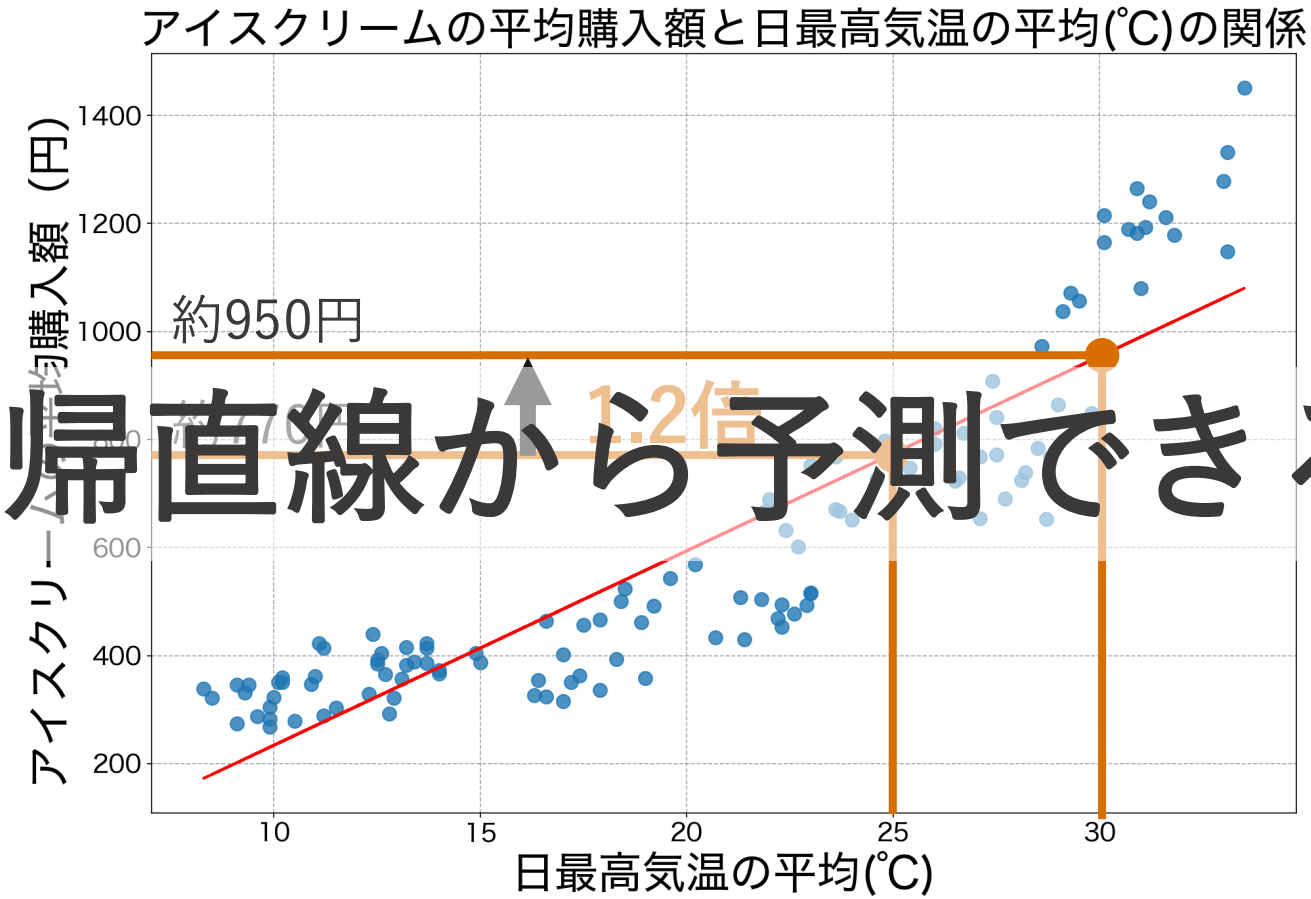



回帰直線を用い気温に対する購入額が予測できる.

回帰直線から25度のとき770円と予測する.

回帰直線から30度のとき950円と予測する.

# 回帰直線から予測する




回帰直線から予測できる.

回帰直線を用い気温に対する購入額が予測できる.

回帰直線から25度のとき770円と予測する.

回帰直線から30度のとき950円と予測する.

## 良い回帰直線とは

回帰直線から予測できる.



予測が当たる回帰直線が良い.

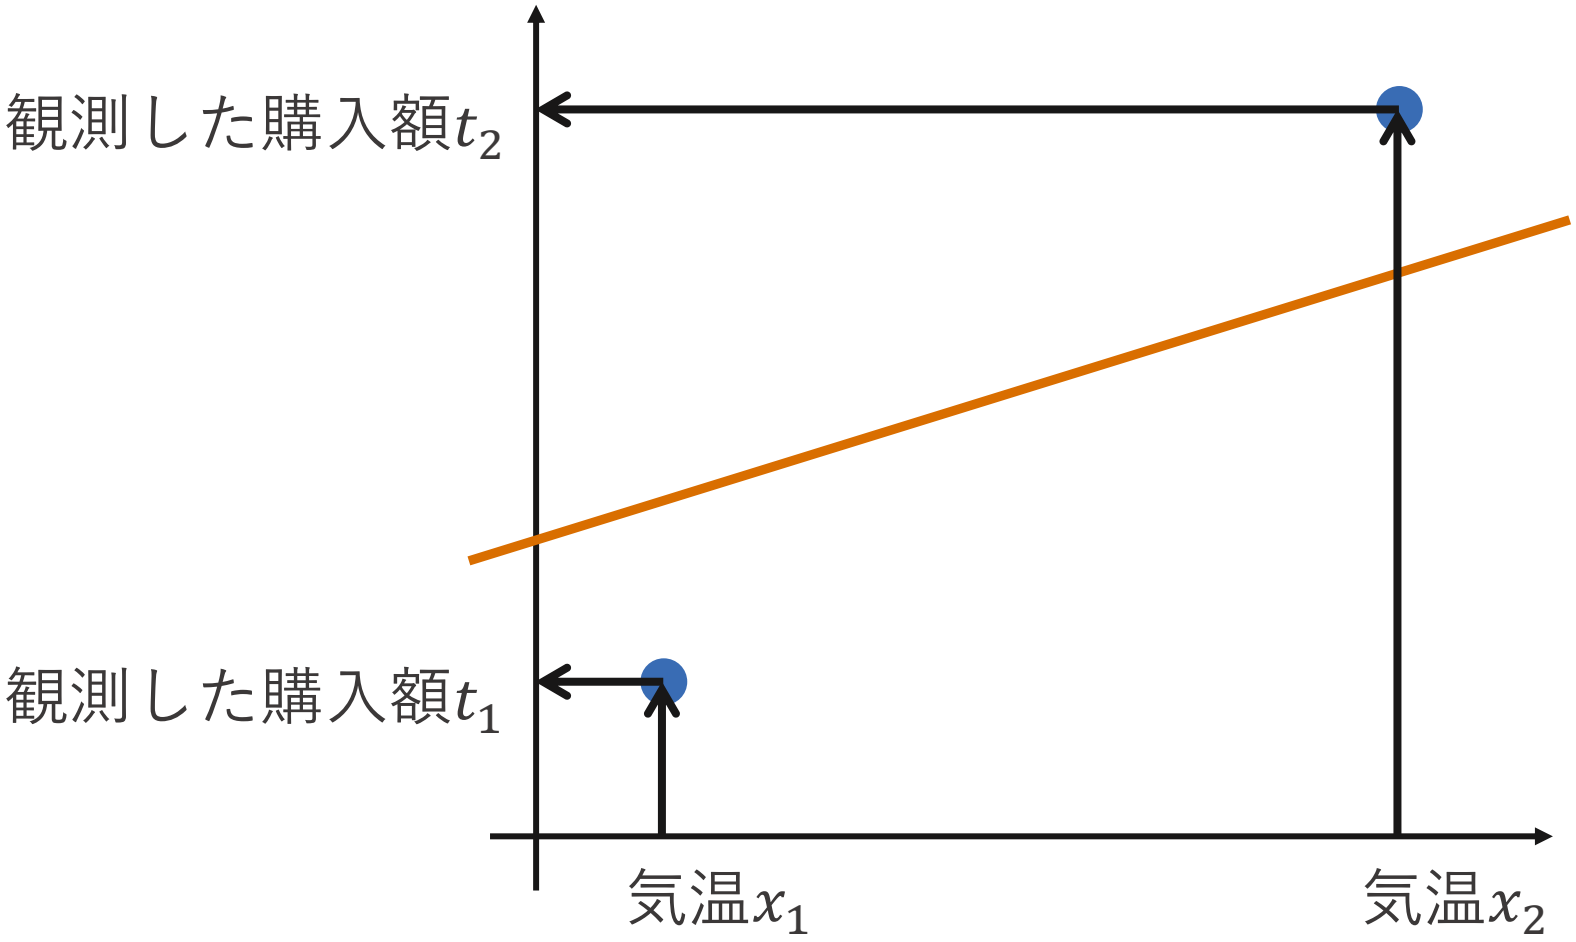
## 良い回帰直線とは

予測が当たる回帰直線が良い.

観測値と予測値の差が小さい回帰直線が良い.

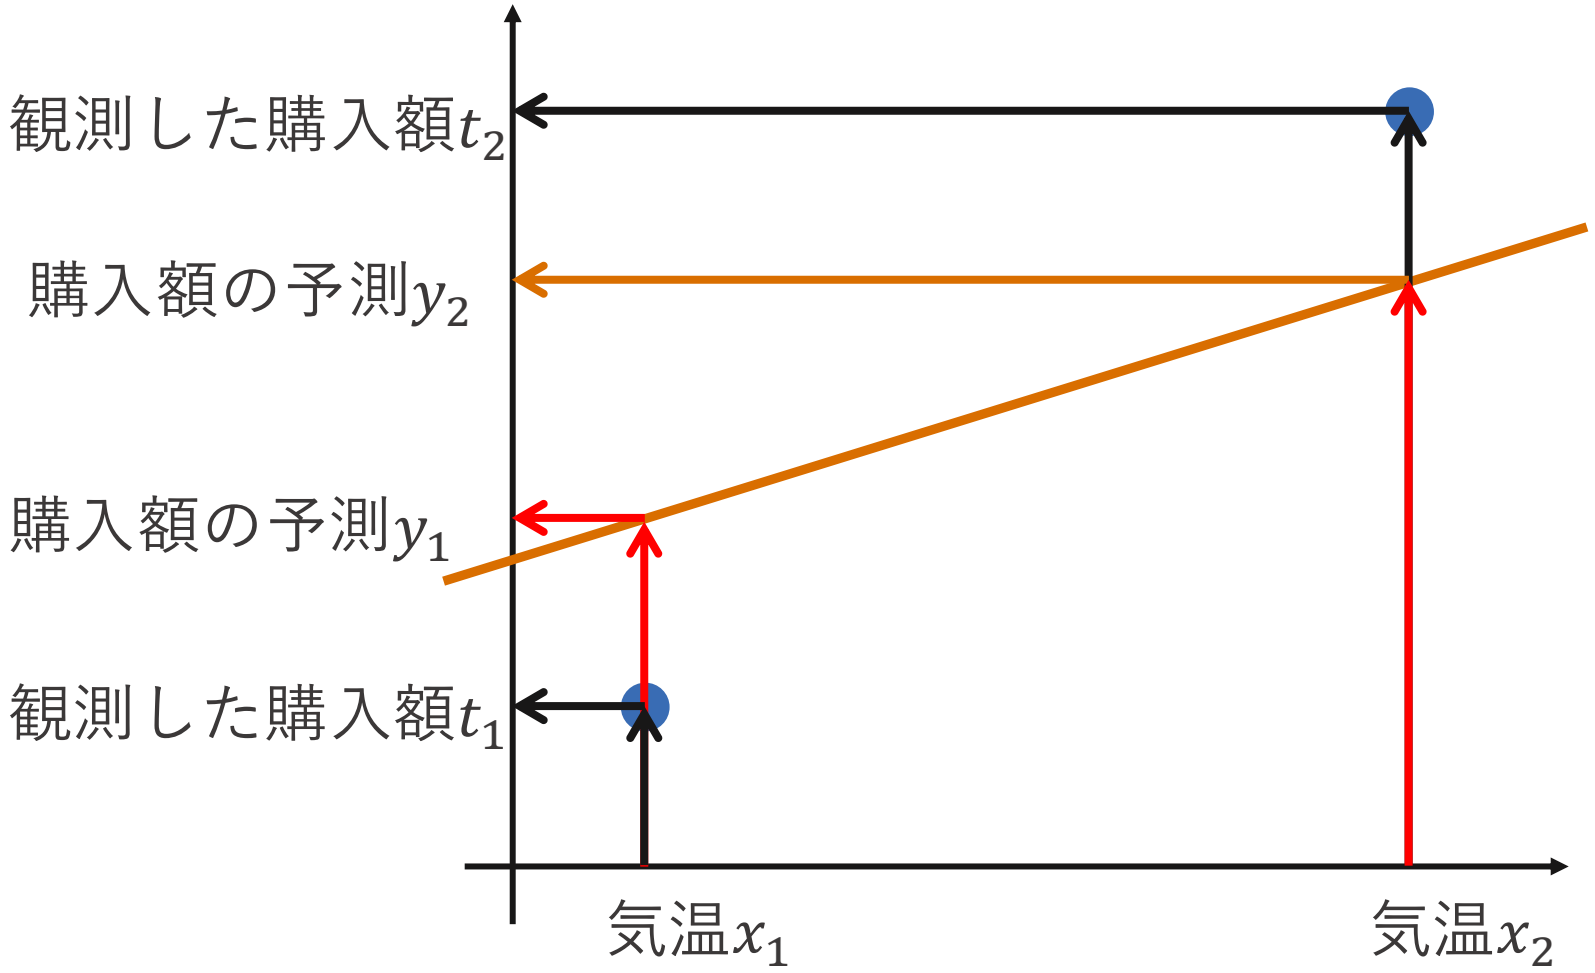
# 差の大きさの平均で評価する

# 観測値




気温$x_1$に対し実際に観測した購入額$t_1$がある.
気温$x_2$に対し実際に観測した購入額$t_2$がある.
実際に観測した値のことを観測値と呼ぶ.

# 予測値




気温$x_1$に対し回帰直線から予測した購入額$y_1$がある.
気温$x_2$に対し回帰直線から予測した購入額$y_2$がある.
回帰直線から予測した値のことを予測値と呼ぶ.

# 誤差

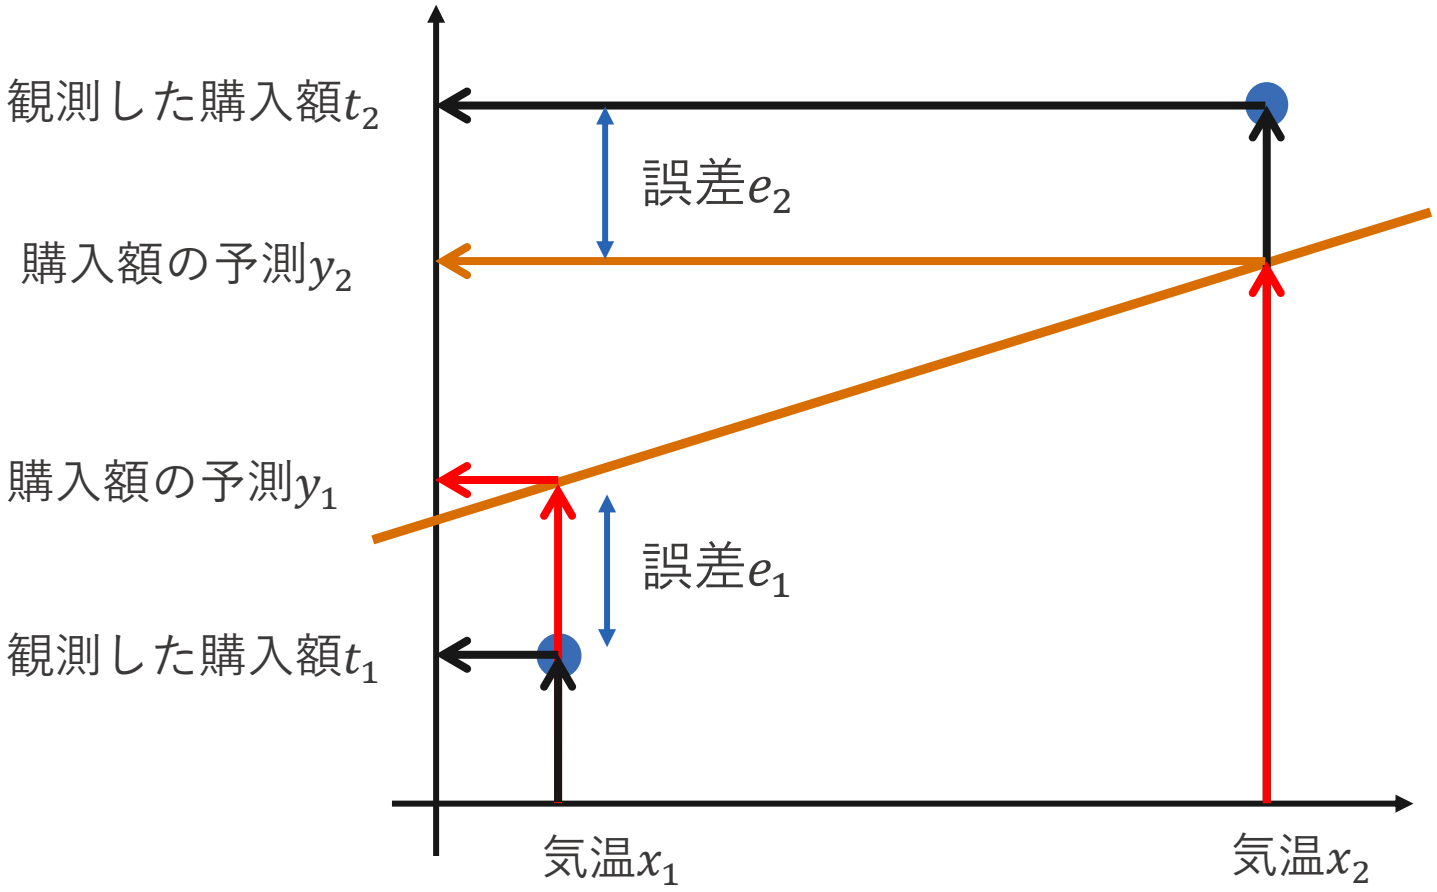
予測値と観測値の差を**誤差**という．

気温$x_1$のときの誤差 $e_1$

$$e_1 = t_1 - y_1$$

気温$x_2$のときの誤差 $e_2$

$$e_2 = t_2 - y_2$$

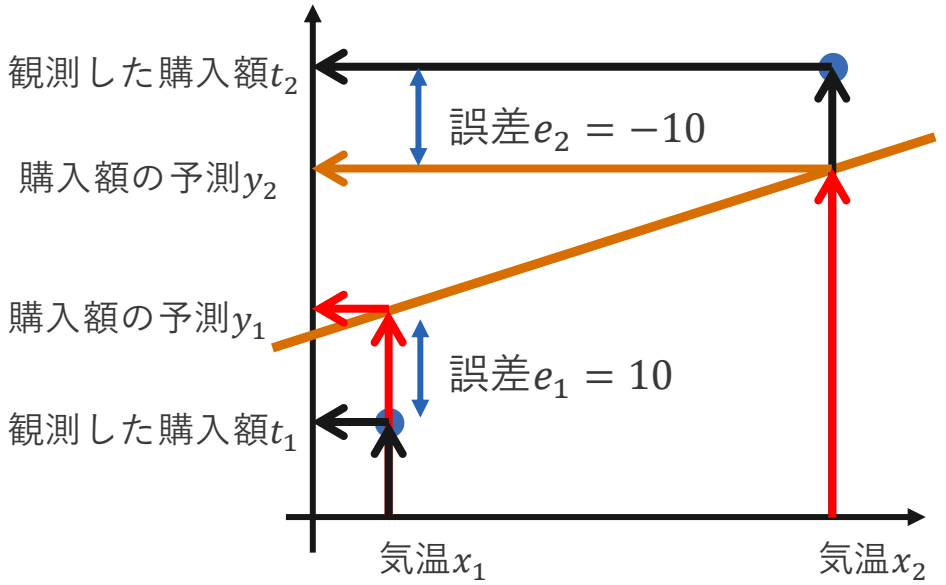


# 誤差は相殺される

全ての誤差が小さい回帰直線が良いと考える.
そうすると，誤差の平均$E$が小さい回帰直線が良いとつい考えてしまう．それで良いのか？

誤差の平均

$$E = \frac{1}{2}(e_1 + e_2)$$




例えば，$e_1 = 10$，$e_2 = -10$だとしたら
誤差の平均は

$$E = \frac{1}{2}(10 - 10) = 0$$

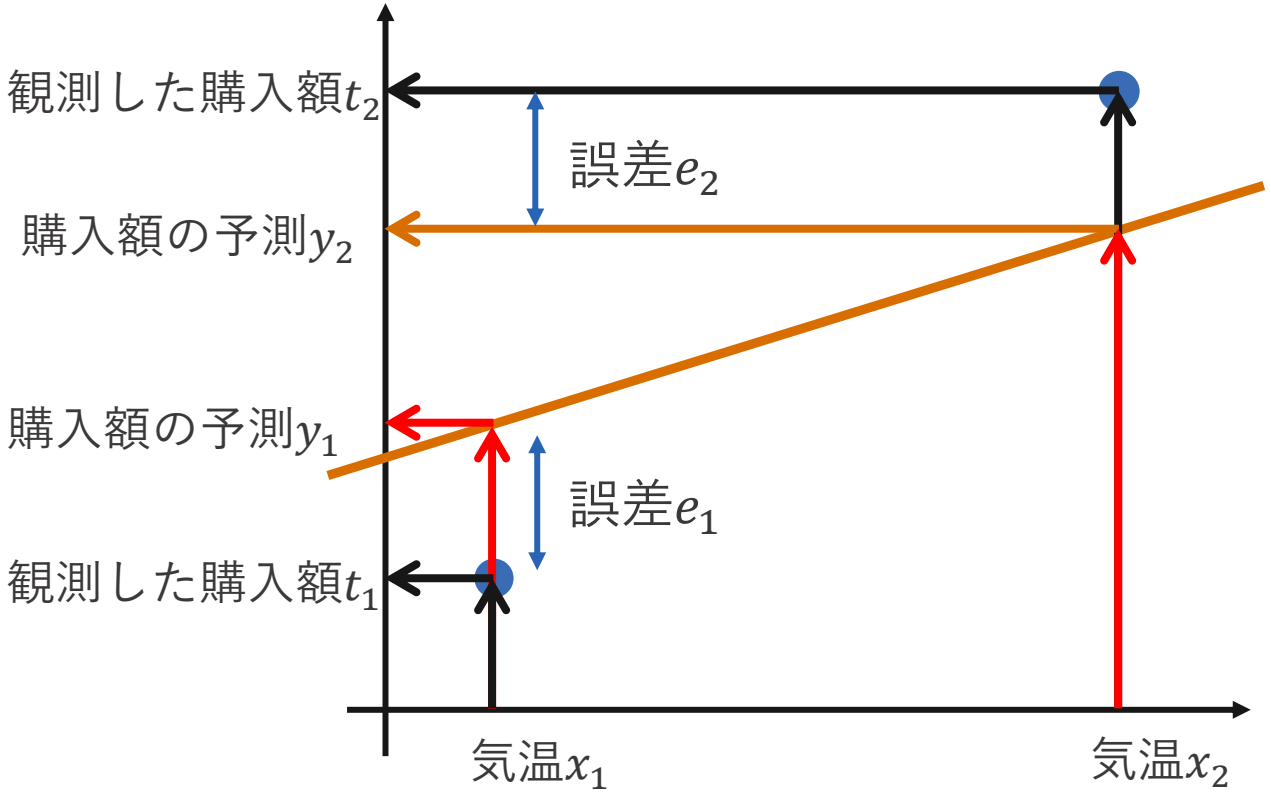
となる，誤差があるにも関わらず，誤差の平均を見ると誤差がないように見える（誤差が相殺される）.

# 予測値と観測値の差

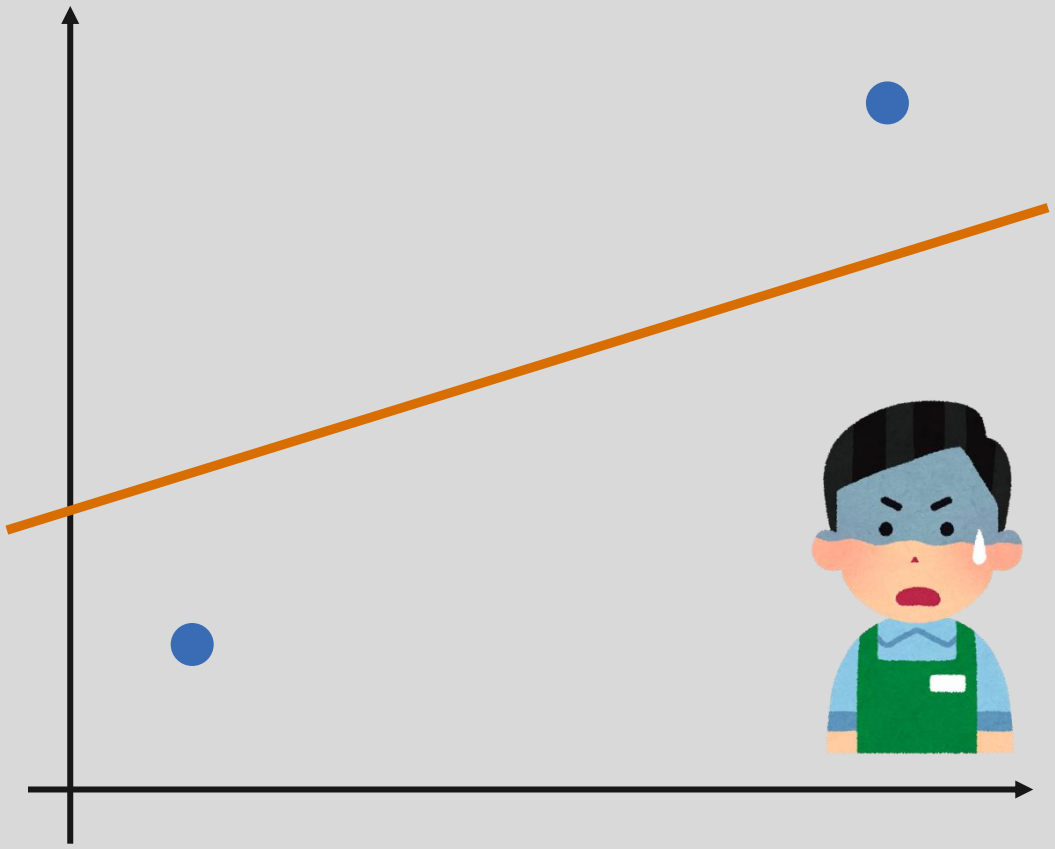
誤差そのものではなく，誤差の大きさを使えば誤差の相殺を避ける事ができる．
ここで誤差の大きさに誤差の二乗を採用しよう．これを**二乗誤差**と呼ぶ．二乗誤差の平均は次の式で書ける．

$$E = \frac{1}{2}(e_1^2 + e_2^2)$$
$$= \frac{1}{2}\left((t_1 - y_1)^2 + (t_2 - y_2)^2\right)$$

これを平均二乗誤差と呼ぶ．

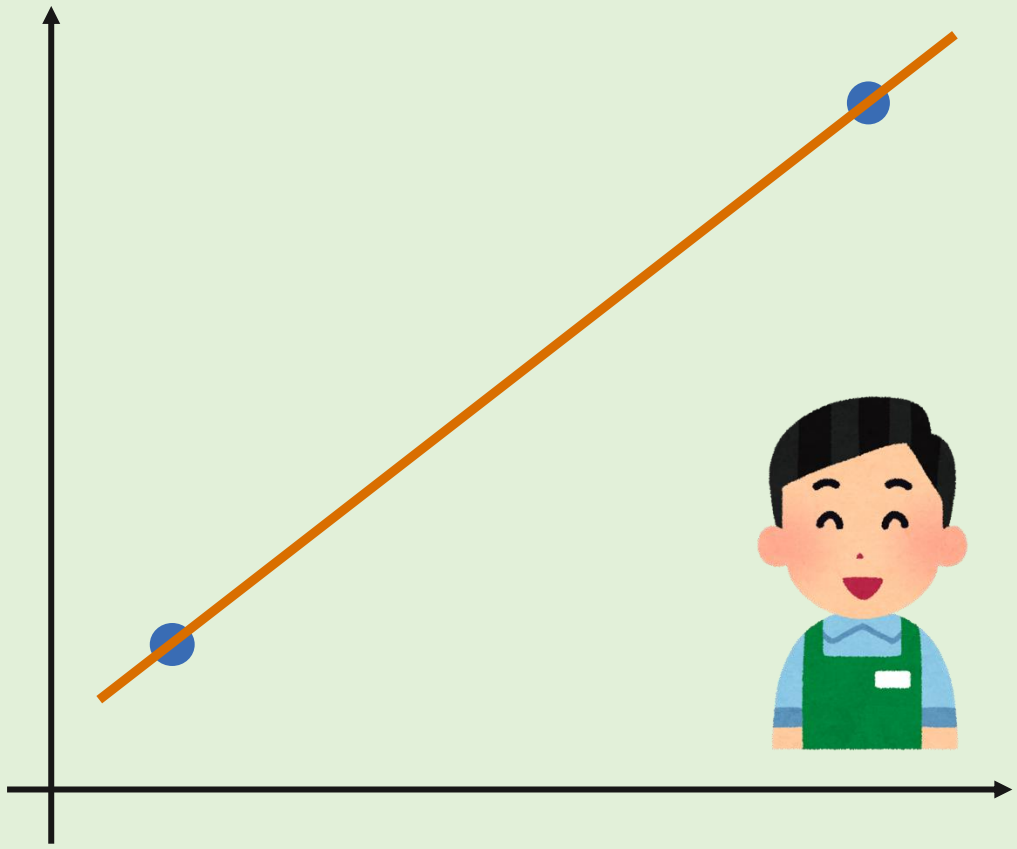


# データ点が2つの場合



平均二乗誤差：$E = \frac{1}{2}\left((t_1 - y_1)^2 + (t_2 - y_2)^2\right)$

平均二乗誤差が大きいからだめ.



平均二乗誤差：$E = 0$

平均二乗誤差が小さいから良い.

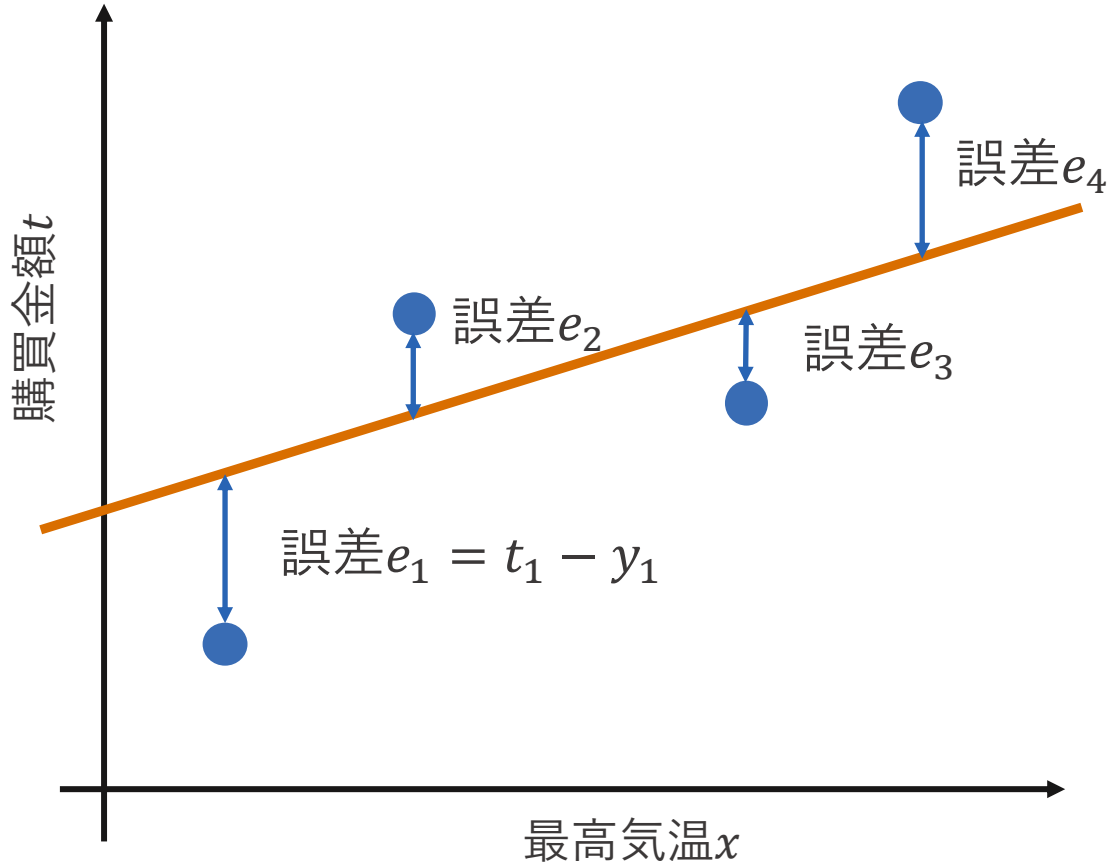
# 複数のデータ点がある場合

通常はデータの中に複数のデータ点がある．
データ点が$N$個あるとすると，平均二乗誤差$E$は次のように書ける．

$$E = \frac{1}{N}(e_1^2 + e_2^2 + \cdots + e_N^2)$$

$$= \frac{1}{N}\sum_{i=1}^{N} e_i^2$$

$$= \frac{1}{N}\sum_{i=1}^{N} (t_i - y_i)^2$$



## 良い回帰直線とは

予測が当たる回帰直線が良い.

観測値と予測の差が小さい回帰直線が良い.

平均二乗誤差の値が小さい回帰直線が良い.

# 目的関数

- 機械学習や人工知能の世界では，小さくしたい関数を**目的関数**という．
  - ここで説明した回帰問題では平均二乗誤差が目的関数となる．
- 機械学習や人工知能は，多くの場合，**目的関数を最小化することを目標としている．**
  - つまり，回帰直線を求める考え方は人工知能技術でよく用いられる考え方である．
  - **回帰直線を理解することで多くの人工知能技術を理解することができる．**

最小化は最大化は等価である．
目的関数にマイナスをかければ最大化問題が最小化問題に切り替わる．

# 回帰直線を求める

発展

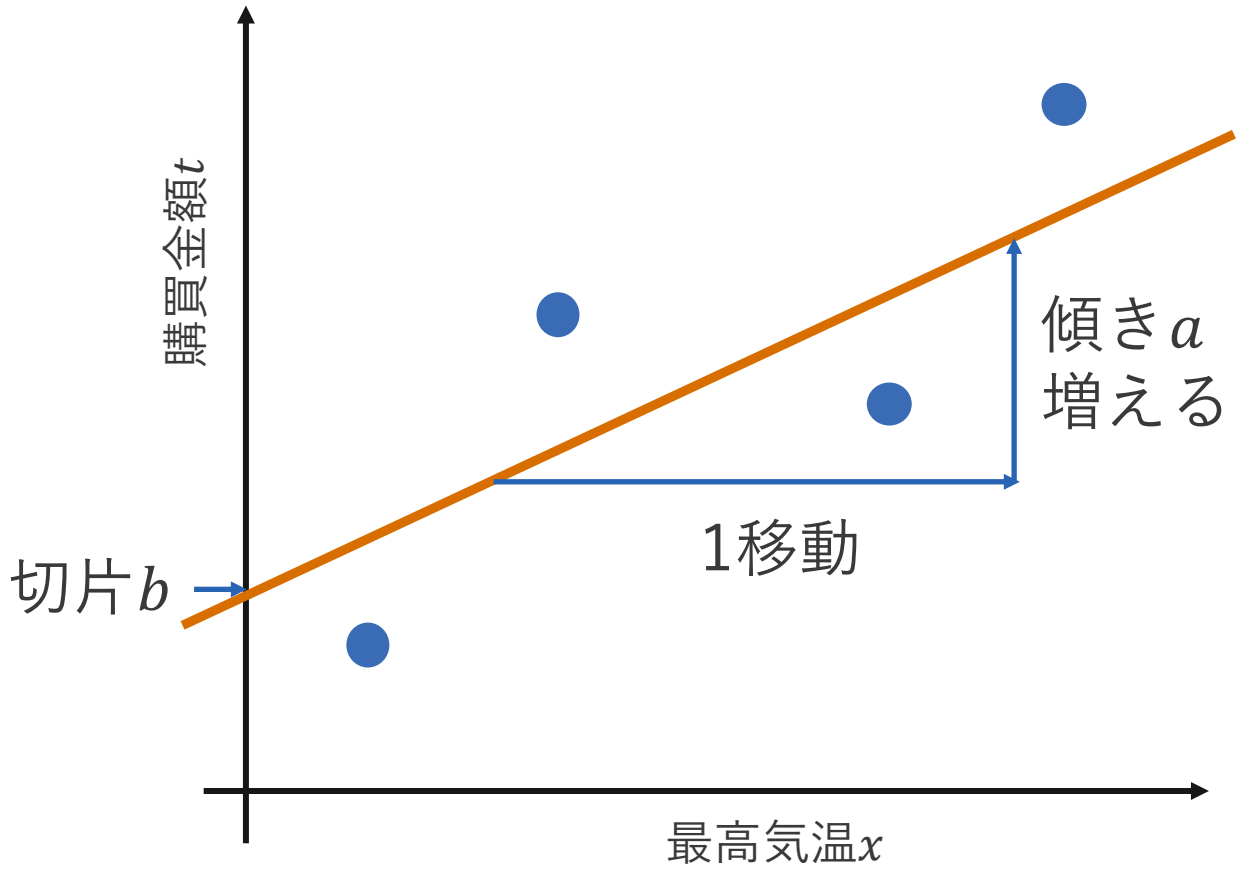
# 回帰直線の式

回帰直線は次のような直線の式で表せる.

$$y_i = ax_i + b$$

目的変数　説明変数　傾き　切片

実際に線を引くためには，傾き$a$と切片$b$をデータから求めなければならない.



# 線形回帰モデル

$$y_i = ax_i + b$$

この式は，回帰方程式や回帰関数などと呼ばれる．
この式は**最も単純な線形回帰モデル**である．しばしば単に線形回帰と呼ばれる．
**モデル**とは，観測でデータ化された現象を説明する何かである．ここでは，$y$を$x$に変換する箱と思っておく．
モデルの動作を決定する変数を**パラメタ**という（ここでは傾き$a$と切片$b$）．

発展的内容
モデルが$y = \sum_{i=0}^{M-1} w_i \phi_i(\mathbf{x})$のような線形結合で書ける場合，そのモデルを線形モデルと呼ぶ (Bishop「パターン認識と機械学習」).

# データから推定されるパラメタ

回帰直線は次のような直線の式で表せる.

$$y_i = ax_i + b$$

回帰直線のパラメタ$a, b$は平均二乗誤差の最小化から次のように推定される. 特に傾き$a$のことを偏回帰係数という.

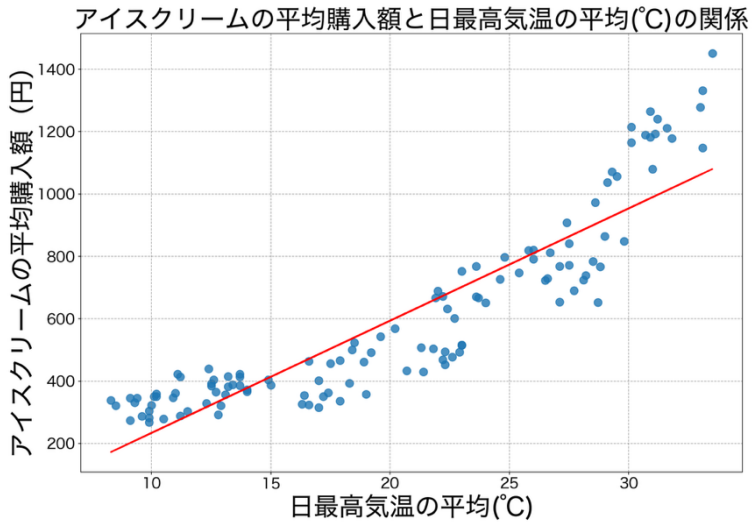
$$a = \frac{\frac{1}{N}\sum_i^N (x_i - \bar{x})(t_i - \bar{t})}{\frac{1}{N}\sum_i^N (x_i - \bar{x})^2}$$

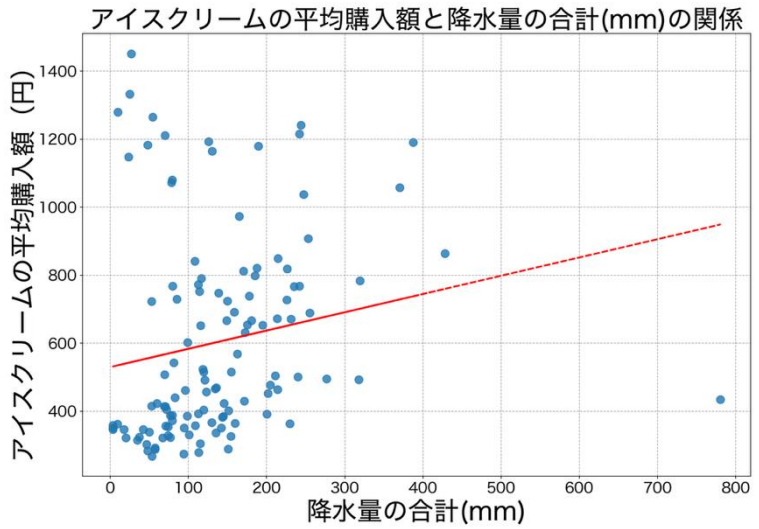
$$b = \bar{t} - a\bar{x}$$

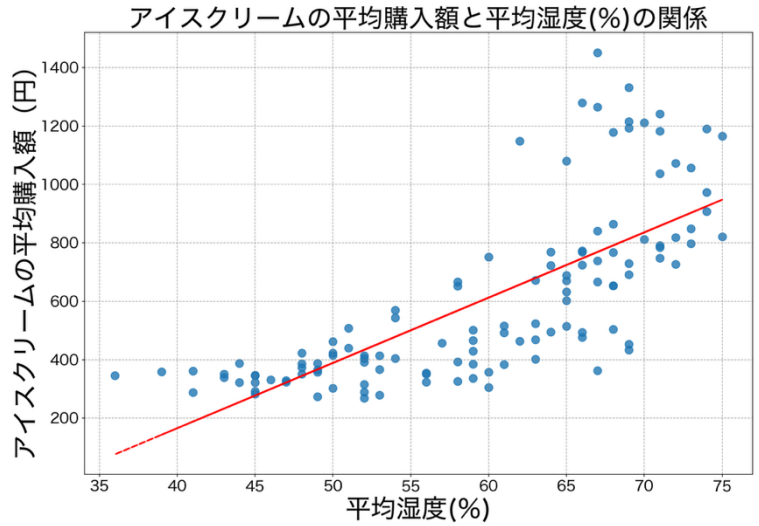
偏回帰係数の偏は略すことが多い(東京大学教養学部統計学教室「統計学入門」).

# 相関係数

# どの要素が一番効果がありそう？



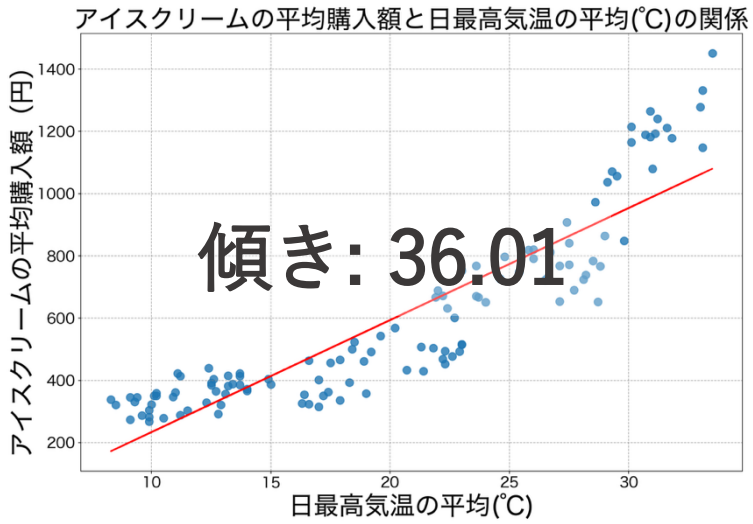



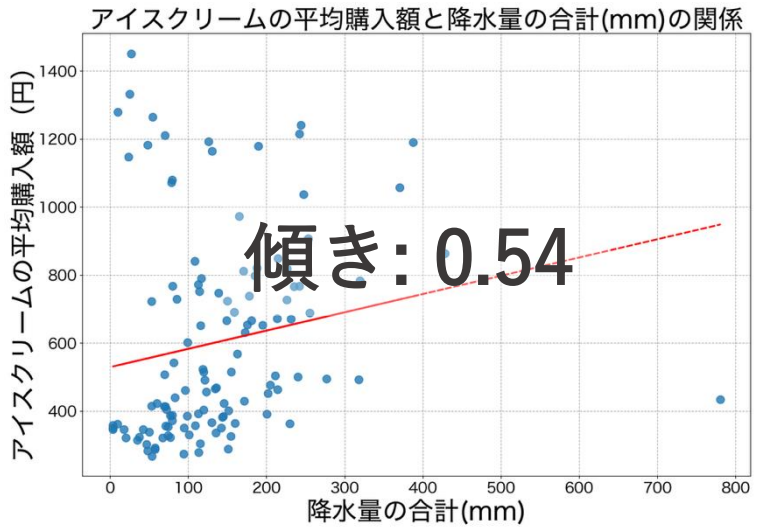



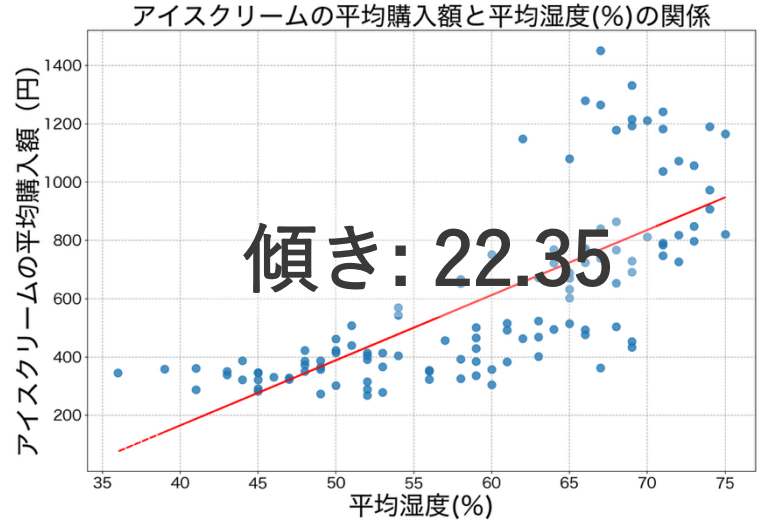

降水量，湿度のデータもあるので，アイスクリームの平均購入額と最高気温，降水量，湿度の回帰直線を比べてみよう．



# どの要素が一番効果がありそう？



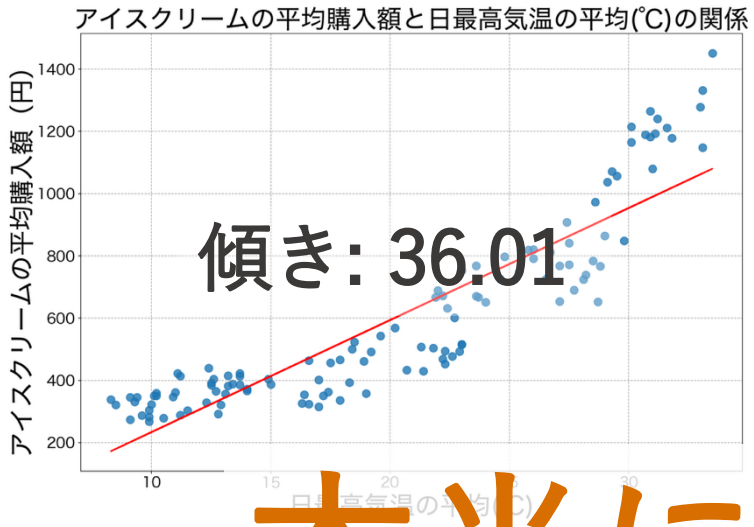



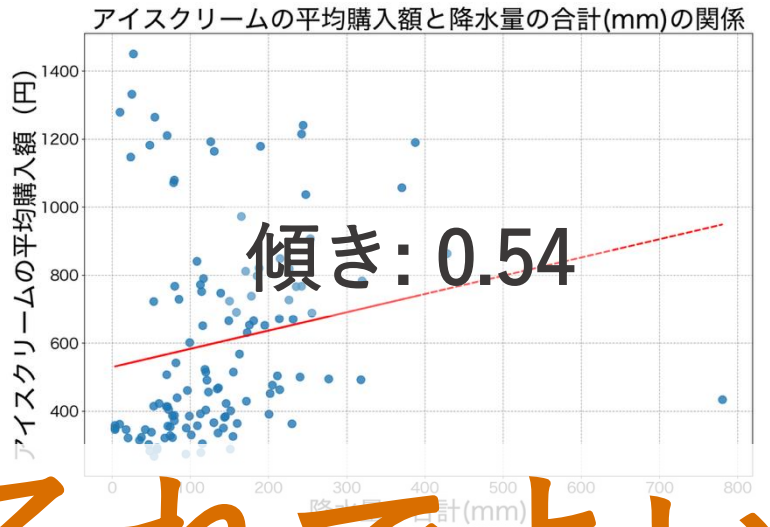



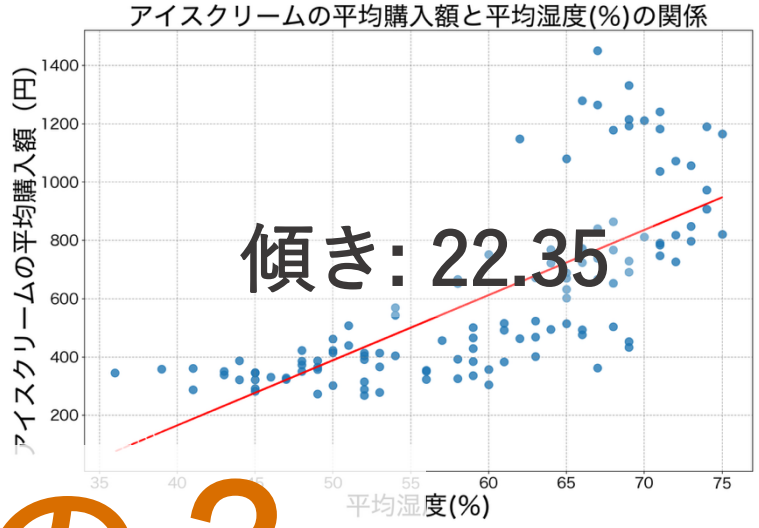

傾きを見ると，傾きが大きい購入額と温度の関係が一番重要そうだ.



# どの要素が一番効果がありそう？



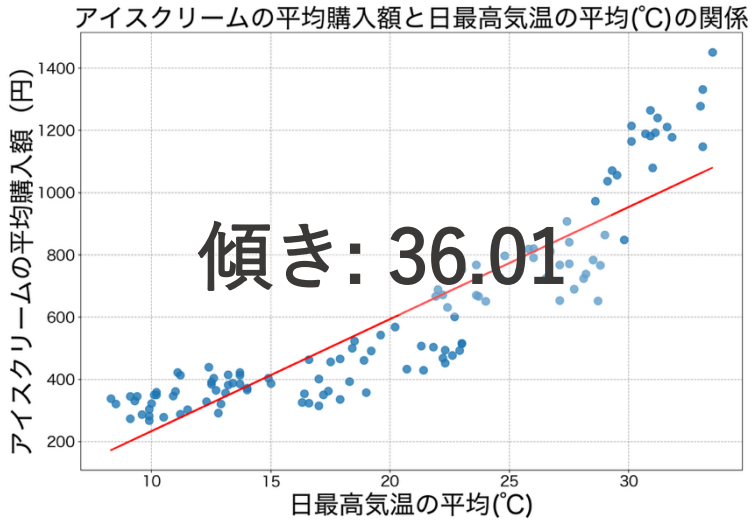



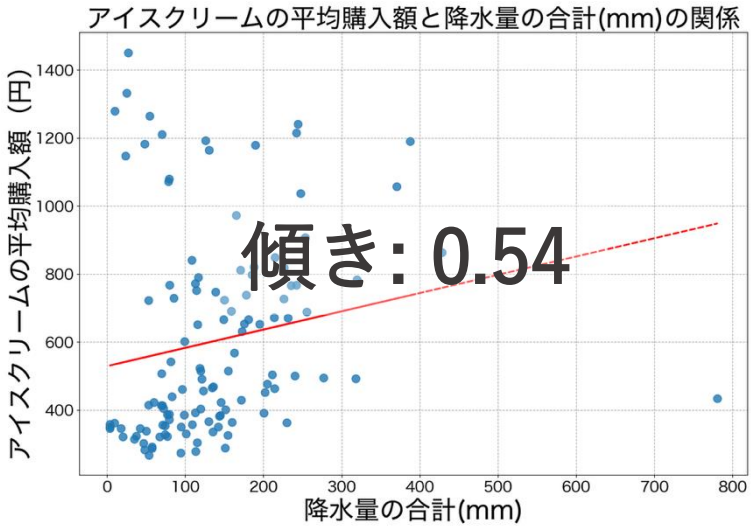

# 本当にそれでよいの？

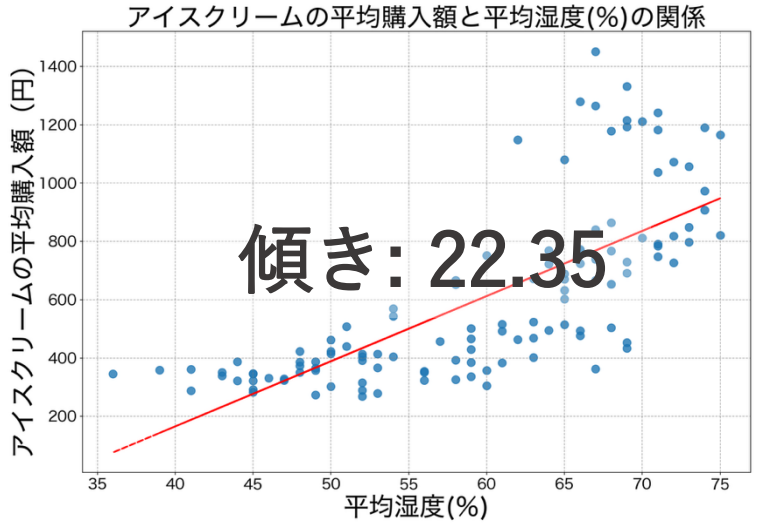
傾きを見ると，傾きが大きい購入額と温度の関係が一番重要そうだ.



# どの要素が一番効果がありそう？




最高気温と湿度は2桁の値をとっている.
一方で降水量は3桁の値をとっている.
縦軸の値の範囲は同じで横軸がとる値の範囲が違うにも関わらず，回帰直線の傾きを比較してよいのだろうか.
当然，値が大きい降水量が説明変数と購買額の回帰直線の傾きの大きさは他に比べ，とても小さい.

# 相関係数

- 値の大きさに関わらず2変数の関係の様子を表す指標に相関係数がある.
- 相関係数$r$は次の式で表される.
- 相関係数は$-1 \leq r \leq 1$の範囲にある.

相関係数は$x$と$t$を入れ替えても同じ値になるため，2変数の役割の区別は無い．スライドの文脈上，説明変数と目的変数という言葉を使ったが，相関係数では区別しないため，実際には単なる変数である.

$$r = \frac{\mathrm{Cov}(x,t)}{\sqrt{\mathrm{Var}(x)}\sqrt{\mathrm{Var}(t)}}$$

← 説明変数と目的変数の共分散

説明変数の標準偏差　　目的変数の標準偏差

この相関係数は，特にピアソンの積率相関係数と呼ばれる.

共分散：$\mathrm{Cov}(x,t) = \frac{1}{N}\sum_i^N (x-\bar{x})(t-\bar{t})$

分散：$\mathrm{Var}(x) = \frac{1}{N}\sum_i^N (x_i-\bar{x})^2$

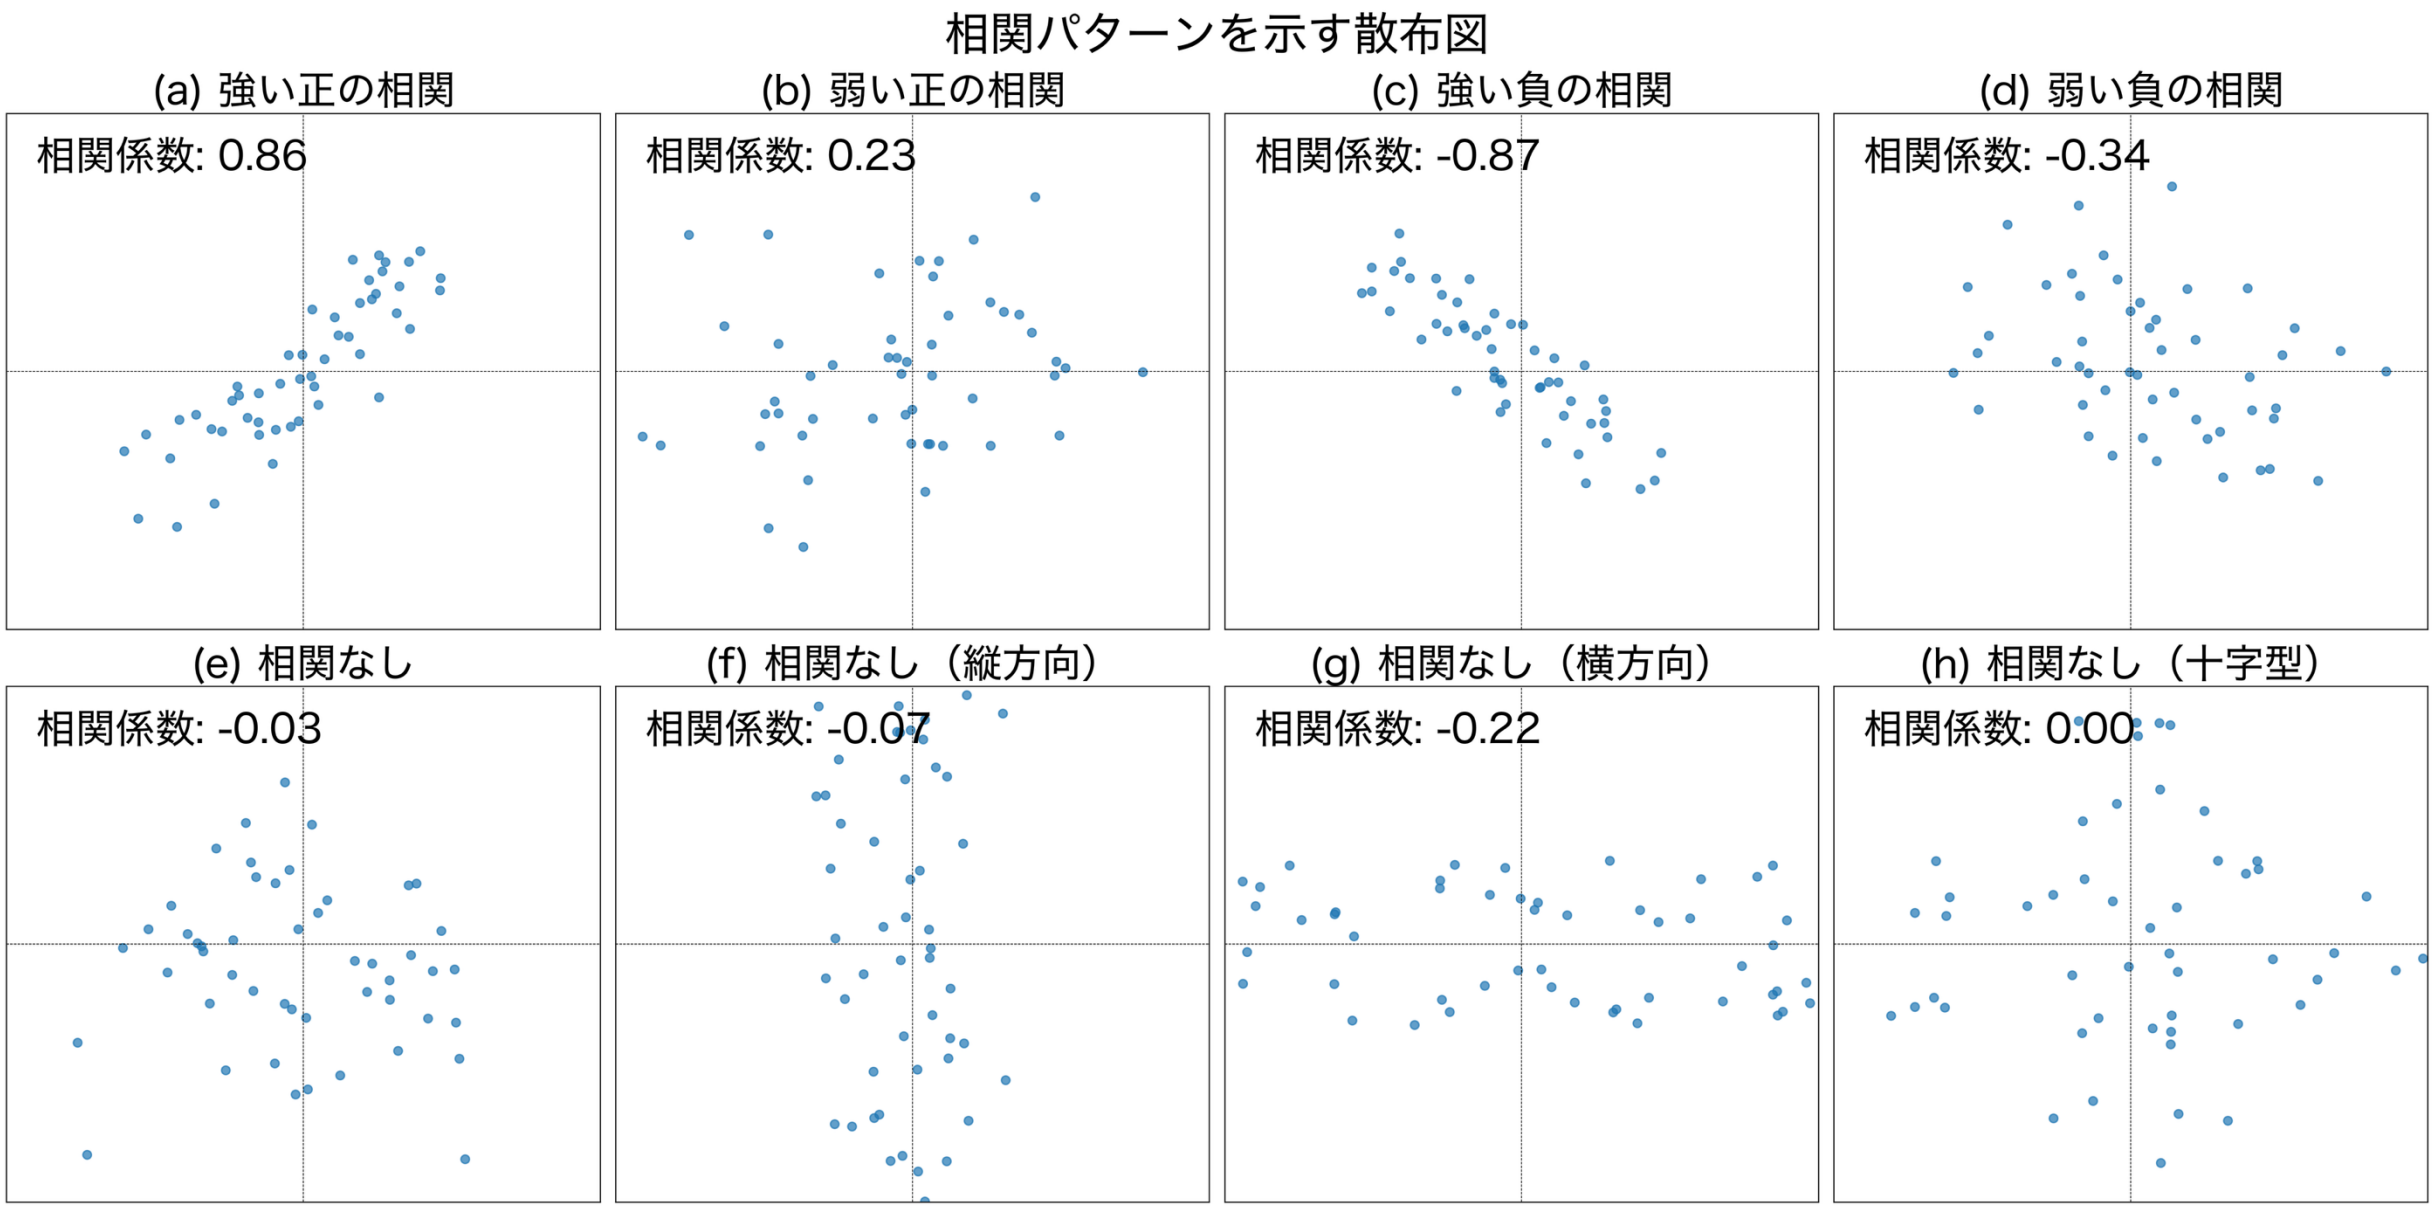
標準偏差：$\sigma(x) = \mathrm{Var}(x)$

# 相関とは

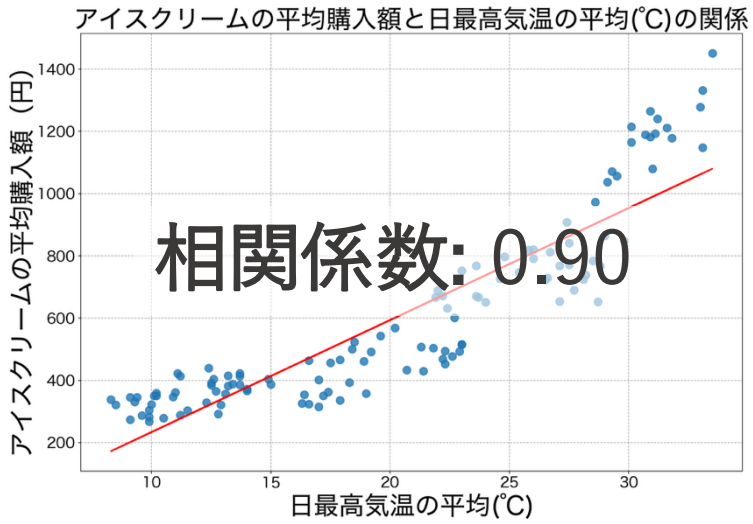
- 統計の世界では，２つの変数間に直線関係に近い傾向がある場合，相関関係があるという．
- 一方の変数が増加し，他方の変数も増加する場合を正の相関があるという．
- 逆に，一方の変数が増加し，他方の変数が減少する場合を負の相関があるという．
- 関係の強さの度合いを「強い」，「弱い」と表現する．

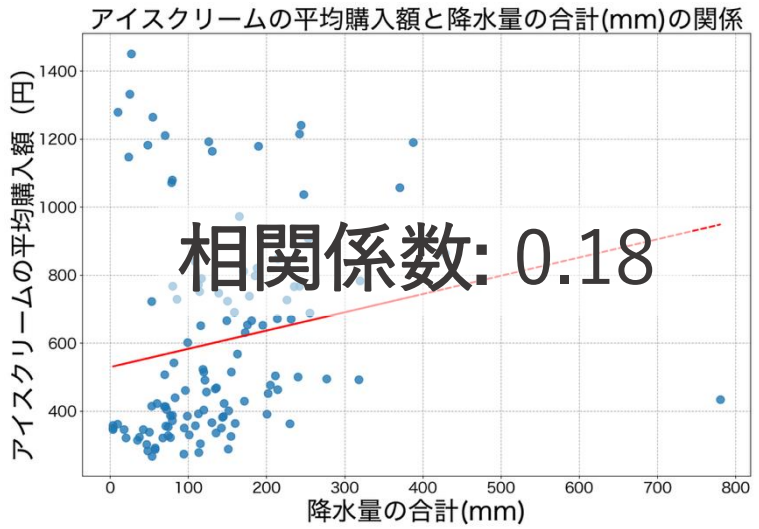
（東京大学教養学部統計学教室「統計学入門」）

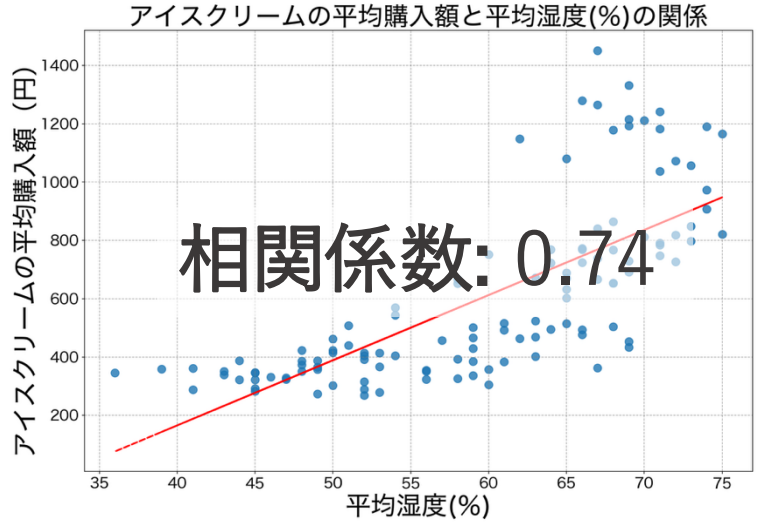
# 相関


相関パターンを示す散布図
(a) 強い正の相関
相関係数: 0.86
(b) 弱い正の相関
相関係数: 0.23
(c) 強い負の相関
相関係数: -0.87
(d) 弱い負の相関
相関係数: -0.34
(e) 相関なし
相関係数: -0.03
(f) 相関なし（縦方向）
相関係数: -0.07
(g) 相関なし（横方向）
相関係数: -0.22
(h) 相関なし（十字型）
相関係数: 0.00

# どの関係を使うのが一番良さそう？




相関係数から購入額と温度に強い正の相関がある.
購入額と温度の関係が一番重要そうだ.



# 注意

- **相関があるからと言って因果関係があるわけではない.**
  - 例
    - 部屋の明るさと視力の悪さを調べたら，部屋が明るいほど視力が悪かった（負の相関があった）.
    - この結果から，部屋が明るいと視力が悪くなると考えてよいか？
    - 実は，家族全員の視力が悪いため部屋を明るくしていただけだった.
- **因果関係があるからと言って相関があるわけではない.**
  - 例
    - 車のアクセルは踏めば踏むほど速度が出る（因果関係がある）.
    - 因果関係があるからといって，アクセルを踏む量と速度に相関があるわけではない.

# 相関係数の値の範囲

$$r = \frac{Cov(x,t)}{\sqrt{Var(x)}\sqrt{Var(t)}} = \frac{\frac{1}{N}\sum_i^N (x_i - \bar{x})(t_i - \bar{t})}{\frac{1}{N}\sqrt{\sum_i^N (x_i - \bar{x})^2}\sqrt{\sum_i^N (t_i - \bar{t})^2}}$$

$$= \frac{(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_N - \bar{x})(t_1 - \bar{t}, t_2 - \bar{t}, \dots, t_N - \bar{t})^T}{\|(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_N - \bar{x})\|\|(t_1 - \bar{t}, t_2 - \bar{t}, \dots, t_N - \bar{t})\|}$$

$$r^2 = \frac{\left((x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_N - \bar{x})(t_1 - \bar{t}, t_2 - \bar{t}, \dots, t_N - \bar{t})^T\right)^2}{\|(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_N - \bar{x})\|^2\|(t_1 - \bar{t}, t_2 - \bar{t}, \dots, t_N - \bar{t})\|^2}$$

コーシー・シュワルツの不等式$(\boldsymbol{u}\cdot\boldsymbol{v})^2 \le \|\boldsymbol{u}\|^2\|\boldsymbol{v}\|^2$より

$$r^2 \le \frac{\|(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_N - \bar{x})\|^2\|(t_1 - \bar{t}, t_2 - \bar{t}, \dots, t_N - \bar{t})\|^2}{\|(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_N - \bar{x})\|^2\|(t_1 - \bar{t}, t_2 - \bar{t}, \dots, t_N - \bar{t})\|^2} = 1$$

よって

$$-1 \le r \le 1$$

発展

# 推定した傾きを眺める

共分散：$\mathrm{Cov}(x,t)=\frac{1}{N}\sum_i^N(x-\bar{x})(t-\bar{t})$

分散：$\mathrm{Var}(x)=\frac{1}{N}\sum_i^N(x_i-\bar{x})^2$

$$a=\frac{\frac{1}{N}\sum_i^N(x_i-\bar{x})(t_i-\bar{t})}{\frac{1}{N}\sum_i^N(x_i-\bar{x})^2}$$

$$=\frac{\mathrm{Cov}(x,t)}{\mathrm{Var}(x)}$$

← 観測値の説明変数と目的変数の共分散

← 観測値の説明変数の分散

$$=\frac{\mathrm{Cov}(x,t)}{\sqrt{\mathrm{Var}(x)}\sqrt{\mathrm{Var}(t)}}\frac{\sqrt{\mathrm{Var}(t)}}{\sqrt{\mathrm{Var}(x)}}$$

相関係数$r$　　標準偏差の比

発展

傾きは，相関係数×標準偏差の比になっている．

標準偏差の比は説明変数と目的変数がとる値の範囲の比と見なせる．また，回帰直線は$\frac{y}{\sqrt{\mathrm{Var}(t)}}=r\left(\frac{x}{\sqrt{\mathrm{Var}(x)}}\right)+\frac{b}{\sqrt{\mathrm{Var}(t)}}$と変換できることから，相関係数$r$は各変数を標準偏差で標準化したときに得られる回帰直線の傾きと言える．

また，傾きから説明変数がとる値の範囲の影響を取り除いた相関係数を得るために，傾きに標準偏差の比をかけるとも見ることもできる．

# まとめ

# まとめ

- データに基づいて考えることが大事です.
  - 勘ではダメです.
- データをグラフを使って可視化しましょう.
  - グラフにすると数値同士の関係が分かるかもしれません.
- 数値の関係を回帰直線で表そう.
  - 予測ができるかもしれません.
- 回帰直線は，観測値と予測値の誤差の大きさの和（平均）が最小となる直線を選ぼう.
- 相関係数を使うと，各説明変数と目的変数の関係（相関）の強さが分かるかもしれない.

# 注意

# 回帰直線の正解は分からない

- 数式を使って回帰直線を導出すると，求めた回帰直線が正解であると思ってしまう．
- しかし，我々には**回帰直線の正解は分からない**．
  - 業界では「神様しか知らない」と言ったりする．
- だから，我々が求めた回帰直線は見当外れで，役に立たないものかもしれない．
- 今回求めた**回帰直線は，いくつもの前提条件をおいた上で求まった人間の先入観が入っている線**であることを忘れないで欲しい．

先入観の例
- 目的変数の関係を直線を採用している．
- 誤差を観測値と推測値の差で求めている．
- 誤差の二乗を誤差の大きさとしている．