データ可視化とEDA

花の長さや幅から、何が分かる？

テーマ2

今日、確かめたいこと

花の種類によって、長さや幅はどう違う？

- 1つの項目を見ると、どんな分布があるか
- 種類で分けると、違いが見えるか
- 2つの項目を組み合わせると、何が分かるか

最後に、気温のデータで「時間に沿った変化」も見ます。

コードがよく分からなくても、機能とその役割を理解することを目指してください。

EDAは、データを調べて手がかりを得ること

EDA：探索的データ分析

表で中身を確かめ、グラフで可視化し、規則性や関係を調べます。

> 「規則性がありそう」と気づいたら、
> 別の見方でも確かめます。

この回では、**図を根拠に、自分の言葉で説明すること**を目指します。

講義と実習の進め方

スライドで、問いと見るポイントを確認します。

「Notebookで実習」 が出たら、指定の見出しへ移ります。

実行したらスライドに戻り、分かったことを共有します。

Notebookは上から順に実行します。途中の説明やコードは、必要なときに読み返せます。コードをすべて覚える必要はありません。

数値を表に並べる

	数学	英語	理科
学生A	80	65	70
学生B	90	88	92
学生C	75	60	78

```
import numpy as np

scores = np.array([
    [80, 65, 70],  # 学生A
    [90, 88, 92],  # 学生B
    [75, 60, 78]   # 学生C
])
```

1行は学生1人、1列は1科目。

各行の数値を `[...]` でまとめ、3行を `np.array()` に渡します。

誰の平均？ 何の平均？

```
scores.shape            # (3, 3)：3行3列
scores.mean(axis=1)     # 学生ごとの平均
scores.mean(axis=0)     # 科目ごとの平均
```

学生Aの平均は、**同じ行の3科目**をまとめます。

数学の平均は、**同じ列の3人分**をまとめます。

axis=1では各行の結果、axis=0では各列の結果が残ります。

Notebookで実習①：配列の計算

「NumPyで配列・行列を扱う」

1. 1次元配列、2次元配列のセルを順に実行する
2. 行ごとの平均と列ごとの平均を、点数表と照らす
3. `scores + 10` の結果を確認する

確認すること： 元の `scores` の値も変わった？

配列全体に、同じ計算ができる

```
v = np.array([10, 20, 30])
v * 2                          # [20, 40, 60]
```

配列の各要素に同じ計算を適用する書き方を、
ベクトル化と呼びます。

`scores + 10` は、新しい配列を作ります。
元の `scores` はそのままです。

Irisは、150件の花の測定記録

1行が1つの花。測定値の単位は、すべてcm。

測定項目（特徴量）	Notebookの列名
がく片の長さ	`sepal length (cm)`
がく片の幅	`sepal width (cm)`
花びらの長さ	`petal length (cm)`
花びらの幅	`petal width (cm)`

種類は setosa、versicolor、virginica の3種です。

測定値と、種類を表すラベル

種類の番号 `target`	種類名 `species`	件数
0	setosa	50
1	versicolor	50
2	virginica	50

番号は、種類を区別するための記号です。

今回の表は、**4つの測定値 ＋ 番号 ＋ 種類名で6列**。

pandasのDataFrameを使うと、列名の付いた表として操作できます。

Notebookで実習②：データの確認

「データを準備する」〜「データを確認する」

1. Irisを読み込み、表の1行を言葉で説明する
2. 行数・列数、種類ごとの件数、欠損件数を確認する
3. 基本統計量から、花びらの長さの平均・最小・最大を探す

確認すること： 平均だけで、値の集まり方も分かる？

同じ平均でも、分布は違う

説明用のデータ	値	平均
A	4, 5, 6	5
B	1, 5, 9	5

Aは5の近くに集まり、Bは広く散らばっています。

どの範囲に、どれくらいあるか。

それを調べるのが、分布を見るということです。

区間に分けて、件数を数える

説明用の値：1.0, 1.2, 1.4, 1.5, 2.1, 2.5 cm

区間（階級）	入る値	件数（度数）
1.0以上、1.5未満	1.0, 1.2, 1.4	3
1.5以上、2.0未満	1.5	1
2.0以上、2.5以下	2.1, 2.5	2

これが**度数分布表**です。1.5は、2番目の区間に入ります。

今回の集計では、最後の階級だけ右端の値も含めます。

度数分布表をコードで作る

```
feature = 'petal length (cm)'
n_bins = 18
counts, bin_edges = np.histogram(df[feature], bins=n_bins)

freq_df = pd.DataFrame({
    '階級の下端': bin_edges[:-1],
    '階級の上端': bin_edges[1:],
    '度数': counts
})
display(freq_df)
```

`counts` は18個の件数、`bin_edges` は19個の境界値です。

隣り合う境界値が、1つの階級の下端と上端になります。

次の表では、下端と上端を [a, b) の形にまとめて表示します。

Irisの花びらの長さの度数分布表

150件を18階級に分けると、次のようになります。

階級（cm）	度数（件）
[1.000, 1.328)	11
[1.328, 1.656)	33
[1.656, 1.983)	6
[1.983, 2.311)	0
[2.311, 2.639)	0
[2.639, 2.967)	0
[2.967, 3.294)	1
[3.294, 3.622)	5
[3.622, 3.950)	5

階級（cm）	度数（件）
[3.950, 4.278)	12
[4.278, 4.606)	17
[4.606, 4.933)	14
[4.933, 5.261)	14
[5.261, 5.589)	7
[5.589, 5.917)	14
[5.917, 6.244)	5
[6.244, 6.572)	2
[6.572, 6.900]	4

[a, b) は「a以上、b未満」。最後の階級だけ右端も含みます。度数の合計は150件。
境界値は小数第3位までの表示です。集計には丸める前の値を使います。

ヒストグラムを描くコード

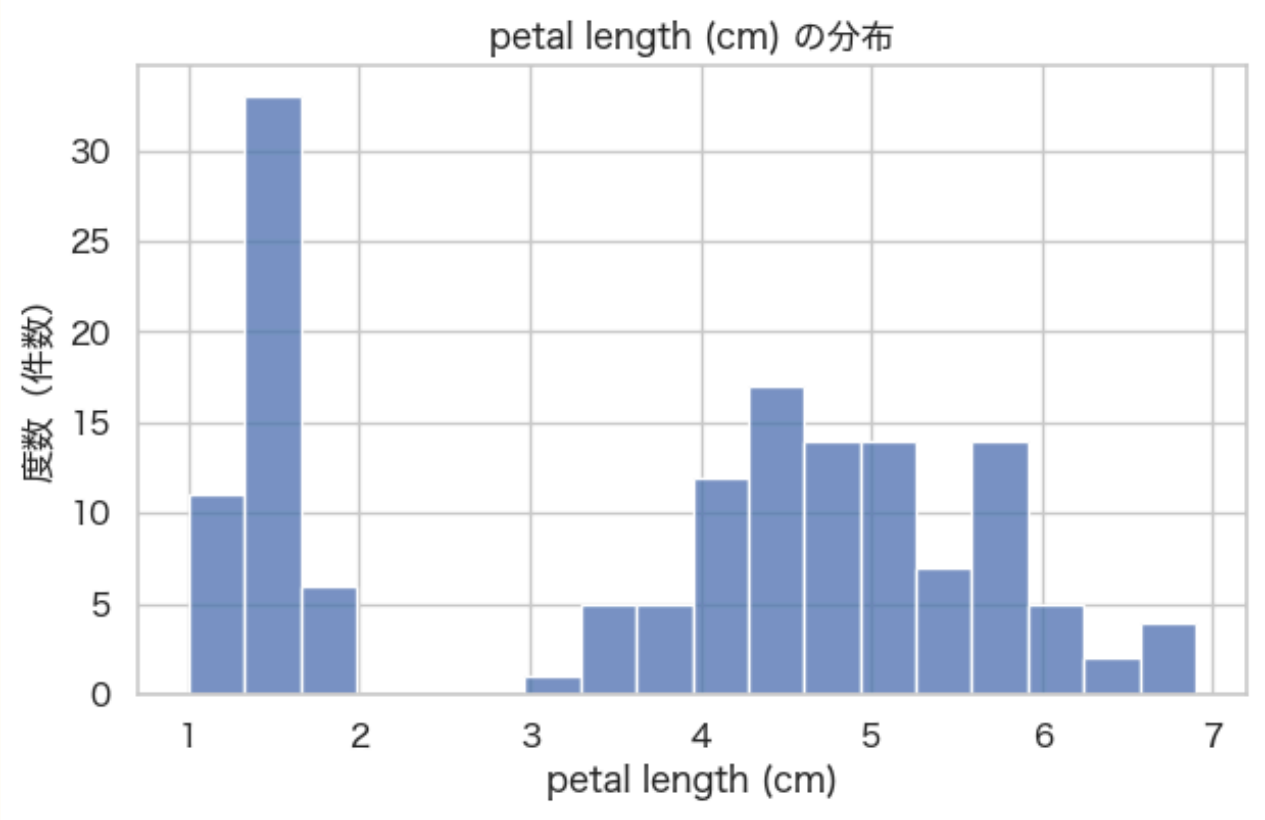
```
import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(7, 4))
sns.histplot(data=df, x=feature, bins=bin_edges, stat='count')
plt.xlabel(feature)
plt.ylabel('度数（件数）')
plt.show()
```

`x` は測定項目、`bins` は度数分布表と同じ境界値です。

表で数えた件数が、そのまま棒の高さになります。

件数を高さにすると、ヒストグラムになる



横軸は花びらの長さ。縦軸は、その区間に入る花の件数。

Notebookで実習③：表と図の対応

「度数分布表から分布を調べる」

「度数分布表をヒストグラムで表す」

1. 初期設定の `feature` と `n_bins = 18` で実行する
2. 描画ライブラリを読み込み、全体のヒストグラムを描く
3. 表の1区間を選び、図の横位置と高さを照らす

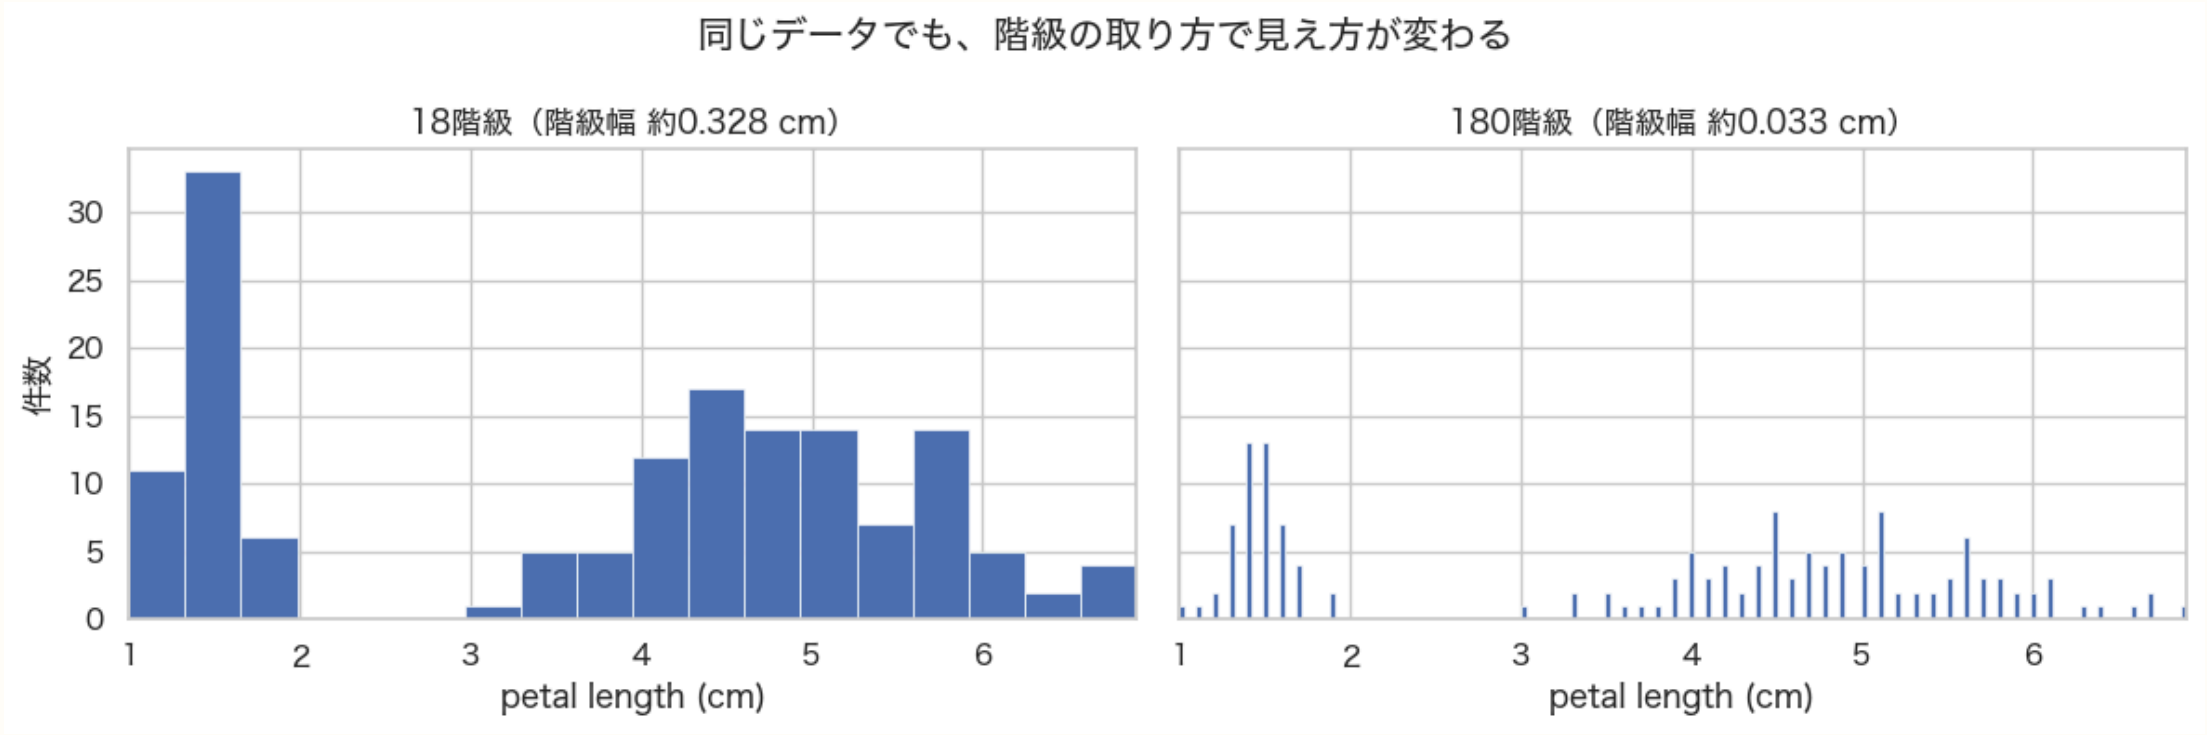
確認すること： 度数を合計すると、何件になる？

階級数を変えて比べるコード

```
values = df['petal length (cm)']
fig, axes = plt.subplots(1, 2, figsize=(12, 4),
                         sharex=True, sharey=True)
for ax, n in zip(axes, [18, 180]):
    ax.hist(values, bins=n, edgecolor='white', linewidth=0.5)
    ax.set_title(f'{n}階級')
    ax.set_xlabel('petal length (cm)')
    ax.set_xlim(values.min(), values.max())
axes[0].set_ylabel('件数')
plt.tight_layout()
plt.show()
```

`bins` の階級数を変え、**同じデータ・同じ軸の範囲**で比べます。

同じデータでも、区間の取り方で見え方が変わる



18階級と180階級。細かい方が、分布を読みやすいだろうか？

Notebookで実習④：階級数を比べる

「階級を細かくしすぎるとどうなるか」

1. 18階級と180階級の図を描く
2. 棒の間に隙間が増える理由を考える
3. 余裕があれば `comparison_bins = [10, 30]` でも比べる

確認すること： どんな設定でも残る、大まかな特徴は？

ヒストグラムの山は、どの種類の花？

全体の分布には、花の種類の情報が隠れています。

同じ測定項目・同じ区間のまま、種類で色を分けます。

> 種類ごとの分布は、離れているだろうか？
> それとも、重なっているだろうか？

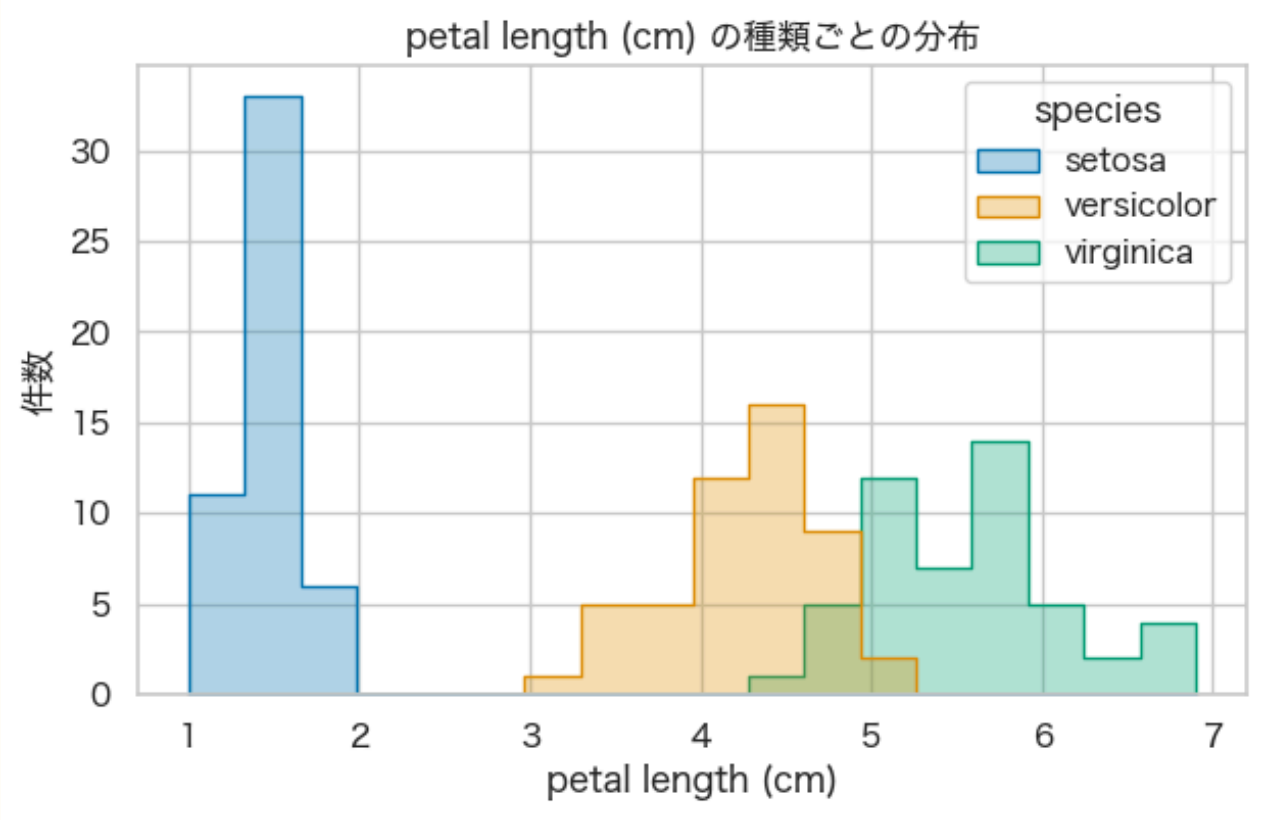
種類ごとに色を分けるコード

```
plt.figure(figsize=(7, 4))
sns.histplot(
    data=df, x=feature, hue='species',
    bins=bin_edges, element='step', common_bins=True,
    hue_order=species_order, palette=species_palette,
    stat='count', multiple='layer', alpha=0.3
)
plt.xlabel(feature)
plt.ylabel('件数')
plt.show()
```

`hue='species'` で種類別に色分けします。

同じ `bin_edges` を使い、全体の図と比べます。

色分けすると、分布の重なりが見える



setosaは短い側。versicolorとvirginicaには、重なる区間がある。

Notebookで実習⑤：種類ごとの分布

「ヒストグラムを花の種類で色分けする」

1. 種類別ヒストグラムを実行し、重なる範囲を読む
2. 度数分布表の `feature` を別の測定項目に変える
3. **表、全体の図、種類別の図**の順に再実行する

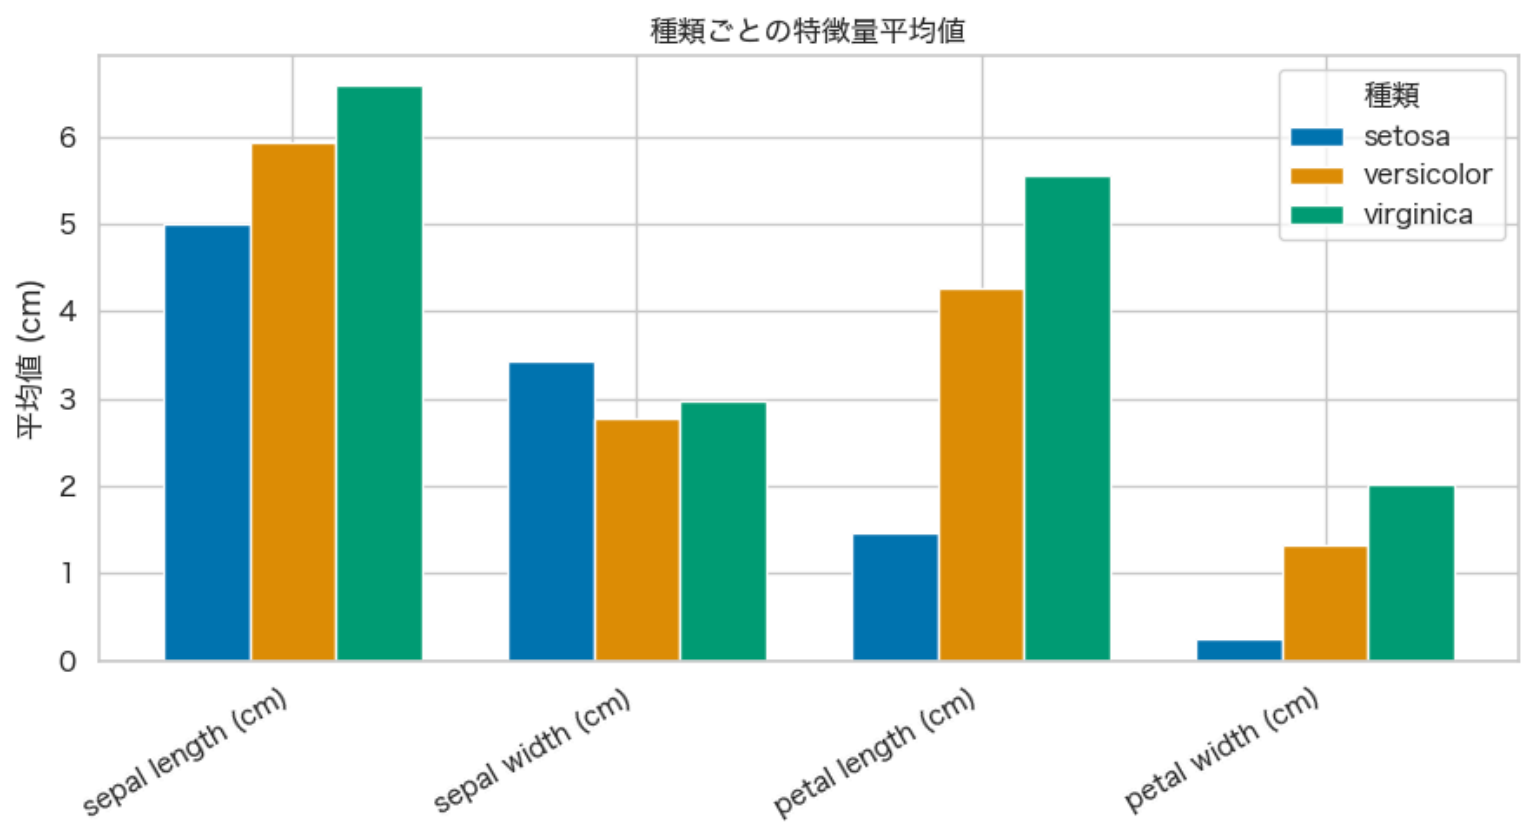
確認すること： 項目を変えると、種類の重なりも変わる？

種類ごとの平均を棒グラフにするコード

```
mean_by_species = (
    df.groupby('species')[numeric_columns].mean()
    .reindex(species_order)
)
x = np.arange(len(numeric_columns))
plt.figure(figsize=(9, 5))
for i, species in enumerate(species_order):
    plt.bar(x + (i - 1) * 0.25, mean_by_species.loc[species],
            width=0.25, label=species, color=species_palette[species])
plt.xticks(x, numeric_columns, rotation=30, ha='right')
plt.ylabel('平均値 (cm)')
plt.legend(title='種類')
plt.tight_layout()
plt.show()
```

`groupby()` で種類ごとに集計し、横位置をずらして3種類の棒を並べます。

種類ごとの平均を、棒の高さで比較する



同じ測定項目の中で比較する。平均だけでは、個々の値の重なりは分からない。

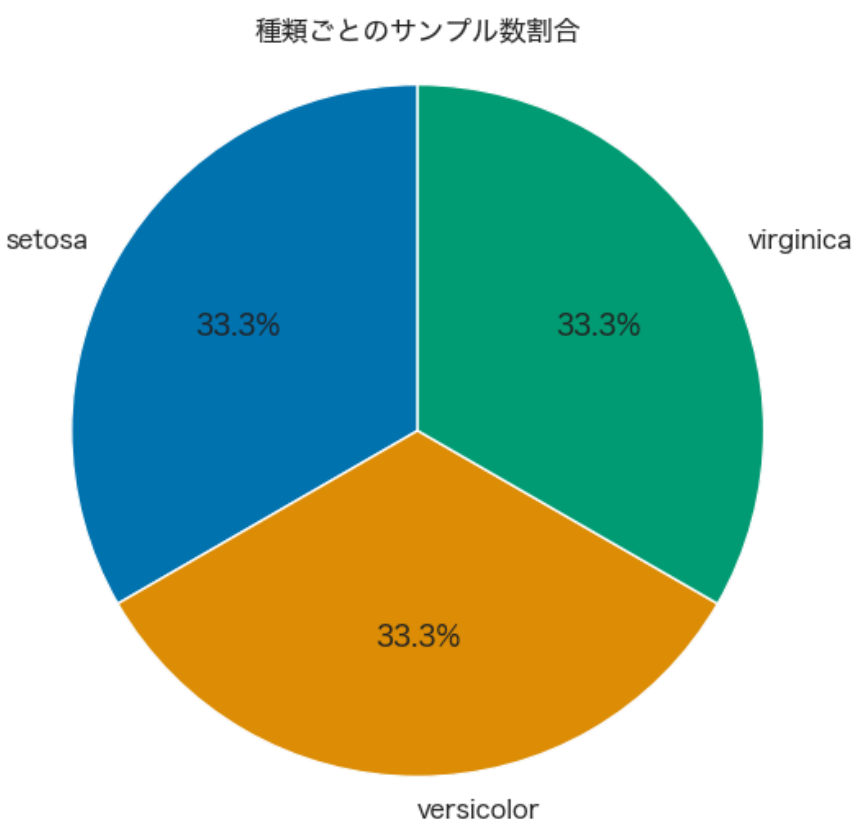
件数を集計して、円グラフにするコード

```
species_count = df['species'].value_counts().reindex(species_order)
plt.figure(figsize=(6, 6))
plt.pie(
    species_count.values, labels=species_count.index,
    autopct='%1.1f%%', startangle=90,
    colors=[species_palette[s] for s in species_count.index]
)
plt.axis('equal')
plt.show()
```

`value_counts()` で種類ごとの件数を数えます。

`autopct` で、割合を小数第1位まで表示します。

このデータセットでは、各種類が3分の1



50 ÷ 150 × 100 ≒ 33.3%。自然界の割合まで分かるわけではない。

Notebookで実習⑥：平均と割合

「棒グラフで種類ごとの平均を比較する」

「円グラフで件数を割合として見る」

1. 種類ごとの平均の表と、棒の高さを照らす
2. 円グラフの割合を、種類ごとの件数と照らす

確認すること： それぞれの図は、どんな問いに答えている？

長さと幅を、一緒に見る

散布図では、**1点が1つの花**を表します。

点の情報	表すもの
横の位置	花びらの長さ
縦の位置	花びらの幅
色と記号	花の種類

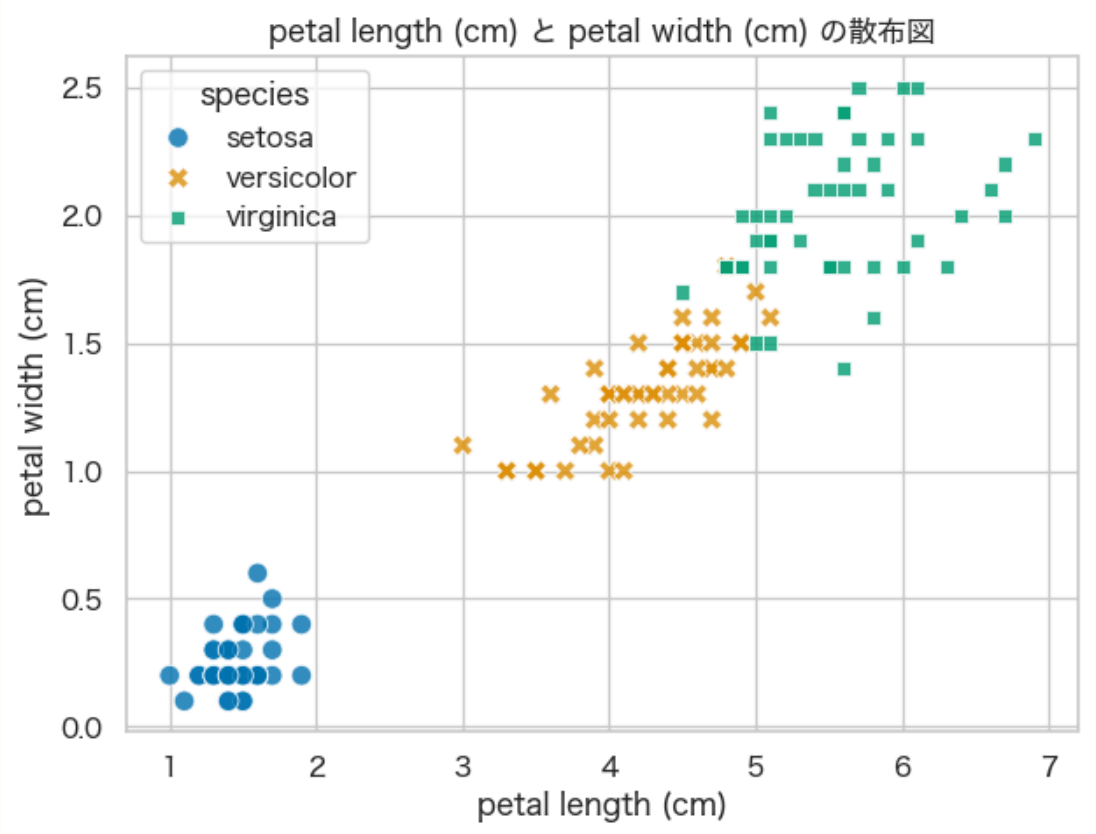
1項目の分布では重なった種類も、見分けやすくなるでしょうか？

2つの列を、点の位置にするコード

```
x_feature = 'petal length (cm)'
y_feature = 'petal width (cm)'
plt.figure(figsize=(7, 5))
sns.scatterplot(
    data=df, x=x_feature, y=y_feature,
    hue='species', style='species',
    hue_order=species_order, style_order=species_order,
    palette=species_palette, s=70, alpha=0.8
)
plt.xlabel(x_feature)
plt.ylabel(y_feature)
plt.show()
```

`x` と `y` が点の位置、 `hue` と `style` が種類の区別。

2つの項目で見る、種類ごとの集まり



点の集まりの向きと、種類どうしが重なる範囲に注目する。

Notebookで実習⑦：組み合わせを変える

「散布図で2つの測定項目を組み合わせる」

1. 花びらの長さと幅で描き、種類の重なりを読む
2. `x_feature` と `y_feature` を別の組み合わせに変える
3. 種類別ヒストグラムと散布図を比べる

確認すること： どの組み合わせが、見分ける手がかりになりそう？

図から言えることを、書き分ける

事実

花びらの長さと幅の散布図では、setosaの点が他の2種から離れている。

解釈

花びらの長さと幅は、setosaを見分ける手がかりになりそう。

限界

新しい花をどれくらい正しく分類できるかは、この図だけでは分からない。

月ごとの変化を見るには？

ここからは、花の測定記録から**気温の記録**へ切り替えます。

- 1行は1か月、2025年1〜12月の12行
- 広島・津山・金沢の各地点の月平均気温（℃）

時間の順に並ぶ値は、折れ線で結ぶと変化を追いやすくなります。

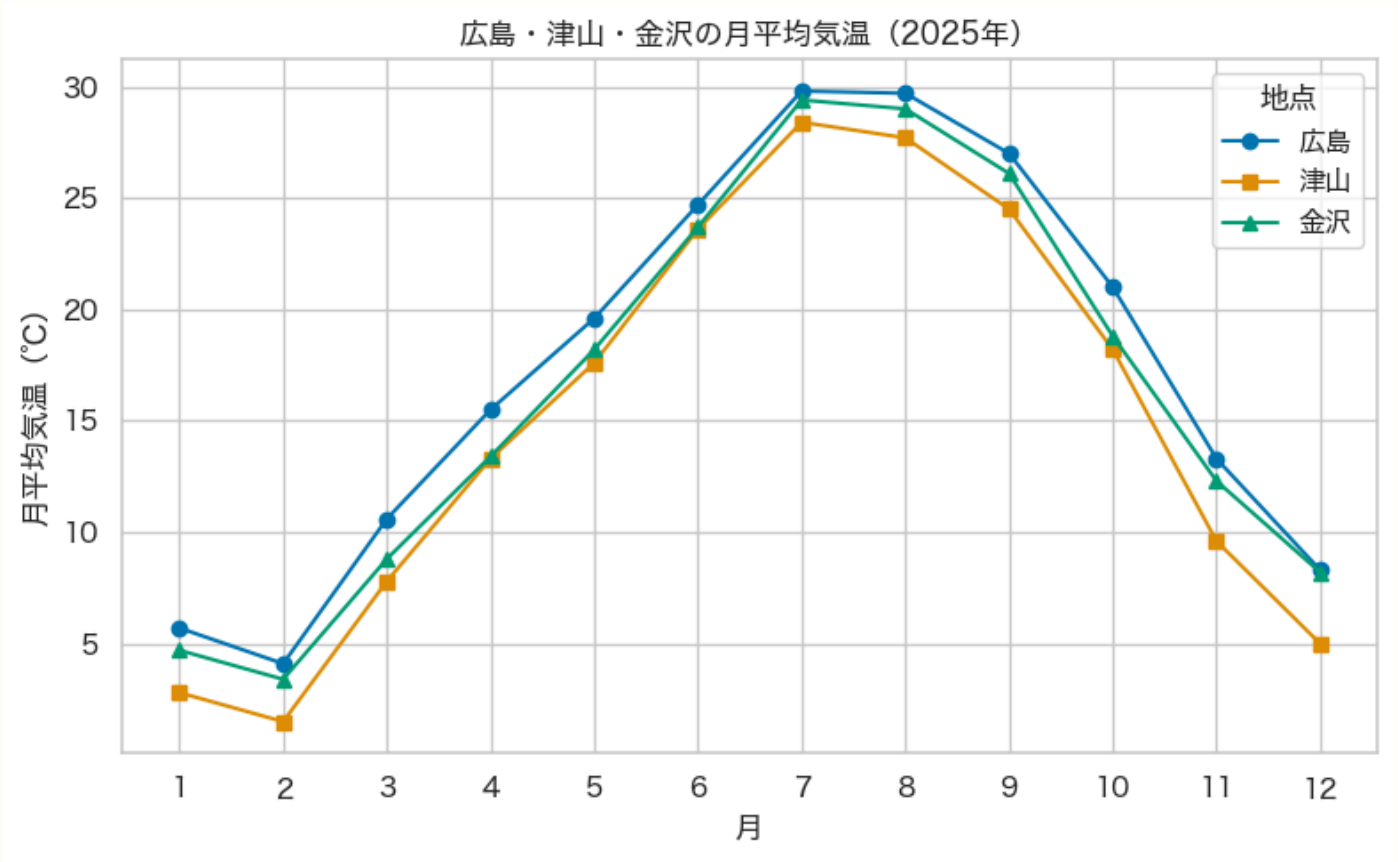
用意されたコードでCSVを読み込み、月ごとの気温を描きます。

CSVを読み込んで、折れ線を描くコード

```
weather_df = pd.read_csv(weather_csv, encoding='utf-8-sig').sort_values('月')
cities = ['広島', '津山', '金沢']
colors = sns.color_palette('colorblind', 3)
plt.figure(figsize=(8, 5))
for city, color, marker in zip(cities, colors, ['o', 's', '^']):
    plt.plot(weather_df['月'], weather_df[city],
             label=city, color=color, marker=marker)
plt.xlabel('月')
plt.ylabel('月平均気温（℃）')
plt.xticks(range(1, 13))
plt.legend(title='地点')
plt.tight_layout()
plt.show()
```

Notebookで準備したCSVを読み、月の順に各地点の値を線で結びます。

線の変化と、同じ月の地点差



各線の高い月・低い月と、同じ月の点の高さの差を読む。

Notebookで実習⑧：気温の変化

「折れ線グラフで月平均気温の変化を見る」

1. CSVを読み込み、表と折れ線グラフを表示する
2. 各地点で、気温が最も高い月と低い月を探す
3. 地点間の差が大きい月と小さい月を比べる

確認すること： この1年分の図から、温暖化まで言える？

月平均と1年分のデータで分かる範囲

月平均では、**日ごとの気温の変動**は分かりません。

線は隣り合う月の点を結んでいます。
月の間の値を直接観測した線ではありません。

2025年の1年分なので、長期的な温暖化や、
複数年の平均的な気候は、この図だけでは判断できません。

問いに合わせて、グラフを選ぶ

知りたいこと	使ったグラフ
どの範囲に値が多い？	ヒストグラム
種類ごとの平均はどう違う？	棒グラフ
全体のうち、どれくらい？	円グラフ
2つの項目には、どんな関係がある？	散布図
時間に沿って、どう変わる？	折れ線グラフ

同じデータでも、問いが変われば、見る図も変わります。

レポートは、演習A〜Cを1本に

演習	必須の内容
A：ペンギン	体重の度数分布表と比較図、階級数4・8・16の比較
B：アイス購入額	気温とアイスクリームの平均購入額の散布図
C：電力需要	選んだ1日の折れ線グラフ、需要が最大の時刻と値

必須の成果物は、**度数分布表1つとグラフ3つ**です。

AはAdelieと別の種類を比べ、階級数4・8・16も試して設定と理由を書きます。Cは日付を変更します。各演習で、図から読み取れることを2〜3文で説明します。

Notebookで確認：レポートの仕上げ

「まとめとレポート」

- 本文テンプレートを使い、Word形式でまとめる
- Aの種類名・階級数、Cの日付を変えて再実行する
- 度数分布表と3種類のグラフに、自分の説明を添える
- 氏名・提出日と「分からなかった点」も記す

提出方法と詳細は、Notebookで確認してください。

花の長さや幅から、何が分かった？

自分が作った図を根拠に、説明してみましょう。

> どの種類が、どんな値の範囲に集まった？
>
> 項目を組み合わせると、何が見えた？
>
> まだ、この分析だけでは言えないことは？