# データ可視化とEDA

## 花の長さや幅から、何が分かる？

テーマ2

# 今日、確かめたいこと

**花の種類によって、長さや幅はどう違う？**

- 1つの項目を見ると、どんな分布があるか
- 種類で分けると、違いが見えるか
- 2つの項目を組み合わせると、何が分かるか

最後に、気温のデータで「時間に沿った変化」も見ます。

# EDAは、データを調べて手がかりを得ること

EDA：探索的データ分析

表で中身を確かめ、グラフで分布や関係を調べます。

> 「違いがありそう」と気づいたら、
> 別の見方でも確かめます。

この回では、**図を根拠に、自分の言葉で説明すること**を重視します。

# 講義と実習の進め方

スライドで、問いと見るポイントを確認します。

**「Notebookで実習」**が出たら、指定の見出しへ移ります。

実行したらスライドに戻り、分かったことを共有します。

Notebookは上から順に実行します。途中の説明やコードは、必要なときに読み返せます。コードをすべて覚える必要はありません。

# 数値を表に並べる

| | 数学 | 英語 | 理科 |
|---|---|---|---|
| 学生A | 80 | 65 | 70 |
| 学生B | 90 | 88 | 92 |
| 学生C | 75 | 60 | 78 |

```
import numpy as np

scores = np.array([
    [80, 65, 70],  # 学生A
    [90, 88, 92],  # 学生B
    [75, 60, 78]   # 学生C
])
```

**1行は学生1人、1列は1科目。**

各行の数値を `[...]` でまとめ、3行を `np.array()` に渡します。

# 誰の平均？ 何の平均？

```
scores.shape            # (3, 3)：3行3列
scores.mean(axis=1)     # 学生ごとの平均
scores.mean(axis=0)     # 科目ごとの平均
```

学生Aの平均は、**同じ行の3科目**をまとめます。

数学の平均は、**同じ列の3人分**をまとめます。

axis=1では各行の結果、axis=0では各列の結果が残ります。

# Notebookで実習①：配列の計算

## 「NumPyで配列・行列を扱う」

1. 1次元配列、2次元配列のセルを順に実行する
2. 行ごとの平均と列ごとの平均を、点数表と照らす
3. `scores + 10` の結果を確認する

**確認すること：** 元の `scores` の値も変わった？

# 配列全体に、同じ計算ができる

```
v = np.array([10, 20, 30])
v * 2                          # [20, 40, 60]
```

配列の各要素に同じ計算を適用する書き方を、

**ベクトル化**と呼びます。

`scores + 10` は、新しい配列を作ります。

元の `scores` はそのままです。

# Irisは、150件の花の測定記録

1行が1つの花。測定値の単位は、すべてcm。

| 測定項目（特徴量） | Notebookの列名 |
| --- | --- |
| がく片の長さ | `sepal length (cm)` |
| がく片の幅 | `sepal width (cm)` |
| 花びらの長さ | `petal length (cm)` |
| 花びらの幅 | `petal width (cm)` |

種類は setosa、versicolor、virginica の3種です。

# 測定値と、種類を表すラベル

| 種類の番号 `target` | 種類名 `species` | 件数 |
|---:|---|---:|
| 0 | setosa | 50 |
| 1 | versicolor | 50 |
| 2 | virginica | 50 |

番号は、種類を区別するための記号です。

今回の表は、**4つの測定値 ＋ 番号 ＋ 種類名で6列**。

pandasのDataFrameを使うと、列名の付いた表として操作できます。

# Notebookで実習②：データの確認

## 「データを準備する」〜「データを確認する」

1. Irisを読み込み、表の1行を言葉で説明する
2. 行数・列数、種類ごとの件数、欠損件数を確認する
3. 基本統計量から、花びらの長さの平均・最小・最大を探す

**確認すること：** 平均だけで、値の集まり方も分かる？

# 同じ平均でも、分布は違う

| 説明用のデータ | 値 | 平均 |
| --- | --- | --- |
| A | 4, 5, 6 | 5 |
| B | 1, 5, 9 | 5 |

Aは5の近くに集まり、Bは広く散らばっています。

**どの範囲に、どれくらいあるか。**

それを調べるのが、分布を見るということです。

# 区間に分けて、件数を数える

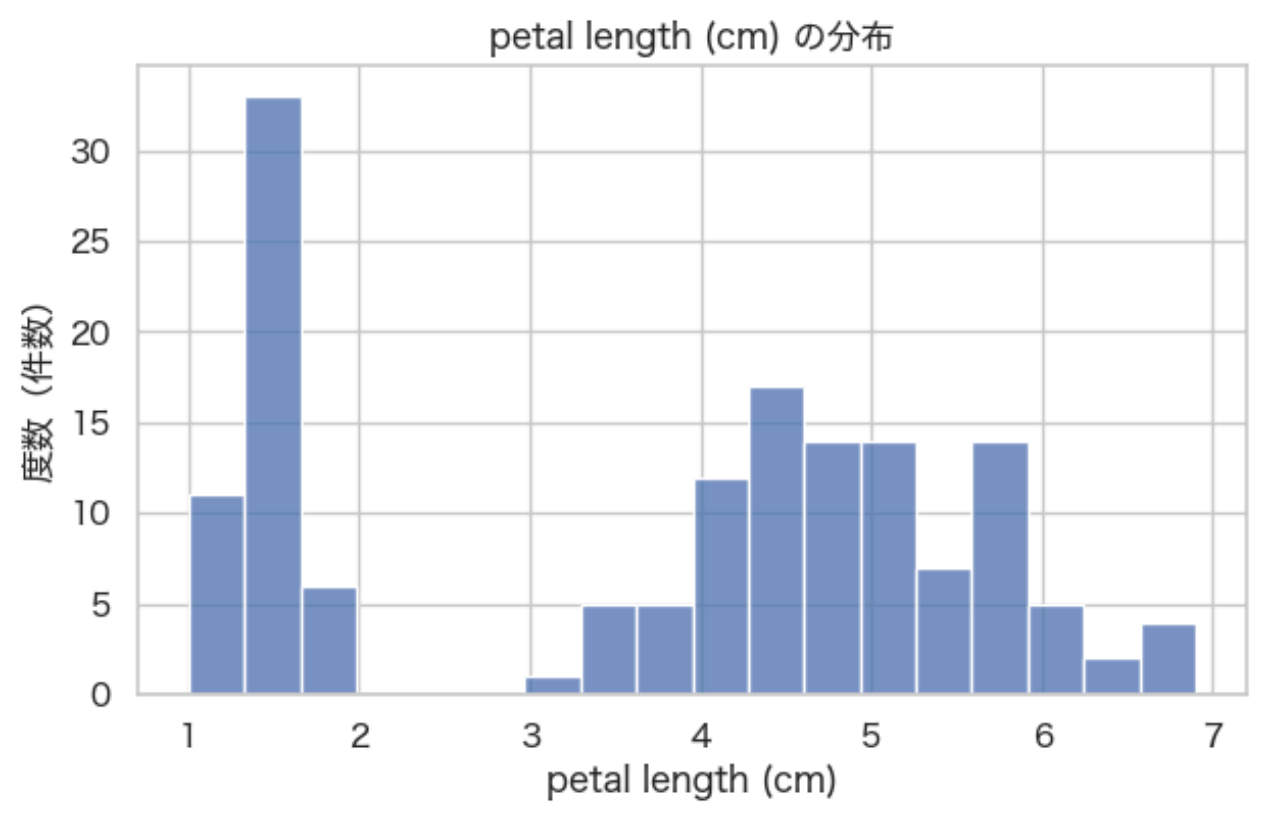
説明用の値：1.0, 1.2, 1.4, 1.5, 2.1, 2.5 cm

| 区間（階級） | 入る値 | 件数（度数） |
|---|---|---|
| 1.0以上、1.5未満 | 1.0, 1.2, 1.4 | 3 |
| 1.5以上、2.0未満 | 1.5 | 1 |
| 2.0以上、2.5以下 | 2.1, 2.5 | 2 |

これが**度数分布表**です。1.5は、2番目の区間に入ります。

今回の集計では、最後の階級だけ右端の値も含めます。

# 件数を高さにすると、ヒストグラムになる




横軸は花びらの長さ。縦軸は、その区間に入る花の件数。

# Notebookで実習③：表と図の対応

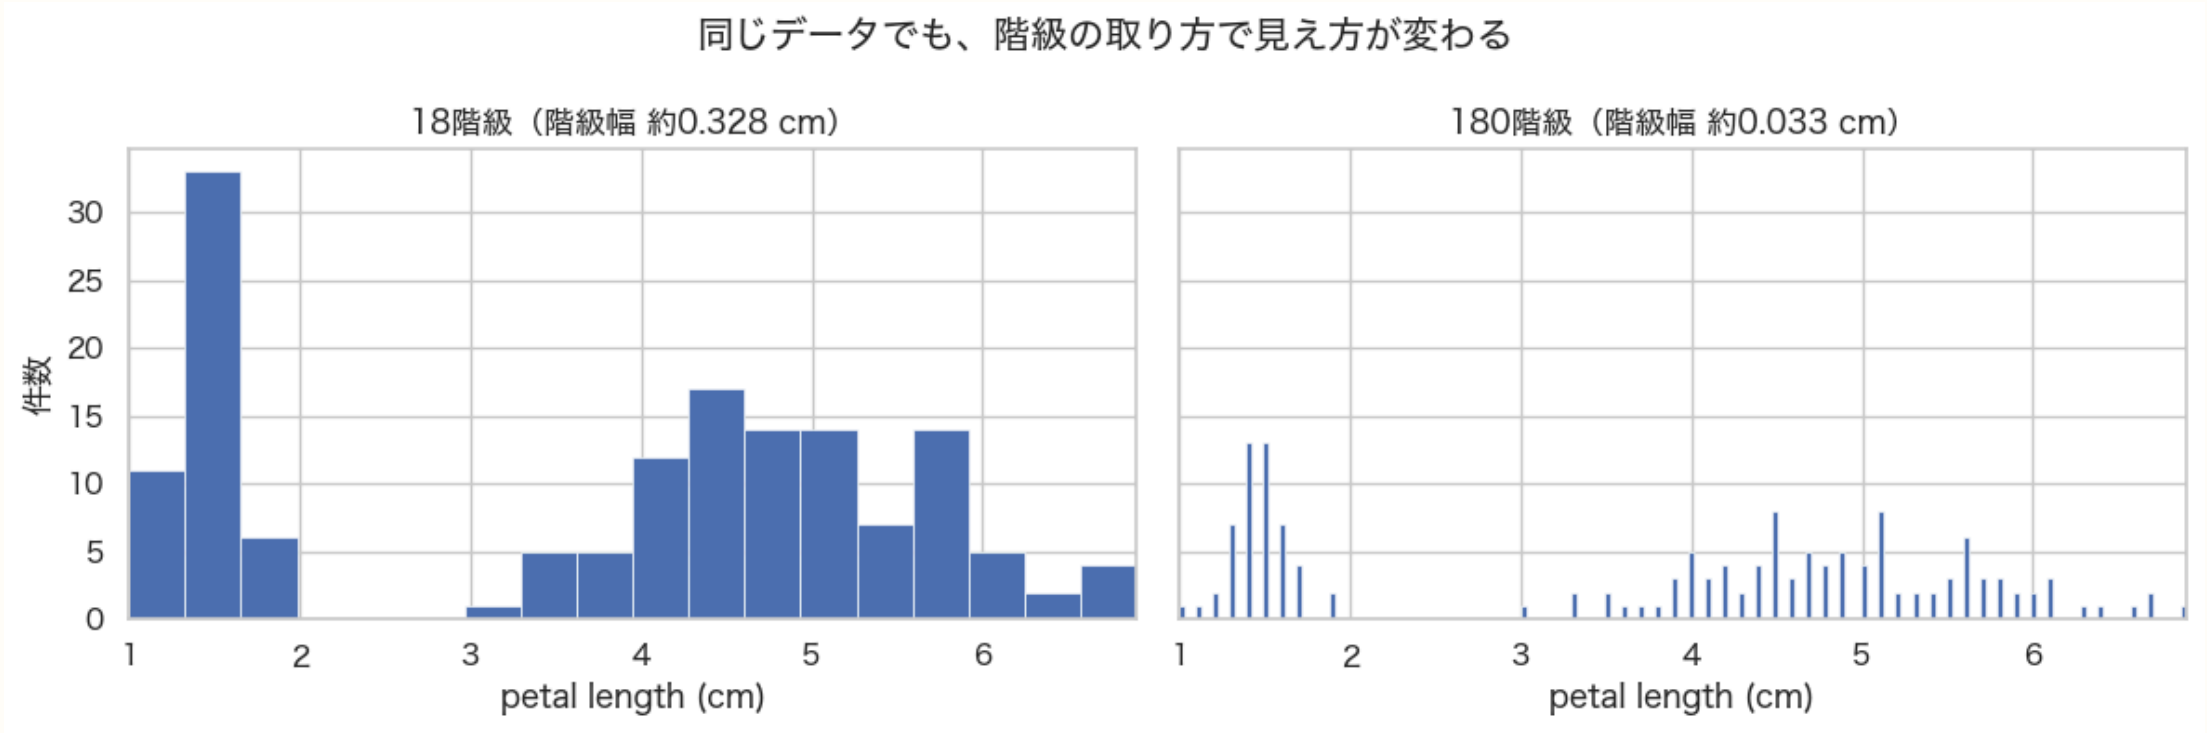
**「度数分布表から分布を調べる」**

**「度数分布表をヒストグラムで表す」**

1. 初期設定の `feature` と `n_bins = 18` で実行する
2. 描画ライブラリを読み込み、全体のヒストグラムを描く
3. 表の1区間を選び、図の横位置と高さを照らす

**確認すること：** 度数を合計すると、何件になる？

# 同じデータでも、区間の取り方で見え方が変わる




18階級と180階級。細かい方が、分布を読みやすいだろうか？

# Notebookで実習④：階級数を比べる

### 「階級を細かくしすぎるとどうなるか」

1. 18階級と180階級の図を描く
2. 棒の間に隙間が増える理由を考える
3. 余裕があれば `comparison_bins = [10, 30]` でも比べる

**確認すること：** どんな設定でも残る、大まかな特徴は？

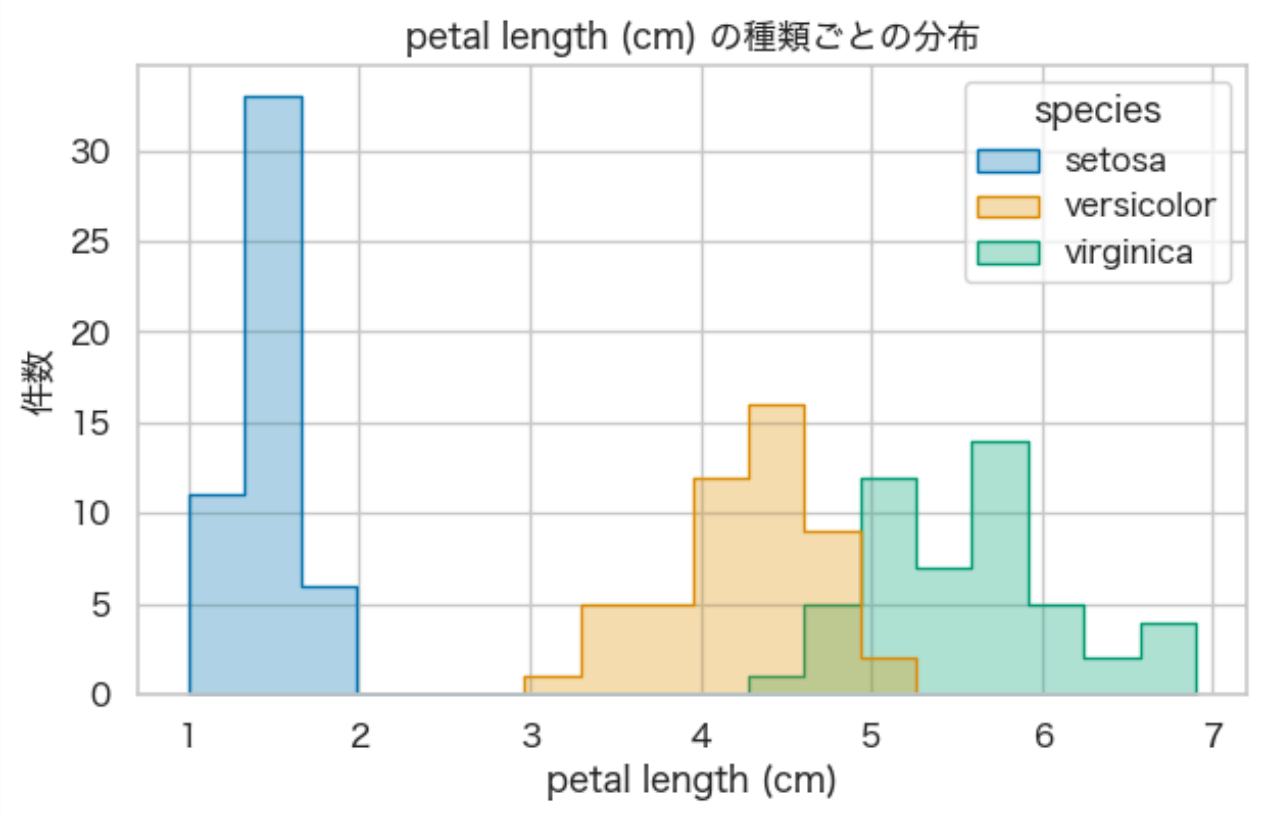
# ヒストグラムの山は、どの種類の花？

全体の分布には、花の種類の情報が隠れています。

**同じ測定項目・同じ区間のまま、種類で色を分けます。**

> 種類ごとの分布は、離れているだろうか？
> それとも、重なっているだろうか？

# 色分けすると、分布の重なりが見える




setosaは短い側。versicolorとvirginicaには、重なる区間がある。

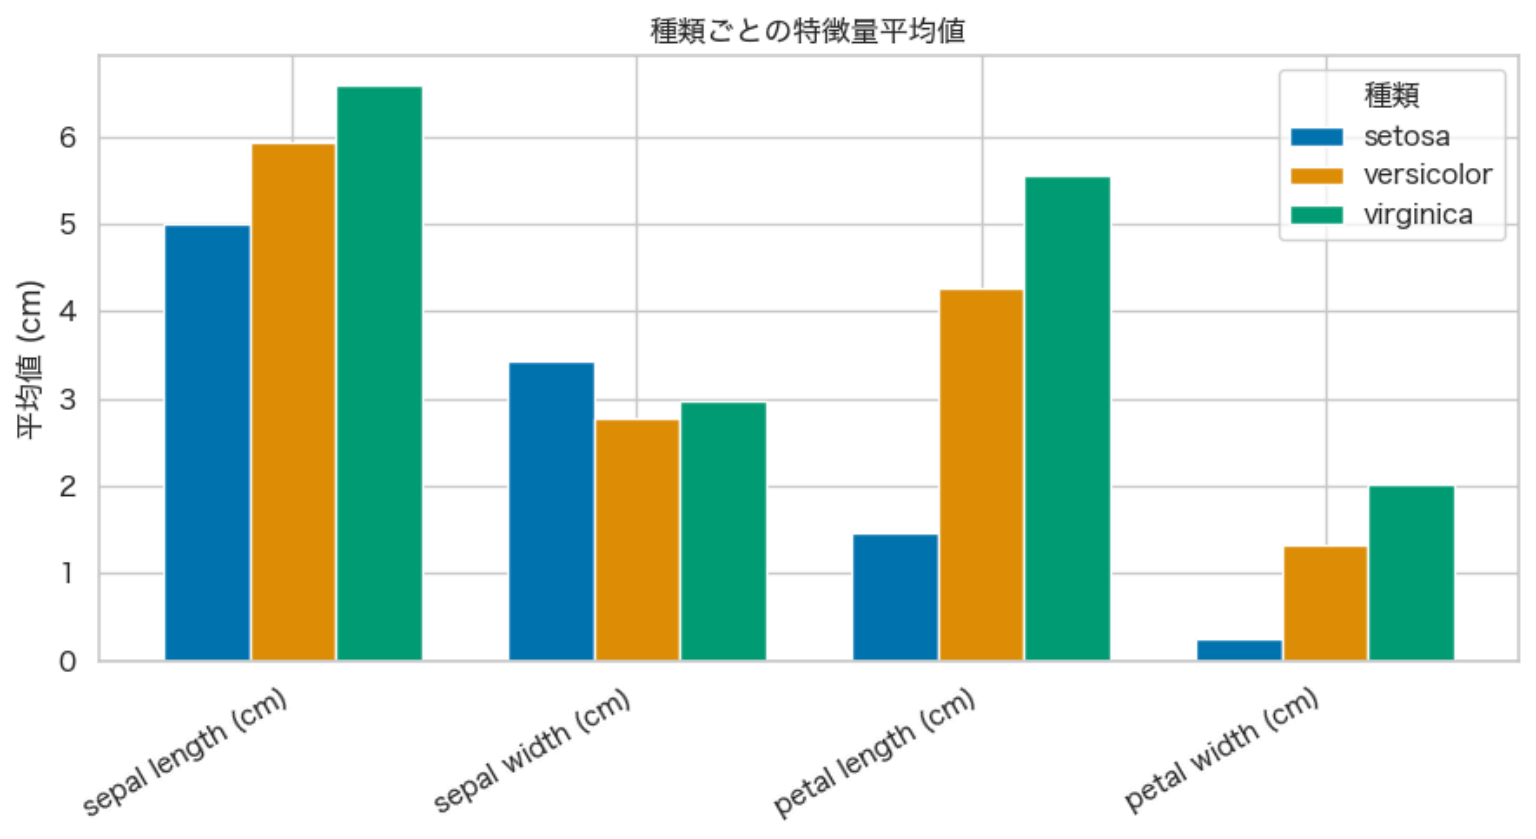
# Notebookで実習⑤：種類ごとの分布

## 「ヒストグラムを花の種類で色分けする」

1. 種類別ヒストグラムを実行し、重なる範囲を読む
2. 度数分布表の `feature` を別の測定項目に変える
3. **表、全体の図、種類別の図**の順に再実行する

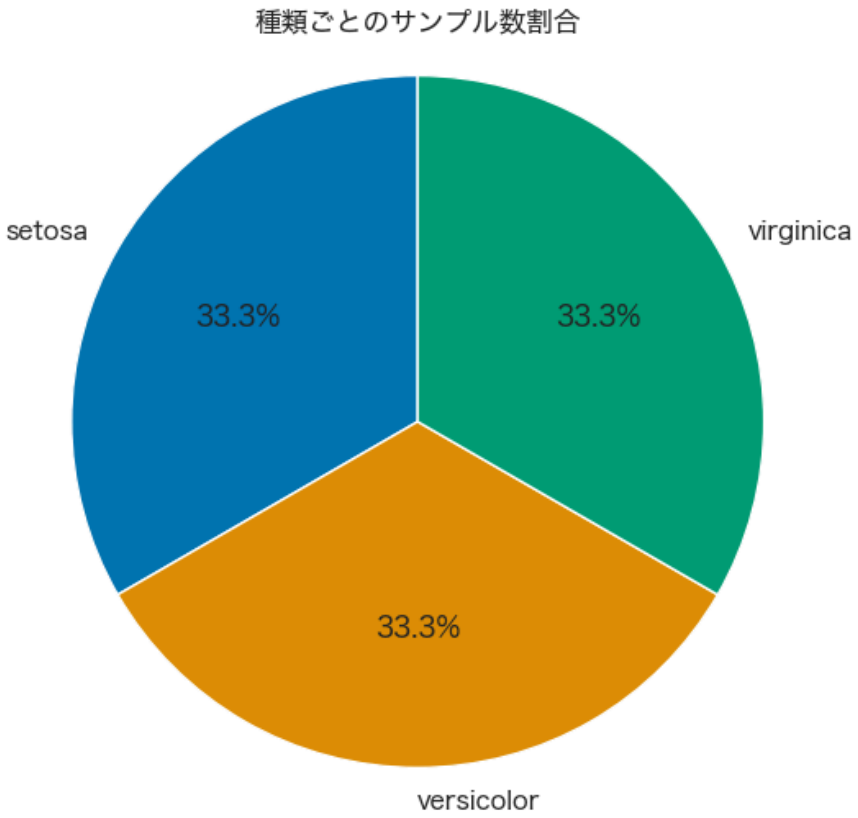
**確認すること：** 項目を変えると、種類の重なりも変わる？

# 種類ごとの平均を、棒の高さで比べる




同じ測定項目の中で比較する。平均だけでは、個々の値の重なりは分からない。

# このデータセットでは、各種類が3分の1




50 ÷ 150 × 100 ≒ 33.3%。自然界の割合まで分かるわけではない。

# Notebookで実習⑥：平均と割合

**「棒グラフで種類ごとの平均を比較する」**

**「円グラフで件数を割合として見る」**

1. 種類ごとの平均の表と、棒の高さを照らす
2. 円グラフの割合を、種類ごとの件数と照らす

**確認すること：** それぞれの図は、どんな問いに答えている？

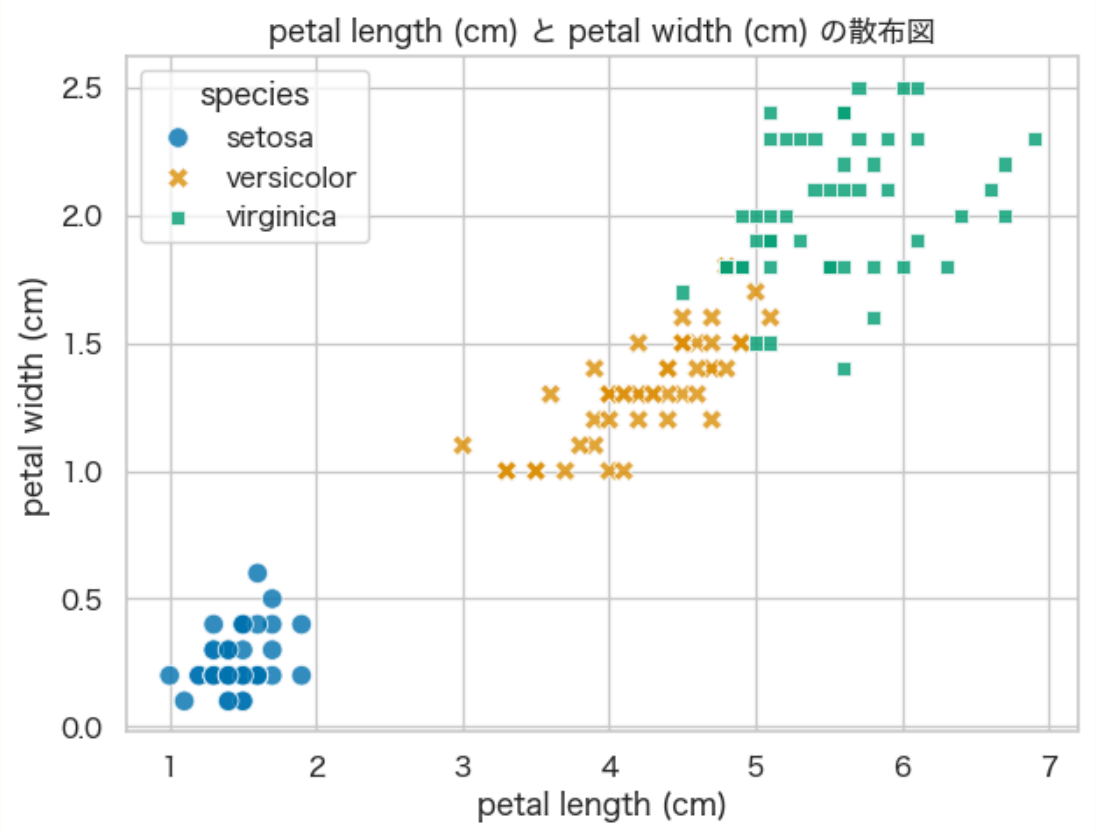
# 長さと幅を、一緒に見る

散布図では、**1点が1つの花**を表します。

| 点の情報 | 表すもの |
|---|---|
| 横の位置 | 花びらの長さ |
| 縦の位置 | 花びらの幅 |
| 色と記号 | 花の種類 |

1項目の分布では重なった種類も、見分けやすくなるでしょうか？

# 2つの項目で見る、種類ごとの集まり




点の集まりの向きと、種類どうしが重なる範囲に注目する。

# Notebookで実習⑦：組み合わせを変える

**「散布図で2つの測定項目を組み合わせる」**

1. 花びらの長さと幅で描き、種類の重なりを読む
2. `x_feature` と `y_feature` を別の組み合わせに変える
3. 種類別ヒストグラムと散布図を比べる

**確認すること：** どの組み合わせが、見分ける手がかりになりそう？

# 図から言えることを、書き分ける

## 事実

花びらの長さと幅の散布図では、setosaの点が他の2種から離れている。

## 解釈

花びらの長さと幅は、setosaを見分ける手がかりになりそう。

## 限界

新しい花をどれくらい正しく分類できるかは、この図だけでは分からない。

# 月ごとの変化を見るには？

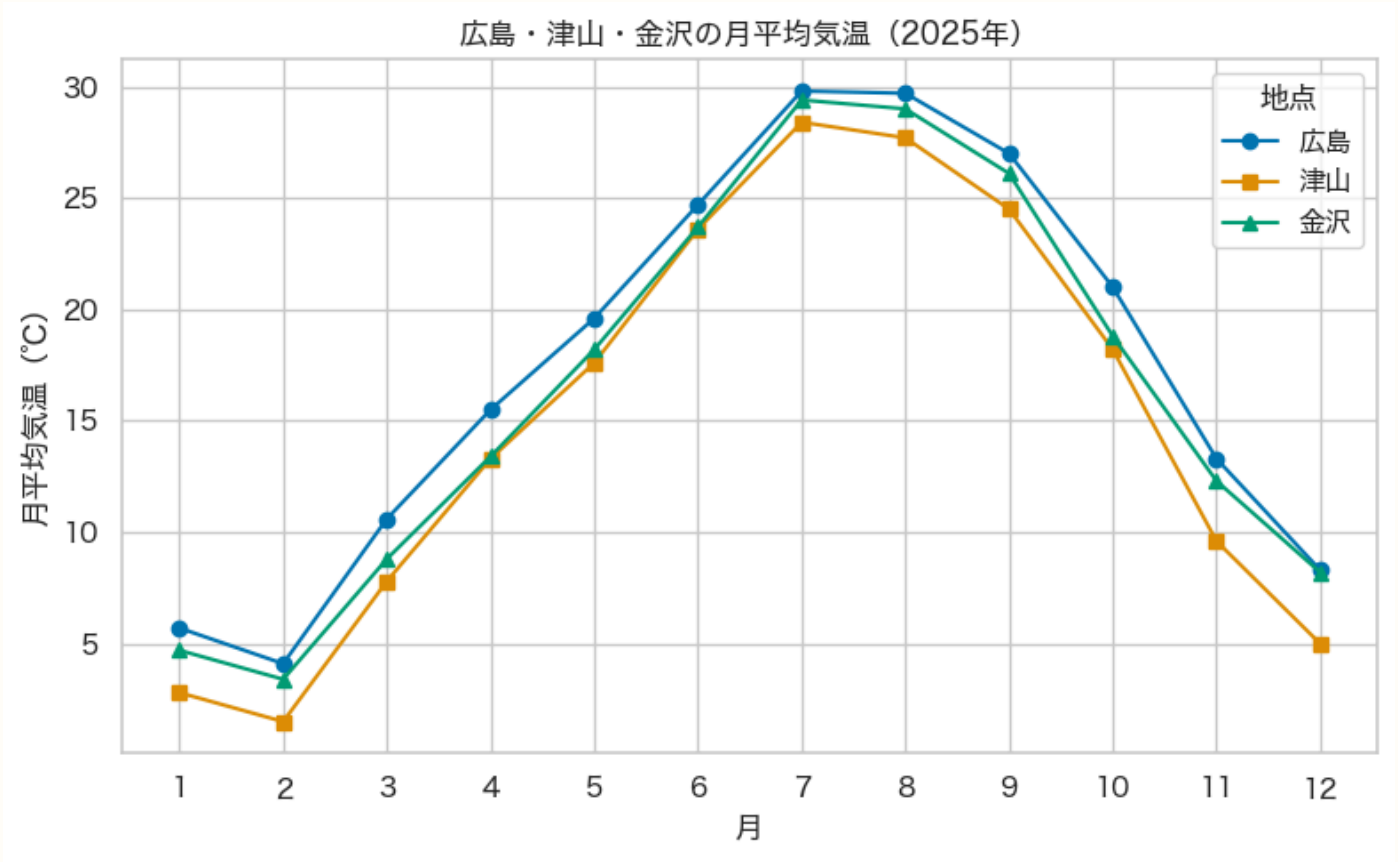
ここからは、花の測定記録から**気温の記録**へ切り替えます。

- 1行は1か月、2025年1〜12月の12行
- 広島・津山・金沢の各地点の月平均気温（℃）

**時間の順に並ぶ値**は、折れ線で結ぶと変化を追いやすくなります。

CSVをpandasで読み込みます。データはNotebookのdataフォルダにあります。

# 線の変化と、同じ月の地点差




各線の高い月・低い月と、同じ月の点の高さの差を読む。

# Notebookで実習⑧：気温の変化

## 「折れ線グラフで月平均気温の変化を見る」

1. CSVを読み込み、表と折れ線グラフを表示する
2. 各地点で、気温が最も高い月と低い月を探す
3. 地点間の差が大きい月と小さい月を比べる

**確認すること：** この1年分の図から、温暖化まで言える？

# 月平均と1年分のデータで分かる範囲

月平均では、**日ごとの気温の変動**は分かりません。

線は隣り合う月の点を結んでいます。
月の間の値を直接観測した線ではありません。

**2025年の1年分**なので、長期的な温暖化や、
複数年の平均的な気候は、この図だけでは判断できません。

# 問いに合わせて、グラフを選ぶ

| 知りたいこと | 使ったグラフ |
| --- | --- |
| どの範囲に値が多い？ | ヒストグラム |
| 種類ごとの平均はどう違う？ | 棒グラフ |
| 全体のうち、どれくらい？ | 円グラフ |
| 2つの項目には、どんな関係がある？ | 散布図 |
| 時間に沿って、どう変わる？ | 折れ線グラフ |

**同じデータでも、問いが変われば、見る図も変わります。**

# レポートは、演習A〜Cを1本に

| 演習 | 必須の内容 |
| --- | --- |
| A：配列とデータ確認 | 配列のコード・出力、Irisの説明・件数・基本統計量 |
| B：分布 | 列名・階級数、コード・度数分布表・種類別ヒストグラム |
| C：関係 | 軸と1点の意味、コード・散布図、図を根拠にした考察 |

必須の図は、**種類別ヒストグラムと散布図の2図**です。

Bでは分布と重なり、Cでは点の集まりと重なりを説明します。Cの考察はBとCの図を使い、事実・解釈・限界に分けます。

# Notebookで確認：レポートの仕上げ

**「まとめとレポート」**

- 本文テンプレートを使い、Word形式でまとめる
- 図や表は、選んだ列名・階級数・軸の設定とそろえる
- コードと結果に、自分の説明を添える
- 氏名・提出日と「分からなかった点」も記す

提出方法と詳細は、Notebookで確認してください。

# 花の長さや幅から、何が分かった？

自分が作った図を根拠に、説明してみましょう。

> どの種類が、どんな値の範囲に集まった？
>
> 項目を組み合わせると、何が見えた？
>
> まだ、この分析だけでは言えないことは？