回帰分析

データから数値を予測する

テーマ3

今日、確かめたいこと

気温が分かると、購入額をどこまで予測できる？

- 散布図と相関係数で、関係を調べる
- 回帰式を学習し、新しい入力から数値を予測する
- 学習に使わなかった期間で、予測のずれを調べる

最後は、レンタサイクルの貸出件数で試します。

回帰で予測するもの

回帰は、入力から **数値** を予測する方法です。

例	説明変数（入力）	目的変数（予測する値）
ペンギン	翼の長さ	体重
アイスクリーム	気温や湿度	平均購入額
レンタサイクル	気温や降水量	貸出件数

予測値と実測値は、一般には一致しません。

講義と実習の進め方

スライドで、考え方と図の見方を確認します。

「Notebookで実習」 が出たら、指定の見出しへ移ります。

本文は上から順に実行し、結果を確認したら戻ります。

> コードの暗記より、入力・出力と結果の意味を押さえます。

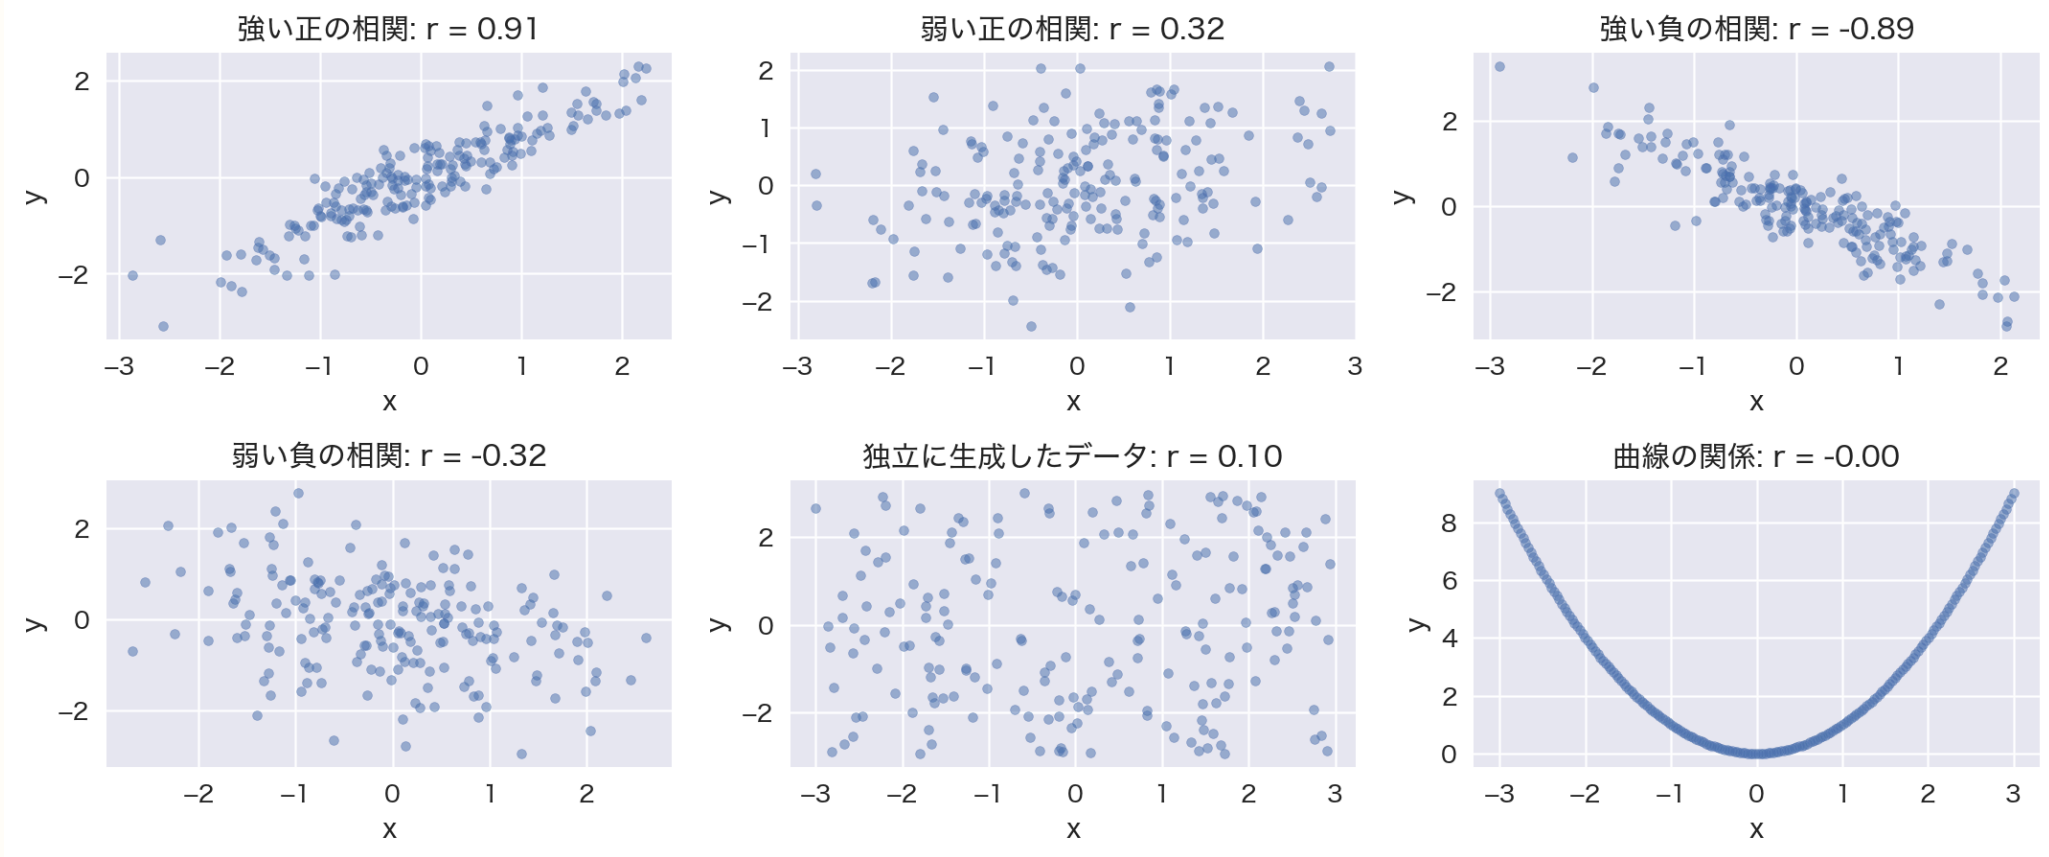
相関係数

相関係数 r は、**直線的な関係の向きと強さ** を表します。

値	散布図の傾向
$+1$ に近い	強い右上がり
-1 に近い	強い右下がり
0 に近い	直線的な関係が弱い

負の相関でも、絶対値が大きければ強い相関です。

散布図と相関係数の対応



人工データの例。右下は相関係数がほぼ0でも、曲線の関係があります。

相関から分かることの範囲

相関係数と散布図を一緒に確認します。

- 曲線の関係は、相関係数だけでは捉えにくい
- 少数の極端な値が、相関係数に影響する場合がある
- 相関だけで、原因と結果の関係は証明できない

気温と購入額には、季節など共通の要因も関わります。

Notebookで実習 ①

2. 散布図と相関係数

1. 6つの散布図を表示する
2. 正負の相関と、絶対値の大きさを比べる
3. 曲線の図で、相関係数だけでは分からないことを考える

実行したらスライドに戻り、結果を確認します。

単回帰の式

説明変数が1つの線形回帰を **単回帰** と呼びます。

$$\hat{y} = wx + b$$

記号	意味	ペンギンの例
x	入力	翼の長さ（mm）
$\hat{y}$	予測値	体重の予測値（g）
w	傾き	1mm長い入力での予測値の変化
b	切片	入力が0のときの式の値

ペンギンの翼の長さと体重

Palmer Penguinsの **Adelieだけ** を使います。

- 1行は1羽の記録
- 入力は翼の長さ、予測するのは体重
- この2列の欠損を除いた151羽を使用
- 種による違いを混ぜないよう、1種類に絞る

出典: Palmer Penguins。観測はKristen Gorman氏とPalmer Station LTER。データはCC0。

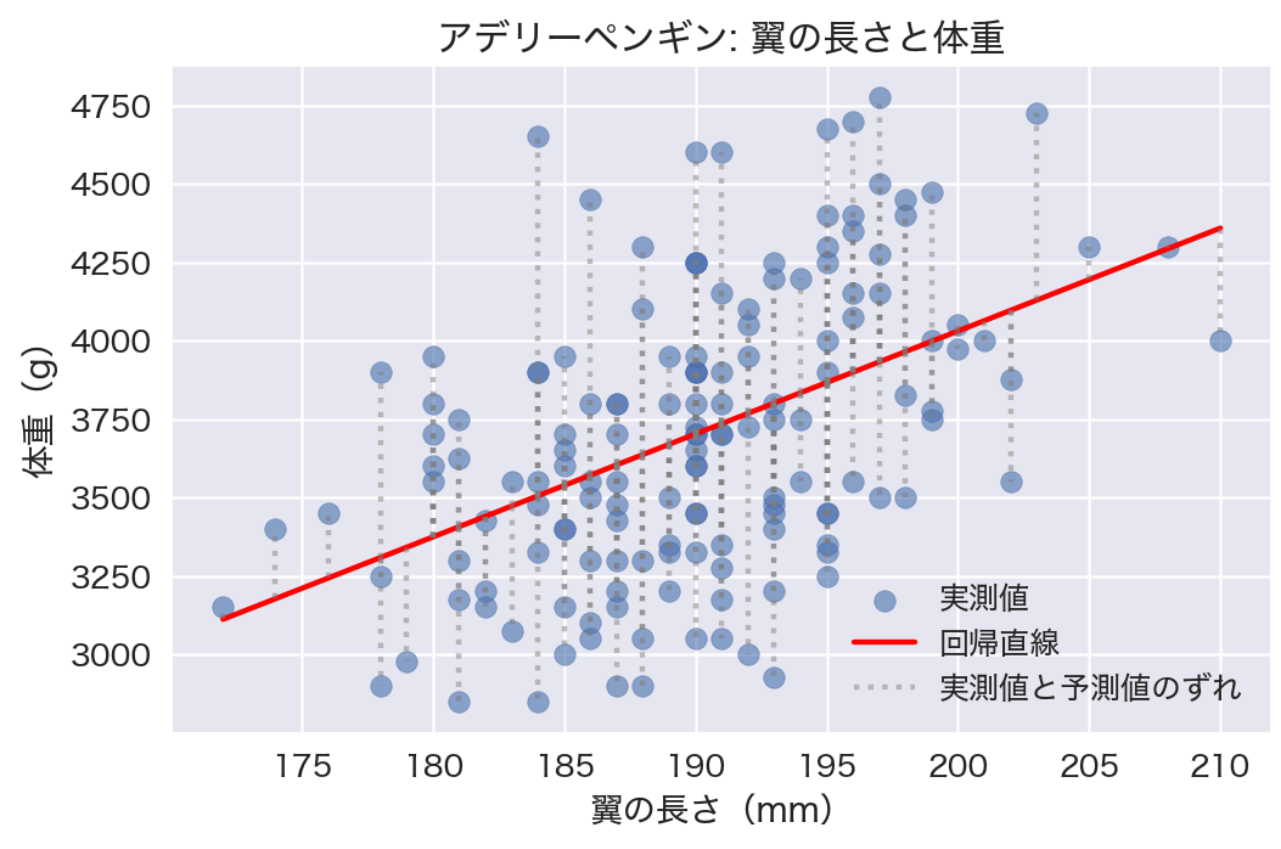
学習と予測のコード

```
X = adelie[['flipper_length_mm']]  # 表: (151, 1)
y = adelie['body_mass_g']          # 1列: (151,)
model = LinearRegression()
model.fit(X, y)
model.predict(X)
```

`fit(X, y)` で式を学習し、`predict(X)` で予測します。

傾きは `coef_`、切片は `intercept_` で確認できます。

ペンギンの回帰直線



灰色の縦線は、各個体の実測値と予測値のずれです。

傾きと切片の読み取り

体重の予測値（g） ≈ 32.83 × 翼の長さ（mm） − 2535.84

- 傾きは約32.83 g/mm
- 翼が1mm長い入力では、予測値が約32.83g大きくなる
- 190mmでの予測は約3702.2g

切片は翼の長さ0mmでの式の値です。

観測範囲外なので、実際の体重として解釈しません。

最小二乗法

学習では、実測値と予測値の **ずれの2乗の合計** を小さくします。

$$\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- y_i は実測値、$\hat{y}_i$ は予測値
- 正負のずれが打ち消し合わないよう、2乗する
- すべての点を通らなくてもよい

この方法で、傾き w と切片 b を求めます。

Notebookで実習 ②

3. ペンギンの翼の長さと体重で単回帰を試す

1. 回帰式と、図の縦方向のずれを確認する
2. 翼の長さを172〜210mmの範囲で変えて予測する
3. 傾きの単位と、予測値の変化を説明する

実行したらスライドに戻り、結果を確認します。

内挿と外挿

予測する入力	呼び方	注意点
観測した範囲の中	内挿	範囲内でも予測にはずれがある
観測した範囲の外	外挿	同じ関係が続くとは限らない

翼の長さ0mmで式を計算できても、妥当な予測とは限りません。

学習データへの当てはまりと、未知データの予測性能も区別します。

アイスクリームのデータ

`ice.csv` ：2003〜2012年の120か月。**1行は1か月** です。

役割	使用する値
目的変数	アイスクリームの平均購入額（円）
説明変数	日最高気温の平均（℃）、降水量（mm）
説明変数	平均湿度（%）、25℃以上の日数（日）

地域・購入額の集計対象・一次出典は元教材に記載がありません。
店舗の売上や個人の購入額とは断定せず、教材のデータとして扱います。

学習期間とテスト期間

期間	件数	役割
2003〜2010年	96か月	関係を調べ、式を学習する
2011〜2012年	24か月	学習に使わず、最後に評価する

今回は **時間順** に分け、後の期間への予測を試します。

散布図・相関係数・基準となる平均は、学習期間だけで求めます。

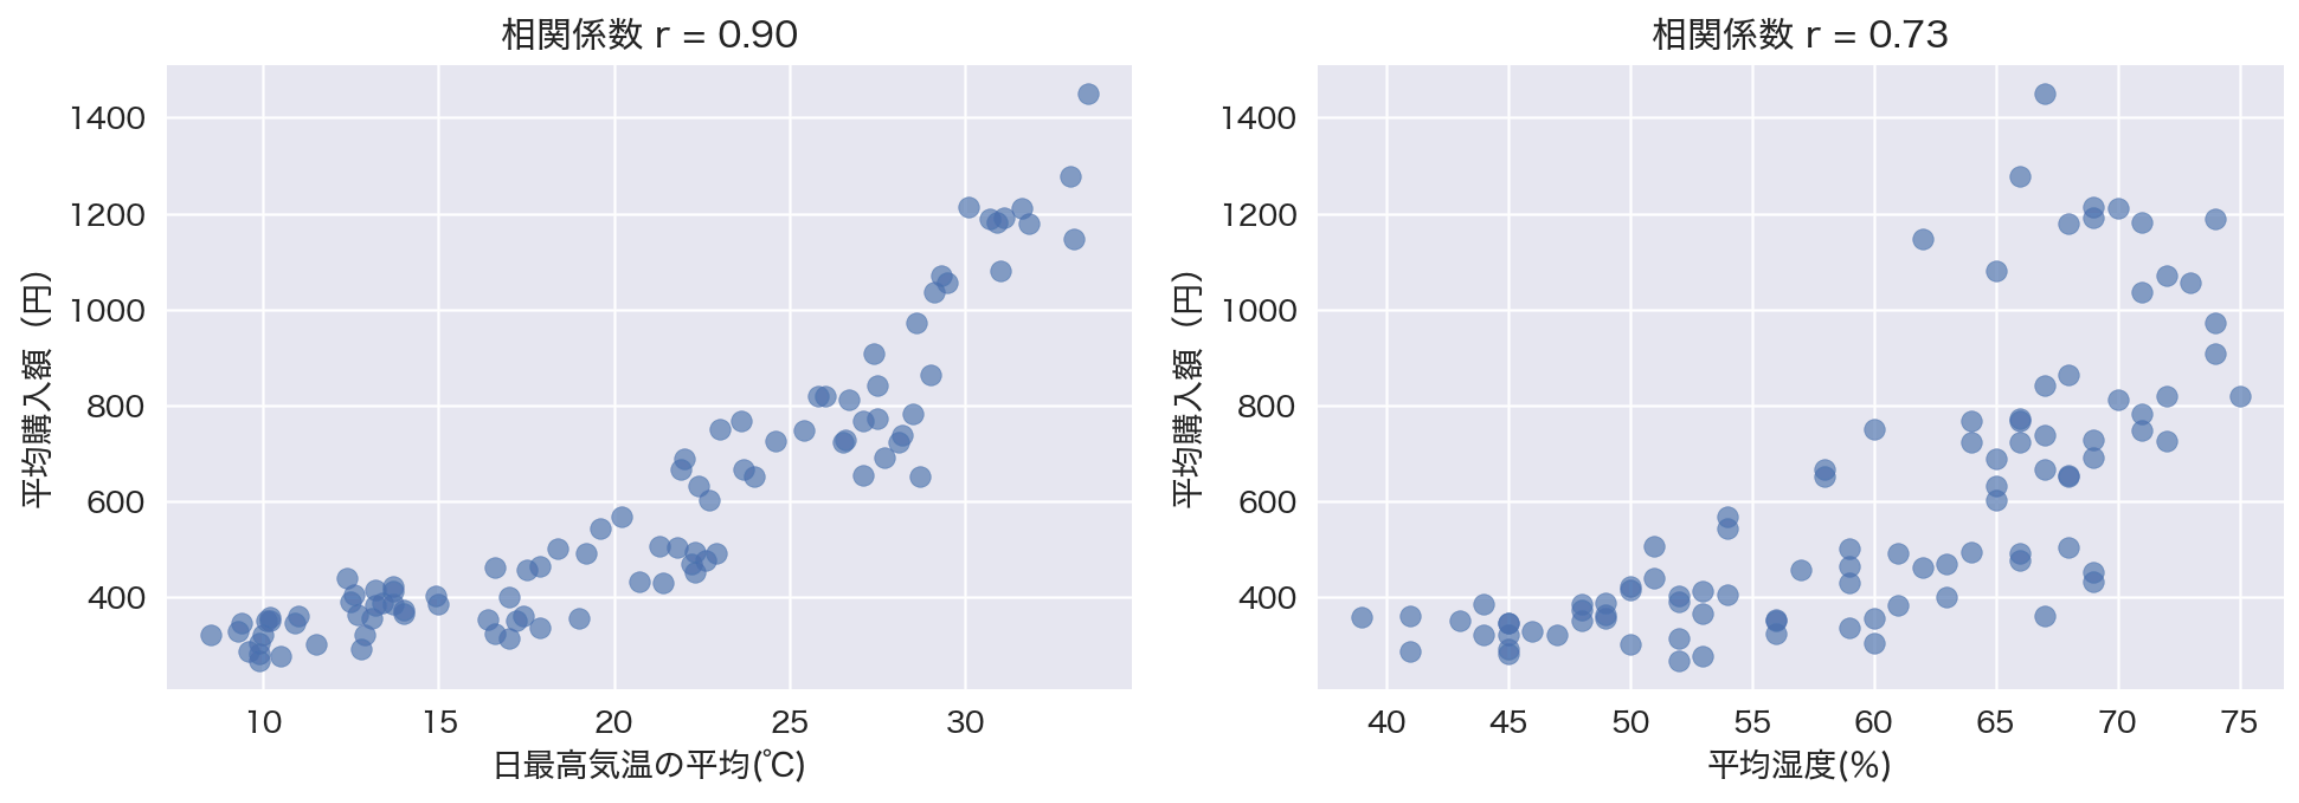
Notebookで実習 ③

4. アイスクリームのデータを読む／5. 学習期間とテスト期間を分ける

1. 表の列名・単位・欠損を確認する
2. 学習96件、テスト24件になっていることを確認する
3. なぜ未来のデータを学習に混ぜないか考える

実行したらスライドに戻り、結果を確認します。

気象と購入額の関係



学習期間の96か月。1点は1か月で、気温が同じくらいでも購入額はばらつきます。

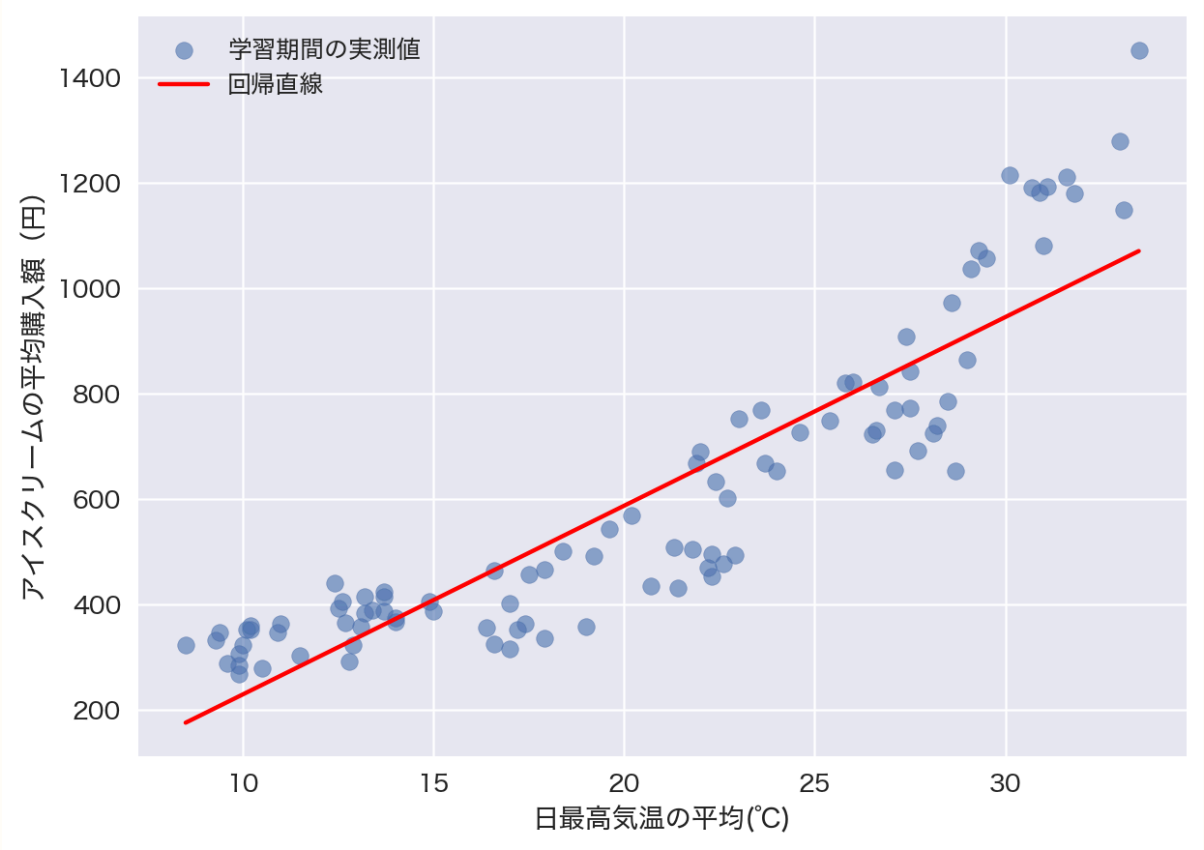
気温による単回帰

```
x_col = '日最高気温の平均(℃)'
single_model = LinearRegression()
single_model.fit(train_df[[x_col]], y_train)
new_weather = pd.DataFrame({x_col: [25.0]})
single_model.predict(new_weather)
```

25℃は、その月の日最高気温の平均 を表します。

ある1日の気温から、個人の購入額を予測する例ではありません。

気温と平均購入額の回帰直線



学習期間の観測範囲に直線を描きます。予測値は各月の購入額と必ず一致するわけではありません。

Notebookで実習 ④

6. 気象データと購入額の関係を見る／7. 気温から購入額を予測する（単回帰）

1. 散布図と相関係数の向きを確かめる
2. 回帰式の傾きと単位（円/℃）を確認する
3. 学習範囲内で入力する気温を変え、予測値を比べる

実行したらスライドに戻り、結果を確認します。

重回帰

説明変数を複数使う線形回帰を **重回帰** と呼びます。

$$\hat{y} = w_1 x_1 + w_2 x_2 + \cdots + w_p x_p + b$$

今回は、気温・降水量・湿度・高温日数の4つを使います。

```
multi_model = LinearRegression()
multi_model.fit(train_df[feature_columns], y_train)
```

説明変数を増やしても、未知データの誤差が必ず減るとは限りません。

重回帰の係数の意味

気温の係数は、基本設定で **約17.52円/℃** です。

> 他の3つの入力を固定すると、気温が1℃高い入力で
> 購入額の予測値が約17.52円増える。

- 他の変数も含めた式の性質を表す
- 単位が異なる係数の絶対値だけで、重要度を比べない
- 係数を、その変数の因果効果とは解釈しない

相関と重回帰の係数

湿度は購入額と正の相関がありますが、重回帰の係数は負です。

見ているもの	関係の捉え方
相関	2つの変数だけの関係
重回帰の係数	他の説明変数を固定した式の関係

説明変数どうしが強く関連すると、係数が不安定になることがあります。

これを **多重共線性** と呼びます。

Notebookで実習 ⑤

8. 複数の気象変数を使う（重回帰）

1. 4つの説明変数の係数と切片を表示する
2. 気温の係数の意味を、単位付きで説明する
3. 説明変数どうしの相関を確認する

実行したらスライドに戻り、結果を確認します。

小さな例で誤差を確かめる

残差を「実測値 − 予測値」とします。

実測値（円）	予測値（円）	残差（円）	絶対値（円）
500	400	+100	100
500	600	−100	100
500	200	+300	300

正負のまま平均すると、過大予測と過小予測が打ち消し合います。

MAEとRMSE

$$MAE = \frac{1}{n}\sum_{i}|y_i - \hat{y}_i|$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i}(y_i - \hat{y}_i)^2}$$

- MAE：ずれの絶対値の平均。先ほどの例は約166.7円
- RMSE：大きなずれをより強く反映。先ほどの例は約191.5円
- どちらも今回は円の単位で、小さいほど誤差が小さい

MAEが100円でも、すべての月の誤差が100円以内という意味ではありません。

比較する簡単な予測方法

回帰モデルと一緒に、**平均を使う2つの基準** も評価します。

方法	予測に使う値
学習期間の平均	96か月の購入額の平均を毎月予測
学習期間の同じ月の平均	例えば7月なら、学習期間の7月の平均

平均の計算にも、テスト期間の購入額は含めません。

季節性を使うだけで、どこまで予測できるかを比べます。

テスト期間の評価結果

方法	MAE（円）	RMSE（円）
学習期間の平均	266.9	327.0
学習期間の同じ月の平均	43.6	67.5
単回帰	119.6	146.1
重回帰	87.0	108.4

同じ月の平均が、この期間では最も小さい誤差でした。

重回帰が単回帰より良くても、簡単な基準との比較が必要です。

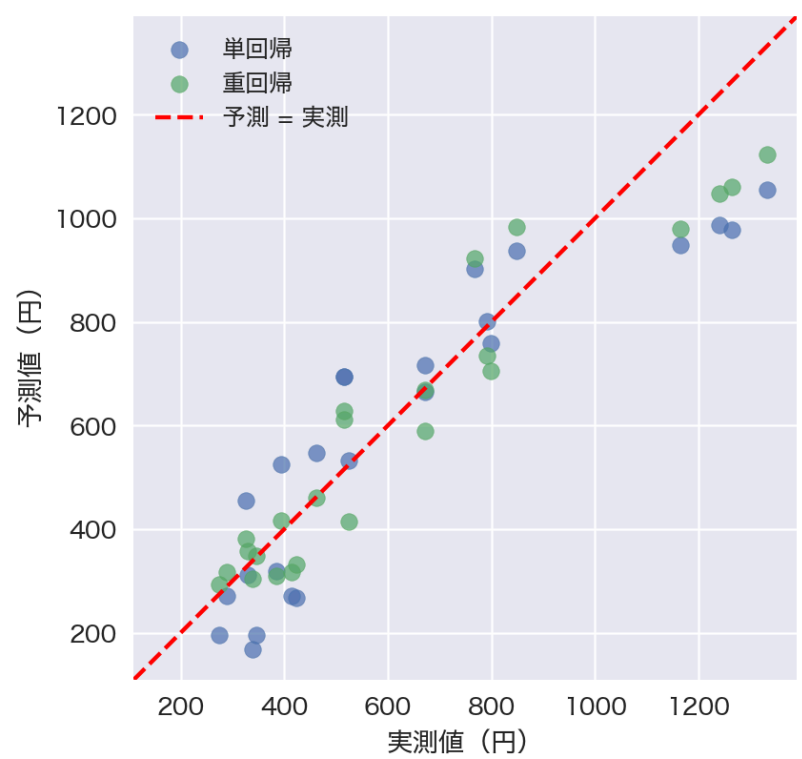
Notebookで実習 ⑥

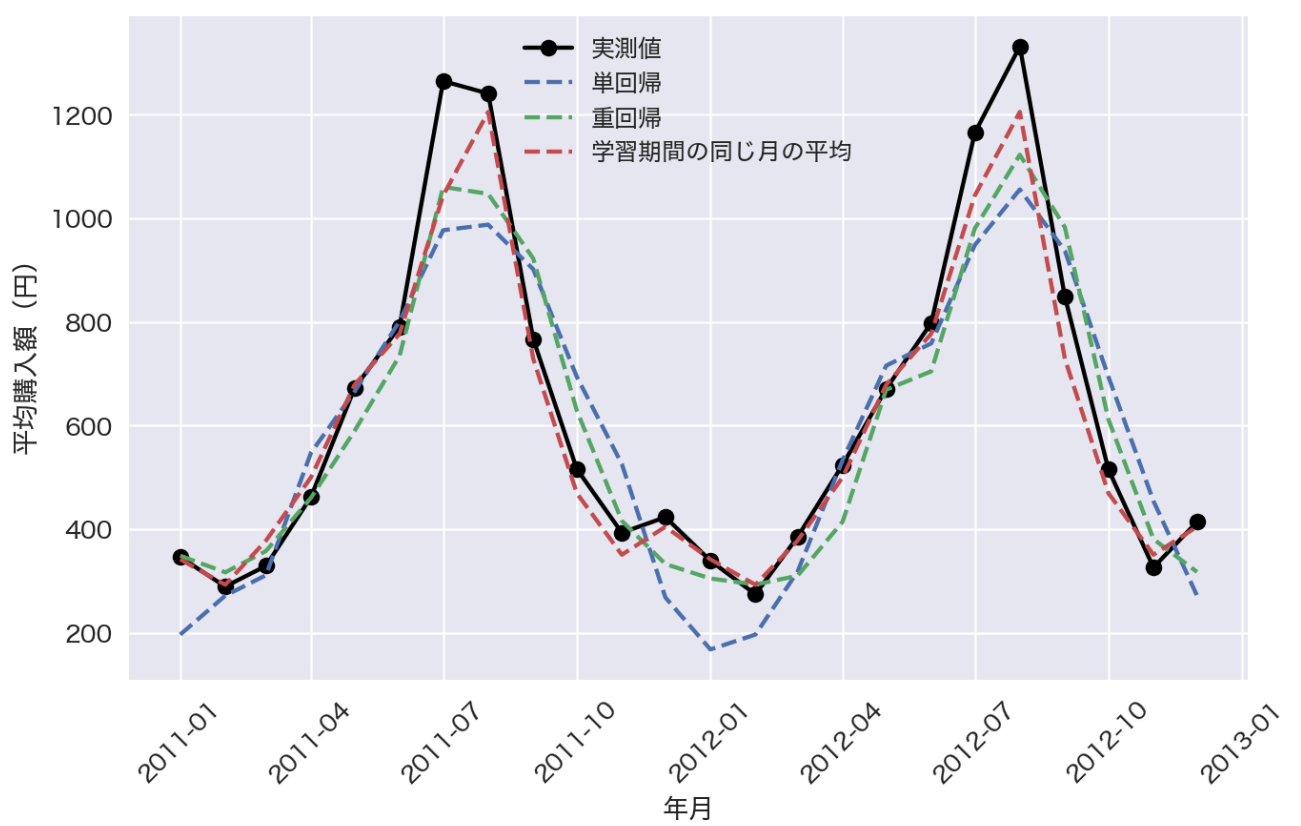
9. 学習に使わなかった期間で評価する

1. 小さな例で、残差・絶対誤差・2乗誤差を確認する
2. テスト期間の4つの方法のMAE・RMSEを比べる
3. 「変数を増やせば必ず良い」と言えるか考える

実行したらスライドに戻り、結果を確認します。

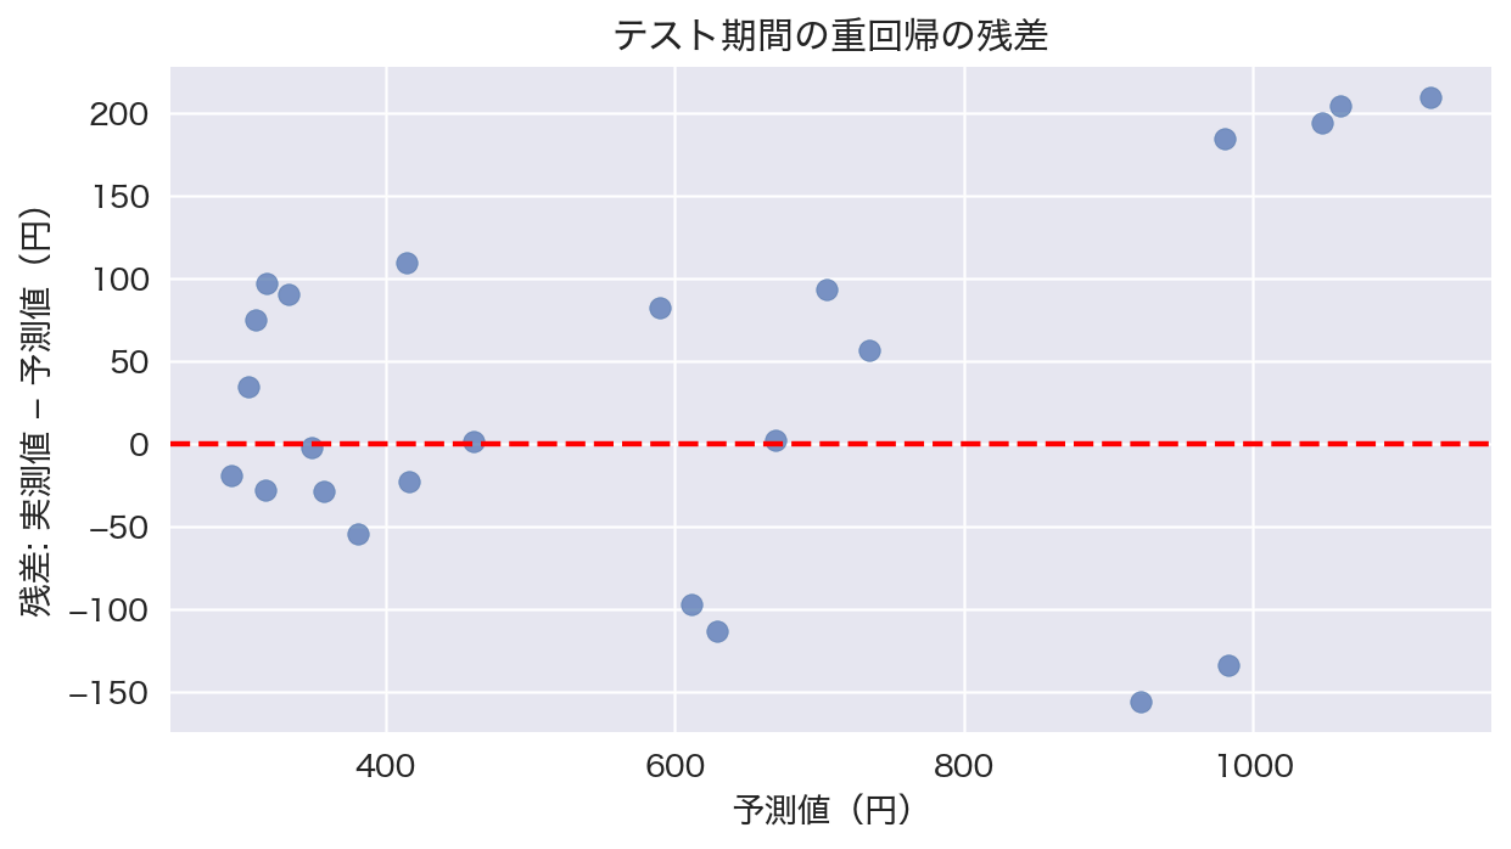
予測と実測の比較





左は対角線に近いほど良い予測。右は同じ月の値を比べ、ずれが大きい時期を探します。

残差からずれを読む



残差 = 実測値 − 予測値。正なら過小予測、負なら過大予測です。

Notebookで実習 ⑦

10. 予測と実測を図で比べる／残差から予測のずれを読む

1. 対角線の上・下が、過大予測・過小予測のどちらか確認する
2. 重回帰でずれが大きい月を、図と表から探す
3. その月の残差の符号を説明する

実行したらスライドに戻り、結果を確認します。

評価結果の限界

今回分かったのは、2011〜2012年での予測のずれです。

- 別の年や地域で、同じ精度になるとは限らない
- テスト結果を見て何度も調整すると、その期間に合わせてしまう
- 調整には、学習期間の中に別の検証期間を設ける

月が始まる前の予測では、気象値そのものの予報誤差も加わります。

演習はレンタサイクルのデータ

ソウルの18時の貸出件数を、気象からどこまで推定できる？

- 1点は、運用している日の18時の1時間分
- 目的変数は貸出件数。利用者数や駐輪場の在庫とは異なる
- 入力は気温・湿度・降水量・風速
- 学習は2017年12月〜2018年8月、テストは2018年9〜11月

Seoul Bike Sharing Demand（UCI、CC BY 4.0）。各演習のコードは単独で実行できます。

演習A：天気と貸出件数の関係

学習期間の散布図と相関係数を確認します。

1. 演習Aのコードセルをそのまま実行する
2. 4つの気象変数から1つ選ぶ
3. 関係の向きや、点のばらつきを2〜3文で説明する
4. 相関だけでは言えないことを書く

提出：コード・散布図・相関係数の表と、結果の説明。

演習B：気温による単回帰

気温の入力値を変えると、予測はどう変わる？

1. 20℃で実行し、回帰式と予測値を確認する
2. `bike_input_temp = 20.0` の数値を変更する
3. 学習期間の気温の範囲内で、コード全体を再実行する
4. 傾きの意味と、変更前後の入力値・予測値を書く

提出：変更後のコード・回帰式・図と、数値・説明。

演習C：変数を増やすと予測は良くなるか

重回帰・単回帰・2つの平均による基準を比べます。

1. 4つの方法のMAE・RMSEを、具体的な数値で比較する
2. 重回帰でずれが大きい1日の実測値・予測値・ずれの向きを書く
3. 気象以外に役立ちそうな情報を挙げる
4. 別の年や都市で同じ精度になると言えるか考える

提出：コード・係数表・評価表・比較図と、結果の説明。

レポートの構成と提出

提出物はWord形式のレポート1本です。

節	書く内容
1. 学んだことの要約	学んだ概念を自分の言葉で説明
2. 演習の結果と説明	演習A〜Cのコード・表・図・数値と説明
3. 分からなかった点	詰まった場所や疑問。なければ「なし」

Notebookのテンプレートを使い、氏名・提出日・出典を記入します。

提出先：大学の電子メール kazuhisa_fujita@komatsu-u.ac.jp

Notebookで実習 ⑧

まとめとレポート／演習A〜C／レポート本文（テンプレート）

1. 演習コードを実行し、Bの気温を変更する
2. 各欄にコード・結果と、自分の説明を入れる
3. 単位・学習期間・テスト期間・提出前チェックを確認する

実行したらスライドに戻り、結果を確認します。

今日のまとめ

データの関係を調べ、式で予測し、未知の期間で確かめました。

- 相関係数は、散布図と一緒に読む
- 単回帰と重回帰は、入力から数値を予測する
- 予測のずれは、MAE・RMSEと比較図で調べる
- 平均による基準と比べ、結果が通用する範囲を考える

レポートでは、自分の図や数値を根拠に説明しましょう。

資料とデータの出典

- 本文・演習コード：`notebook/lesson03_regression_basic_template.ipynb`
- ペンギン：Palmer Penguins（CC0）
- アイスクリーム：既存教材から引き継いだ `ice.csv`
- レンタサイクル：Seoul Bike Sharing Demand（UCI、CC BY 4.0）

図と評価値は、教材の同梱データと初期設定から計算しています。

列の説明・取得条件：`notebook/datasets/README.md`